فصل اول

فصل اول: محاسبات موازی بر روی سیستم‌های ناهمگون.....۵

۱ موازی‌سازی.....۵

۲ معماری کامپیوتر.....۷

۳ محاسبات ناهمگون یا **HETEROGENEOUS**.....۱۰

۴ معماری **heterogeneous** یا نامتجانس (ناهمگون).....۱۰

۵ قابلیت محاسباتی یا **compute capabilitiy**.....۱۳

۶ الگوی محاسباتی ناهمگون.....۱۳

۷ تفاوت ترد **CPU** با ترد **GPU**.....۱۵

۸ **CUDA** : یک پلتفرم برای محاسبات ناهمگون.....۱۵

۹ آیا برنامه‌نویسی با **CUDA** مشکل است؟.....۲۰

۱۰ محیط توسعه‌ی **CUDA**.....۲۱

فصل دوم : مدل برنامه‌نویسی CUDA.....۲۲

۱ معرفی مدل برنامه‌نویسی **CUDA**.....۲۲

۲ ساختار برنامه‌نویسی **CUDA**.....۲۳

۳ مدیریت حافظه.....۲۵

۳.۱ سلسله مراتب حافظه **GPU** (خلاصه).....۲۷

۳.۲ تفاوت فضای حافظه **host** و **device**.....۳۰

۳.۳ چرا در زبان **c** از **pointer to pointer** استفاده می‌شود.....۳۰

۴ مدیریت تردها.....۳۲

۴.۱ ابعاد **GRID** و **BLOCK**.....۳۴

۴.۲ دسترسی به متغیرهای **GRID/BLOCK** از سمت **HOST** و **DEVICE**.....۳۶

۴.۳ سلسله مراتب ترد.....۳۸

۵ راه‌اندازی یک کرنل **CUDA** ۳۸
۵.۱ رفتار آسنکرون ۴۰
۶ نوشتن کرنل ۴۰
۶.۱ توابع کرنل، توابع دارای محدودیت هستند ۴۱
۷ صحت سنجی کرنل ۴۲
۷.۱ تصدیق کد کرنل ۴۲
۸ رسیدگی به خطاها ۴۲
۹ کامپایل و اجرا ۴۳
۱۰ گرفتن تایم کرنل ۴۷
۱۱ گرفتن زمان اجرا با استفاده از تایمر **CPU** ۴۷
۱۱.۱ محدودیت‌هایی که وجود دارد را بشناسید ۵۰
۱۲ گرفتن زمان با استفاده از **nvprof** ۵۰
۱۲.۱ مقایسه‌ی پرفرمنس نرم‌افزار برای بیشینه کردن محدودیت‌های نظری ۵۲
۱۳ سازماندهی کردن تردهای موازی ۵۳
۱۴ اندیس‌گزاری ماتریس‌ها با بلاک‌ها و تردها ۵۳
۱۵ جمع کردن ماتریس‌ها ۵۷
۱۶ جمع کردن ماتریس‌ها با استفاده از **1D grid and 1D block** ۶۳
۱۷ جمع ماتریس‌ها با استفاده از گرید **2D** و بلاک **1D** ۶۴
۱۸ مدیریت **device** ۶۶
۱۹ استفاده از **runtime API** برای اطلاعات گرفتن از **GPU** ۶۶
۲۰ مشخص کردن بهترین **GPU** ۶۹
۲۱ استفاده از **nvidia-smi** برای گرفتن اطلاعات **GPU** ۷۰
۲۲ تنظیم کردن **device** در **runtime** ۷۲

فصل سوم: مدل اجرایی CUDA ۷۳

۱ معرفی مدل اجرایی **CUDA** ۷۳

۲ گذری بر معماری **GPU** ۷۳

۲.۱ عدد جادویی : ۳۲ ..... ۷۵

۲.۲ **SM** : قلب معماری **GPU** ۷۶

۳ معماری **Fermi** ۷۷

۴ معماری **Kepler** ۷۹

۵ بهینه‌سازی بر اساس **profiling** ۸۳

۶ درک طبیعت اجرای رشته ۸۵

۷ رشته‌ها و **thread block** ها ۸۵

۷.۱ **Thread block** : از دید نرم‌افزاری و از دید سخت‌افزاری ۸۷

۸ انشعاب رشته ۸۷

۸.۱ نکات کلیدی ۹۵

۹ تقسیم منابع ۹۶

۱۰ **Latency Hiding** ۹۸

۱۰.۱ توان عملیاتی و پهنای باند ۹۹

۱۱ تصرف یا **Occupancy** ۱۰۱

۱۱.۱ راهنمای انتخاب ابعاد **grid,block** ۱۰۵

۱۲ سنکرون کردن ۱۰۵

۱۳ مقیاس پذیری ۱۰۶

۱۴ توزیع موازی ۱۰۸

۱۵ چک کردن رشته‌های فعال توسط **nvprof** ۱۰۸

۱۶ چک کردن عملیات‌های حافظه با **nvprof** ۱۰۹

۱۷ افزایش میزان موازی‌سازی ۱۱۰
۱۷.۱ متریک‌ها و پرفرمنس ۱۱۳

فصل اول: محاسبات موازی بر روی سیستم‌های ناهمگون

۱ موازی‌سازی

امروزه، موازی سازی در همه‌جا وجود دارد، و برنامه‌نویسی موازی به عنوان یک مبحث جدایی ناپذیر در دنیای برنامه‌نویسان به شمار میآید. موازی‌سازی در چندین سطوح، مرتبط با معماری طراحی می باشد. به صورت کلی دو نوع موازی‌سازی وجود دارد:

- موازی‌سازی **Task**
- موازی‌سازی **Data**

موازی‌سازی **Task** وقتی کاربرد پیدا می‌کند که چندین **task** و یا چندین تابع وجود دارد که می‌توانند به صورت مستقل از همدیگر کار کنند. در واقع موازی‌سازی در مورد **Task** تلاش می‌کند که توابع را بر روی هسته‌های مختلف تقسیم کند.

موازی‌سازی **Data** وقتی کاربرد پیدا می‌کند که داده‌های زیادی وجود دارد که امکان پردازش همزمان بر روی آن‌ها وجود دارد. در واقع موازی‌سازی **Data** بر روی تقسیم داده‌ها بر روی چندین هسته تمرکز دارد.

برنامه‌نویسی **CUDA** برای مسایلی که در آن‌ها امکان محاسبات موازی بر روی داده‌ها وجود دارد، بسیار مناسب به شمار میآید. عمده تمرکز این کتاب نحوه حل برنامه نویسی موازی بر روی داده ها با استفاده از برنامه‌نویسی **CUDA** می‌باشد. بسیاری از برنامه‌هایی که برای پردازش داده‌های بزرگ هستند می‌توانند از مدل **data-parallel** برای افزایش سرعت محاسبات خود بهره ببرند. پردازش **data-parallel** داده‌ها را بر روی تردهای موازی نگاشت می‌کند.

اولین گام در طراحی برنامه **data-parallel** این است که داده‌ها را بر روی تردها پخش کنیم، که هر ترد وظیفه‌ی کار بر روی قسمتی از داده را بر عهده میگیرد. در حالت کلی، دو رویکرد برای تقسیم دیتا وجود دارد: تقسیم **block** ی و تقسیم **cyclic** . در تقسیم **block** ی، بسیاری از المان‌های متوالی از داده، به صورت دسته‌ای در کنار هم هستند. هر دسته بر روی یک ترد انتساب داده شده، و تردها در هر لحظه فقط یک دسته از این داده‌ها را پردازش می‌کنند. در تقسیم **cyclic** ،میزان داده کمتری در دسته‌ها قرار میگیرد، پس طبیعتا تعداد دسته‌ها بیشتر از روش **block** ی خواهد بود. تردهای همسایه، دسته‌های همسایگی را نیز دریافت می‌کنند و هر ترد می‌تواند بیش از یک دسته را پردازش کند. انتخاب یک دسته جدید برای پردازش بر روی ترد، موجب پریدن هر چند دسته که در ترد است می‌شود. تصویر زیر دو

مثال از نحوه‌ی تقسیم دیتای یک بعدی را نمایش میدهد. در تقسیم **block** ی، هر ترد تنها یک قسمت از داده‌ها را برای پردازش برمیدارد، و در تقسیم **cyclic** ، هر ترد بیشتر از یک دسته را برای پردازش برمیدارد.(هر رنگ مرتبط با یک ترد است، پس در این مورد چهار ترد وجود دارد).

Block partition: each thread takes one data block

Cyclic partition: each thread takes two data blocks

در تصویر زیر سه مثال ساده از دیتای دو بعدی را نشان میدهد: تقسیم **block**ی در راستای محور **y**، تقسیم **block** ای در راستای هر دو محور، و تقسیم **cyclic** در راستای محور **x** . بقیه‌ی حالت‌های ممکن به عنوان تمرین به عهده خودتان گذاشته می‌شود.

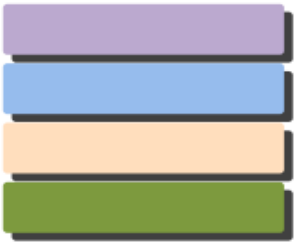

Block partition on one dimension

Block partition on both dimensions

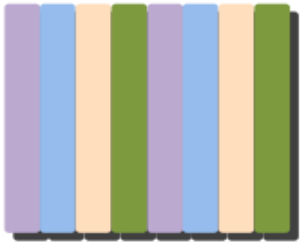

Cyclic partition on one dimension

معمولا، داده به صورت یک بعدی ذخیره می‌شود، حتی اگر یک دید چند بعدی از داده داشته باشیم، همچنان بر روی حافظه به صورت یک بعدی نگاشت می‌شود. مشخص کردن این که چطور داده بر روی تردها تقسیم شود معمولا وابسته به این است که به صورت فیزیکی چطور ذخیره شده است، همچنین این که ترتیب تردها به چه صورت می‌باشد. این که چطور تردها را مدیریت می‌کند تاثیر زیادی بر روی عملکرد کلی برنامه خواهد داشت.

عملکرد برنامه معمولا حساس به **block size** هست. مشخص کردن بهترین میزان تقسیم در روش **block** ی و در روش **cyclic** به معماری کامپیوتر وابسته است. در این مورد در ادامه بیشتر یاد خواهیم گرفت.

۲ معماری کامپیوتر

چندین روش برای طبقه‌بندی کردن معماری کامپیوترها وجود دارد. یکی از این روش‌ها که خیلی استفاده می‌شود طبقه‌بند فلین است، که معماری کامپیوتر را به چهار دسته مختلف تقسیم می‌کند، این طبقه بندی بر اساس نحوه‌ی جریان یافتن **instructions** و **data** بر روی هسته‌های سیستم عامل هست که شامل موارد زیر می‌شود:

- Single Instruction Single Data (SISD)
- Single Instruction Multiple Data (SIMD)
- Multiple Instruction Single Data (MISD)
- Multiple Instruction Multiple Data (MIMD)

معماری یک دستورالعمل یک داده اشاره به کامپیوترهای قدیمی دارد: یک معماری سریال. که تنها یک هسته در چنین سیستم عاملی وجود دارد. و در هر لحظه تنها یک جریان دستورالعمل قادر به اجراست، و عملیات‌ها بر روی یک جریان داده اعمال می‌شوند.

یک دستورالعمل چند داده اشاره به نوعی از معماری موازی دارد. در این معماری چندین هسته وجود دارد. همه‌ی هسته‌ها یک جریان دستورالعمل را در هر لحظه اجرا می‌کنند، و هر کدام بر روی جریان داده‌های مختلف اجرا می‌شوند. کامپیوترهای برداری معمولا از نوع **SIMD** هستند، و بیشتر کامپیوترهای مدرن یک معماری **SIMD** را به کار میگیرند. شاید بزرگترین مزیت **SIMD** این است که، در لحظه نوشتن کد بر روی **CPU** ، برنامه‌نویس می‌تواند به صورت سریال فکر کند ولی به پرفرمنس یک عملیات موازی دست پیدا کند چرا که کامپایلر جزییات پیاده‌سازی را برعهده خواهد گرفت.

چندین دستورالعمل یک داده به یک معماری غیر رایج اشاره دارد، که هر هسته بر روی یک جریان داده‌ی یکسان با چندین جریان دستورالعملی متفاوت عملیاتی را انجام میدهد.

چندین دستورالعمل چندین داده به معماری رایج موازی سازی اشاره دارد که در آن چندین هسته بر روی چندین جریان داده عملیاتی را انجام میدهد، و هر کدام به صورت مستقل دستورالعمل‌هایی را اجرا می‌کنند. بسیاری از معماری‌های **MIMD** یک کامپوننت زیرین **SIMD** را نیز در خود دارند.

در سطح معماری، پیشرفت‌های زیادی به منظور رسیدن به موفقیت‌های زیر صورت پذیرفته است:

- کاهش تاخیر
- افزایش پهنای باند
- افزایش توان عملیاتی

تاخیر یا latency به میزان زمانی اطلاق می‌شود که یک عملیات شروع و پایان می‌پذیرد، و معمولا در واحد میکروثانیه بیان می‌شود. **پهنای باند** مقدار داده‌ای است که می‌تواند در یک واحد زمانی پردازش شود، معمولا پهنای باند را تحت **megabytes/sec** و یا **gigabytes/sec** بیان می‌کنند. **توان عملیاتی** میزان دستوراتی است که می‌توان در یک واحد زمانی انجام داد، که معمولا تحت عنوان **gflops** بیان می‌شود(**giga float operation per second**) ، مخصوصا در فیلدهای علمی که محاسبات سنگین بر روی محاسبات ممیز شناور انجام می‌شود. تاخیر زمان سپری شده برای تکمیل شدن یک عملیات را نشان میدهد، در حالی که توان عملیاتی تعداد دستوراتی است که می‌توان در یک واحد زمانی انجام داد را نمایش میدهد.

معماری کامپیوتر همچنین می‌تواند بر اساس سازماندهی حافظه تقسیم شود، بر این مبنا کامپیوترها به دو دسته تقسیم می‌شوند.

➤ **Multi-node with distributed memory**(چند نودی با حافظه توزیع شده)

➤ **Multiprocessor with shared memory**(چندپردازشگری با حافظه اشتراکی)

در یک سیستم چند نودی، موتورهای محاسباتی با ابعاد بزرگ ساخته شده که با شبکه به هم متصل هستند. هر پردازشگر حافظه محلی خود را دارد، و پردازشگرها می‌توانند محتوای حافظه محلی خود را بر روی شبکه به اشتراک بگذارند. شکل زیر یک سیستم چند نودی با حافظه توزیع شده را نمایش میدهد. چنین سیستم‌هایی را معمولا کلاستر می‌نامند.

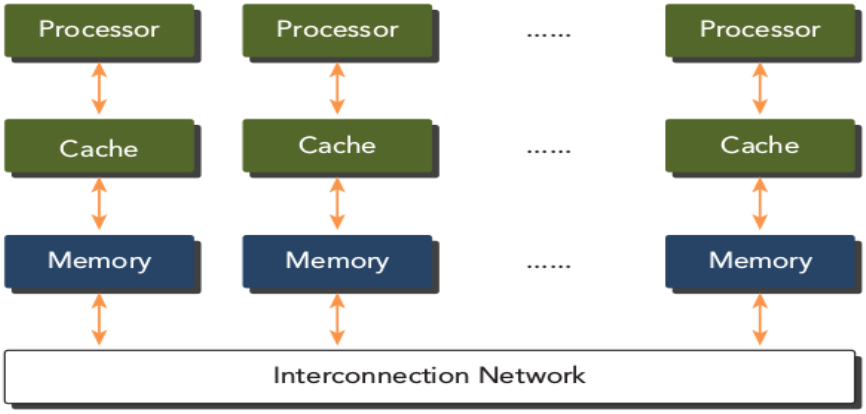

معماری چند پردازنده‌ای (چند هسته‌ای) معمولا از رنج دو پردازنده‌ای(**dual processor**) تا هزاران یا صدها پردازنده می‌باشد. این پردازنده‌ها به صورت فیزیکی به یک حافظه مشترک متصل هستند، که در شکل بعدی مشخص می‌باشد، یا این که با یک لینک با تاخیر پایین(مثل **PCI-Express** یا **PCIe**) به هم متصل هستند.

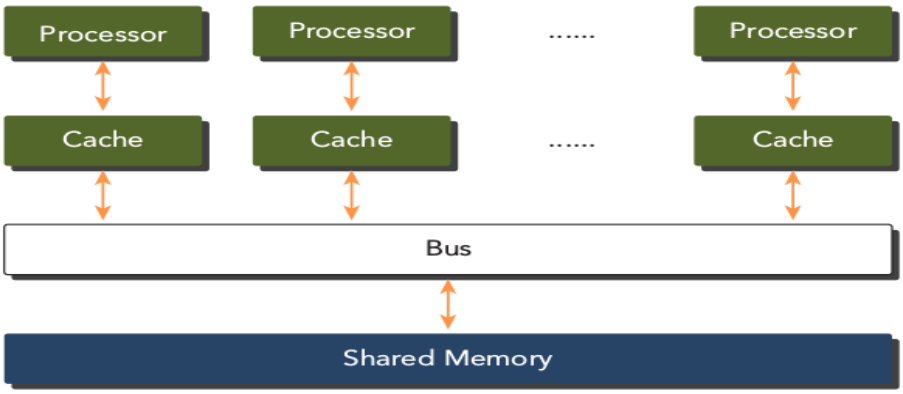

اصطلاح **many-core** معمولا برای توصیف معماری چندهسته‌ای مخصوصا با تعداد هسته‌های بالا (ده ها یا صدها هسته) استفاده می‌شود. اخیرا، معماری کامپیوترها در حال انتقال از **multi-core** به **many-core** می‌باشد.

GPU ها یک معماری **many-core** دارند، و به صورت **مجازی** همه‌ی انواع موازی‌سازی که قبلا بیان شد را دارند: **SIMD**، **MIMD**، **multi-threading** و موازی سازی در سطح دستورات. **NVIDIA** از عبارت **single Instruction,Multiple thread(SIMT)** برای چنین معماری استفاده می‌کند.

CPU و **GPU** تاریخچه‌ی متفاوتی دارند. در واقع، **GPU** ها در گذشته به عنوان یک شتاب‌دهنده استفاده میشد. ولی اخیرا **GPU** ها خیلی قدرتمند، همه‌کاره، کاملا برنامه‌پذیر، قابلیت موازی‌سازی **task** و **data** را پیدا کرده‌اند و برای مسایلی که درگیر محاسبات موازی هستند بسیار ایده‌آل هستند.

تفاوت GPU و CPU در این دیدگاه

اگر چه ممکن است هم برای **CPU** و هم برای **GPU** از اصطلاح **many-core** استفاده شود ولی **GPU** از لحاظ معماری کاملا متفاوت از یک هسته **CPU** است.

یک هسته‌ی **CPU**، نسبتا سنگین وزن بوده، و برای محاسبات منطقی خیلی پیچیده طراحی شده است، هدف در این طراحی بهینه کردن محاسبات سریال و پشت سر هم می‌باشد.

یک هسته‌ی **GPU** ، نسبتا سبک وزن، و برای کارهای **data-parallel** با منطق ساده‌تر بهینه شده است، و تمرکز روی توان عملیاتی در برنامه‌های موازی است.

۳ محاسبات ناهمگون یا HETEROGENEOUS

در روزهای آغازین دنیای کامپیوتر، کامپیوترها تنها شامل واحد پردازنده مرکزی بودند، یعنی **CPU** ها که به منظور اجرای کارهای برنامه‌نویسی کلی طراحی شده بودند. ولی در دهه‌ی گذشته، کامپیوترهای پیشرو در محاسبات با کارآیی بالا، برخی المان‌های پردازشی دیگری را نیز استفاده کردند. شاخص‌ترین آن **GPU** هست، که ذاتا برای انجام محاسبات گرافیکی به صورت موازی طراحی شده است. در طی زمان، **GPU** ها قوی‌تر و جامع‌تر شده، و باعث شد که بتوان از آن‌ها برای مقاصد کلی در کارهای محاسباتی استفاده کرد یعنی کارهای **general-purpose** که این کار با یک کارآیی فوق العاده و توان مصرفی بهینه انجام می‌شود.

معمولا، **CPU** ها و **GPU** ها به عنوان واحدهای پردازشی مجزایی هستند که با باس **PCI-Express** و تنها یک نود محاسباتی به هم متصل می‌شوند. در این معماری، **GPU** ها را به عنوان یک دیوایس مجزا می‌بینند.

تغییراتی که منجر به استفاده از سیستم‌های ناهمگون به جای سیستم‌های همگون شد راهی بود که برای رسیدن به محاسبات با کارآیی بالا در تاریخ طی شد. سیستم‌های همگون از یک یا چندین پردازنده از یک معماری یکسان برای اجرای یک برنامه استفاده میکردند. سیستم‌های ناهمگون از معماری**های** مناسب برای اجرای برنامه استفاده می‌کنند، و هر کار متناسب با معماری به پردازنده تخصیص داده می‌شود، که منجر به افزایش کارآیی در این گونه سیستم‌ها می‌شود.

اگر چه سیستم‌های ناهمگون مزیت‌های خیلی مهمی نسبت به سیستم‌های قدیمی در محاسبات دارند، ولی امروزه استفاده موثر از این سیستم‌ها با افزایش پیچیدگی طراحی برنامه‌ها محدود شده است. در حالی که برنامه‌نویسی موازی توجه‌ها را به خود جلب کرده است، همچنان پیچیدگی‌هایی نیز در خود گنجانده است.

اگر شما در زمینه‌ی برنامه‌نویسی موازی تازه‌کار هستید، در این صورت می‌توانید از ابزارهای پیشرفته و توسعه‌هایی که در زمینه‌ی سیستم های ناهمگون رخ داده است استفاده لازم را ببرید. اگر که یک برنامه‌نویس سطح بالا در زمینه‌ی پردازش موازی هستید، تطابق یافتن با معماری ناهمگون برای شما آسان‌تر خواهد بود.

۴ معماری heterogeneous یا نامتجانس (ناهمگون)

امروزه، نودهای محاسباتی در یک معماری عادی ناهمگون متشکل از دو سوکت **CPU** و دو یا بیشتر **GPU** است. یک **GPU** دیگر یک پلتفرم مستقل نیست بلکه یک پردازنده کمکی برای **CPU** می‌باشد. بنابراین، **GPU** ها باید به عنوان یک دیوایس برای **CPU** با استفاده از یک باس **PCI-Express** باشند، که

در شکل زیر نمایش داده شده است. دقیقا به همین دلیل است که، در اصطلاح برنامه‌نویسی **GPU** مـــا از **CPU** به عنوان **host** و از **GPU** به عنوان **device** استفاده می‌کنیم.

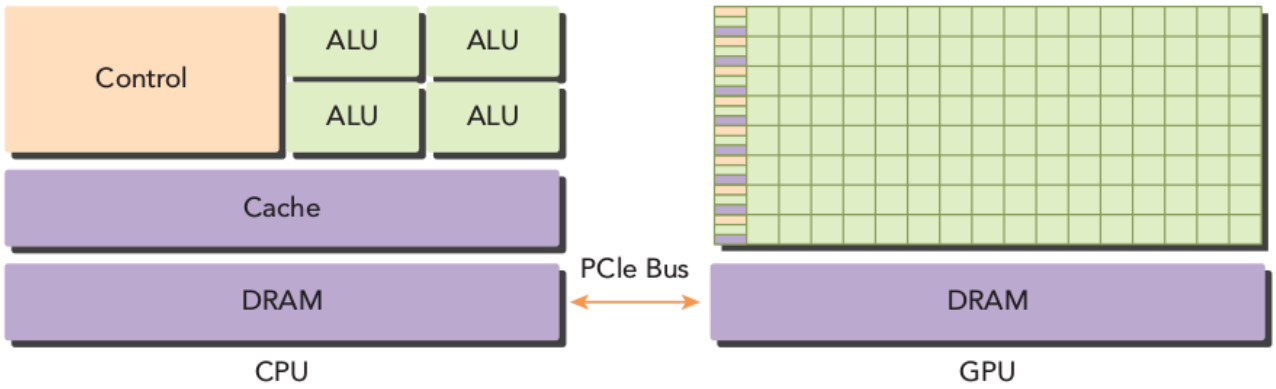

در **heterogeneous** ها برنامه از دو بخش تشکیل میگردد.

- کد میزبان (**Host code**)
- کد دیوایس (**Device code**)

Host code بر روی **CPU** ها اجرا شده و **device code** بر روی **GPU** ها اجرا می‌شود. یک برنامـه کـه بـر روی یک پلتفرم **heterogeous** اجرا می‌شود، معمـولا بـا **CPU** شـروع می‌شـود. کـد **CPU** مسـوولیت‌های روبه‌رو را دارد: مدیریت محیط، کد، و داده‌ای است که دیوایس میگیرد.

با برنامه‌های محاسباتی سنگین، معمولا **program section** مقدار قابل توجهی از داده‌هـای مـوازی را در خود خواهد داشت. **GPU** ها برای سرعت بخشیدن به اجرای این قسمت از داده‌ی موازی هسـتند. وقـتی که یک قطعه‌ی سخت‌افزاری که به صورت سخت‌افزاری نـیز از **CPU** جـدا می‌باشـد بـه منظـور سـرعت بخشیدن به این قسمت‌ها استفاده شود، معمولا از آن به عنوان یک شتاب دهنده یاد می‌شود. **GPU** ها به عنوان بارزترین شتابدهنده‌ی سخت‌افزاری می‌باشد.

پلتفرم محاسباتی **NVIDA's GPU** در سری‌های زیر فعال هستند:

- Tegra
- GeForce
- Quadro
- Tesla

خانواده‌ی **Tegra** به منظور استفاده در موبایل‌ها و ابزارهای نهفته مانند تبلت‌ها و گوشی‌ها طراحی شـده، **Gefore** برای اسـتفاده کـاربران، **Quadro** بـرای مصورسـازی‌های حـرفه‌ای و **Tesla** بـرای دیتاسـنترهای محاسبات موازی هستند. **Fermi**، شتاب‌دهنده‌ی **GPU** از خانواده‌ی **Tesla**، اخـیرا توجهـات زیـادی را بـه عنوان شتاب‌دهنده‌ی محاسباتی در برنامه‌های با کارآیی بالا جلب کـرده اسـت. **Fermi**، توسـط **NVIDIA** در سال ۲۰۱۰ به عنوان اولین معماری کامل محاسباتی **GPU** رونمایی شد. **GPU** شـتاب‌دهنده‌ی **Fermi**

تـا بـه امـروز در بسـیاری از زمینه‌هـای محاسـباتی اسـتفاده شـده اسـت مثـل مطالعـات زمین‌لـرزه، شبیه‌سازی‌های بیوشیمی، مدل‌سازی آب و هوا، و پردازش سیگنال، محاسبات مالی، آنـالیز داده. **Kepler**، نسل فعلی معماری **GPU** که بعد از **Fermi** بود، در پاییز ۲۰۱۲ رونمایی شد، که قـدرت پردازشـی خیلی بیشتری را نسبت به نسل قبلی پیشنهاد می‌کرد و روش‌های جدیدی برای بهبود و بهینه کردن اجراهـای موازی در اختیار قرار میداد. **Tegra K1** از **Kepler** به منظور افزایش قدرت محصولات نهفته استفاده کرده است.

ویژگی‌های مهمی وجود دارد که مشخص کننده‌ی توانایی **GPU** می‌باشد:

- تعداد هسته‌های **CUDA**
- میزان حافظه

همچنین، دو متریک برای اندازه‌گیری کارآیی یک **GPU** وجود دارد:

- **peak computational performance**
- **memory bandwidth**

peak computational performance راهی برای اندازه‌گیری قابلیت محاسباتی است، که به این صـورت تعریف می‌شود که چقدر محاسبات ممیز شناور **single** یا **double** را می‌توان در یک ثانیه انجام داد. **Peak performance** معمولا به صورت **gflops** و یا **tflops** بیان می‌شود. پهنای باند حافظه با **gigabytes/sec** بیان می‌شود. جدول زیر یک خلاصه‌ای از معماری **Fermi** و **Kepler** و ویژگی‌های کارآیی را آورده است.

	FERMI (TESLA C2050)	KEPLER (TESLA K10)
CUDA Cores	448	2 x 1536
Memory	6 GB	8 GB
Peak Performance*	1.03 Tflops	4.58 Tflops
Memory Bandwidth	144 GB/s	320 GB/s

* Peak single-precision floating point performance

بیشتر مثال‌هایی که در این کتاب زده می‌شود هم بر روی **Fermi** قابـل اجـرا خواهـد بـود و هم بـر روی **Kepler**. برخی از مثال‌ها نیازمند یک معماری خاص می‌باشد کـه تنهـا در **GPU** هـای **Kepler** گنجانـده شده است.

۵ قابلیت محاسباتی یا compute capabilitiy

NVIDIA از یک اصطلاح خاص یعنی **compute capability** برای ورژن سخت‌افزار **GPU** برای همه‌ی خانواده‌ی **Tesla** استفاده می‌کند. دیوایس‌ها با ورژن کلی یکسان معماری هسته یکسانی خواهند داشت.

- معماری کلاس **Kepler** با عدد ۳ نمایش داده می‌شود.
- معماری کلاس **Fermi** با عدد ۲ نمایش داده می‌شود.
- معماری کلاس **Tesla** با عدد ۱ نمایش داده می‌شود.

اولین کلاس **GPU** هایی که توسط **NVIDIA** رونمایی شد، در خود نام **Tesla** را برای همه‌ی **GPU** ها نیز داشت (یعنی هم نام **Tesla** بود و هم معماری سخت‌افزار هسته **Tesla** بود). همه‌ی مثال‌های این کتاب نیاز به **cp** بالای ۲ خواهند داشت.

TABLE 1-2: Compute Capabilities of Tesla GPU Computing Products

GPU	COMPUTE CAPABILITY
Tesla K40	3.5
Tesla K20	3.5
Tesla K10	3.0
Tesla C2070	2.0
Tesla C1060	1.3

۶ ۶ الگوی محاسباتی ناهمگون

محاسبات **GPU** قصد جایگزینی با محاسبات **CPU** را ندارند. هر کدام مزیت‌های خاصی برای نوع خاصی از برنامه‌ها دارند. محاسبات **CPU** برای عملیات‌هایی که کنترل سختی دارند مناسب می‌باشد، و **GPU** برای محاسباتی مفید هستند که در آن **Task** ها محاسبات موازی زیادی دارند. وقتی **CPU** همراه با **GPU** قرار میگیرد، یک ترکیب خیلی قوی را ایجاد خواهند کرد. **CPU** برای محاسبات کوتاه که کنترل غیر قابل پیش‌بینی دارند مناسب می‌باشد، و **GPU** برای محاسبات سنگین ولی کنترل سبک مناسب می‌باشد. در واقع دو پارامتر برای انتخاب بهتر بین **CPU** و **GPU** وجود دارد:

- سطح موازی سازی
- اندازه داده

اگر یک مساله حجم داده کمی داشته باشد، و منطق برنامه پیچیده باشد، و یا سطح موازی‌سازی پایینی داشته باشد، در این صورت **CPU** انتخاب مناسب‌تری می‌باشد چرا که توانایی مناسبی در منطق پیچیده‌تر دارد. اگر یک برنامه دارای مقدار زیادی داده بود، و سطح موازی‌سازی بالایی داشته باشد، در

این صورت **GPU** انتخاب مناسب تری می‌باشد چرا که **GPU** تعداد هسته‌های بسیار بیشتری دارد، که می‌تواند از **multi-threading** به صورت گسترده استفاده کند، و نسب به **CPU** دارای عرض پهنای باند بیشتری می‌باشد.

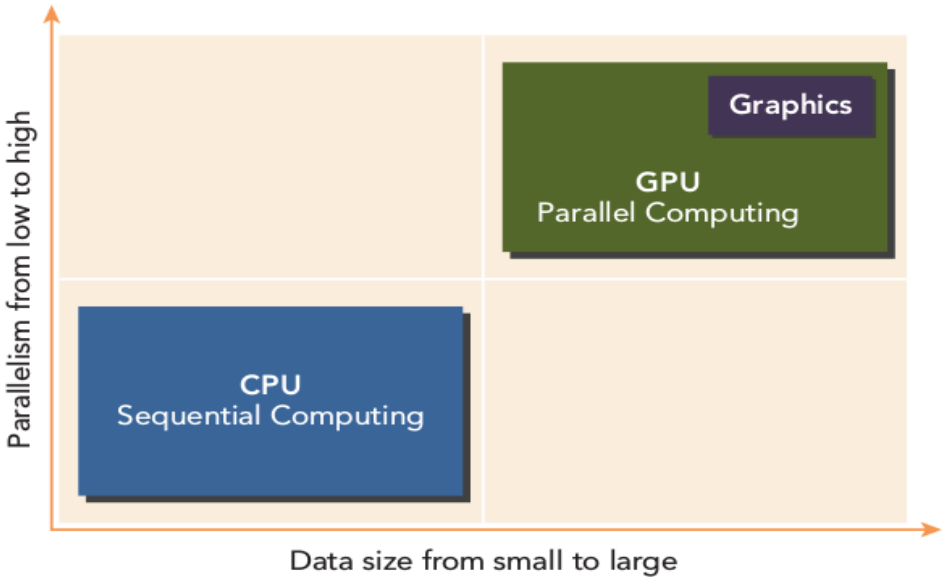

معماری محاسبات موازی ناهمگون **CPU+GPU** به این دلیل به وجود آمد که **CPU** و **GPU** هر کدام ویژگی‌های مکملی دارند که باعث می‌شود برنامه‌ها برای هر چیزی مهیا باشند. بنابراین، به منظور کارآیی بهینه ممکن است که نیاز داشته باشید برای برنامه خودتان همه از **CPU** و هم از **GPU** استفاده کنید، اجرای قسمت ترتیبی و یا قسمت موازی بر روی **CPU** و قسمتی که دارای داده‌ی موازی سنگین هست بر روی **GPU** که در شکل زیر نمایش داده شده است.

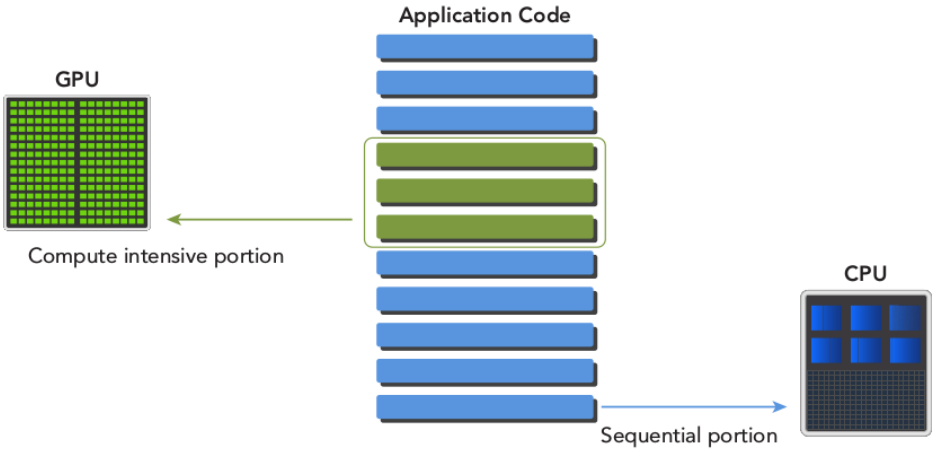

FIGURE 1-11

نوشتن کد به این صورت به شما این اطمینان را میدهد که ویژگی‌های **GPU** و **CPU** مکمل همدیگر باشند، و منجر به استفاده‌ی حداکثری از قدرت **CPU+GPU** خواهد شد. برای این که بتونیم یک برنامه

طراحی کنیم که از ترکیب **CPU+GPU** پشتیبانی داشته باشد، **NVIDIA** یک مدل برنامه‌نویسی به نام **CUDA** ایجاد کرده است. این مدل برنامه‌نویسی جدید تمرکز کتاب در ادامه خواهد بود.

۷ تفاوت ترد CPU با ترد GPU

تردها روی **CPU** به عنوان موجودیت‌های سنگینی شناخته می‌شوند. سیستم عامل باید یک ترد را خاموش و روشن کند تا توانایی **multi-threading** را فعال کند. **Context switches** کند و پر هزینه هستند.

تردها بر روی **GPU** خیلی سبک هستند. در یک سیستم عادی، ده ها هزار ترد در صف هستند تا کاری را انجام دهند. اگر یک **GPU** باید منتظر گروهی از تردها باشد، خیلی راحت می‌تواند یک کار دیگر را اجرا کند.

هسته‌های **CPU** طراحی شده‌اند تا میزان **latency** را کمینه کنند، در حالی که هسته‌های **GPU** برای تعداد زیادی ترد موازی طراحی شده‌اند تا قابلیت محاسباتی را بیشینه کنند.

امروزه، یک **CPU** با چهار هسته **quad** می‌تواند تنها ۱۶ تا ترد را به صورت همزمان اجرا کند، البته اگر **CPU** بتواند از **hyper-threading** پشتیبانی کند می‌توان آن را تا ۳۲ تا ترد افزایش داد.

GPU های مدرن **NVIDIA** می‌توانند تا ۱۵۳۶ تا ترد فعال به ازای هر **multiprocessor** داشته باشند. روی یک **GPU** با ۱۶ تا **multiprocessor**، این عدد تا ۲۴۰۰۰ ترد فعال افزایش می‌یابد.

۸ CUDA : یک پلتفرم برای محاسبات ناهمگون

CUDA یک پلتفرم محاسبات موازی **general-purpose** می‌باشد، یک مدل برنامه‌نویسی که موتورهای برنامه‌نویسی موازی در **GPU** های **NVIDIA** را به منظور حل مسایل پیچیده به صورت موثری به کار میگیرد. با استفاده از **CUDA** ، شما می‌توانید به **GPU** به منظور محاسبات دسترسی داشته باشید، که قبلا بر روی **CPU** اجرا میشد.

پلتفرم **CUDA** از طریق کتابخانه‌های شتابدهنده‌ی **CUDA** ، رابط برنامه‌نویسی و افزونه‌هایی که برای زبان‌های استاندارد فراهم شده شامل **C,C++,Fortran** و **python** قابل دسترسی خواهد بود. این کتاب بر روی **CUDA C programming** تمرکز خواهد داشت.

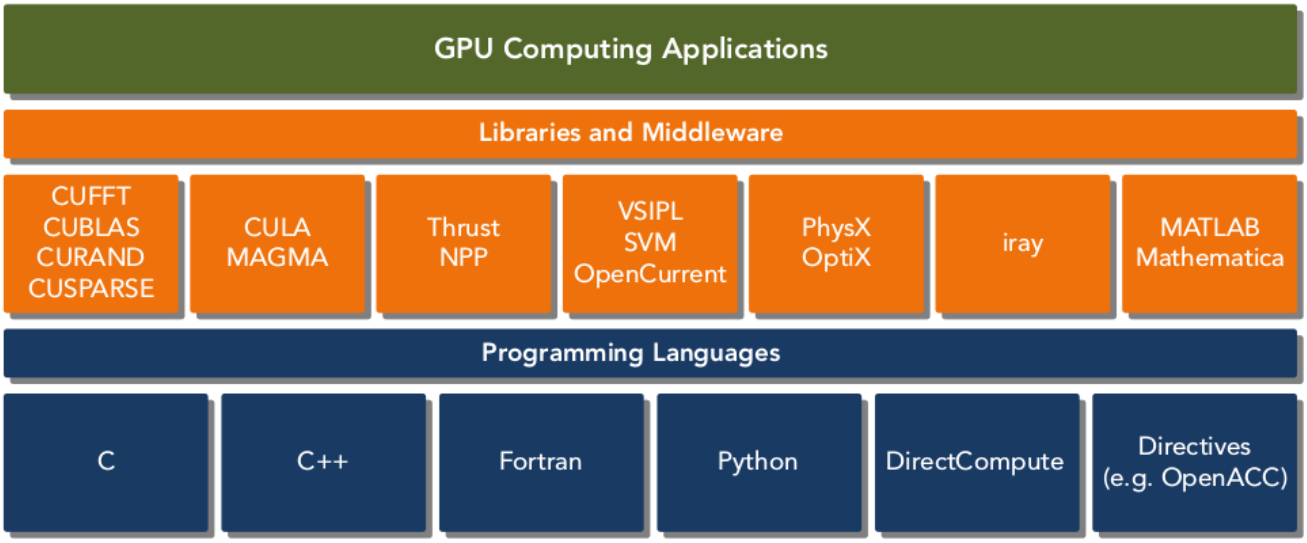

CUDA C یک افزونه از **ANSI C** استاندارد می‌باشد که افزونه‌های زبان به درد بخوری برای فعال کردن برنامه‌نویسی ناهمگون در اختیار ما قرار میدهد، همچنین یک **API** سر راست برای مدیریت **device** ، حافظه، و **task** های دیگر نیز دارد. **CUDA** همچنین یک مدل برنامه‌نویسی **scalable** دارد که می‌شود میزان **scalable** بودن موازی سازی را با تغییر تعداد هسته‌ها تغییر داد، در عین حال نیازی به معلومات پیچیده در مورد **GPU** نخواهد بود و برای کسی که زبان **C** را یاد گرفته این کار آسان خواهد بود.

CUDA دو سطح **API** برای مدیریت **GPU device** و مدیریت تردها فراهم کرده است که بعدا در شکل نیز خواهیم دید:

- CUDA Driver API
- CUDA Runtime API

API مربوط به **driver** یک **API** سطح پایین بوده و تقریبا برای برنامه‌نویسی دشوار می‌باشد، اما کنترل بیشتری بر روی **GPU** در اختیار ما قرار میدهد. **API** مربوط به **runtime** یک **API** سطح بالا بوده که بر روی **API** درایور ساخته شده است. هر تابع از **API** مربوط به **runtime** به عملیات‌های ابتدایی تر که مربوط به **API** درایور است شکسته می‌شود.

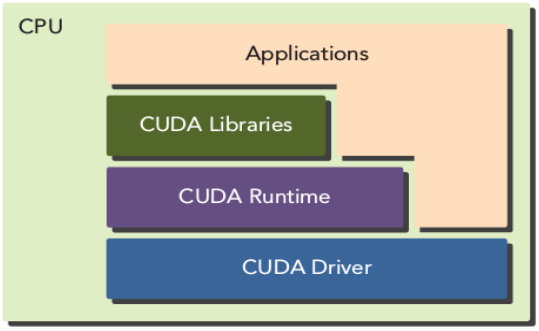

در حقیقت در مورد کارآیی این دو API تفاوت زیادی وجود ندارد. این که چطور کرنل شما از حافظه استفاده می‌کند و چطور تردها را مدیریت می‌کنید چیزی است که تفاوت کارآیی را مشخص می‌کند.
این دو API دو به دو با همدیگر ناسازگار هستند. شما باید یکی از این دو را انتخاب کنید، و این امکان وجود ندارد که توابع این دو را با هم ترکیب کنید. همه‌ی مثال‌ها در این کتاب از runtime استفاده می‌کنند.

یک برنامه **CUDA** ترکیبی از دو بخش زیر می‌باشد.

- یک کد میزبان که بر روی **CPU** اجرا می‌شود.
- یک کد **device** که بر روی **GPU** اجرا می‌شود.

کامپایلر **nvcc** مربوط به کودای **NVIDIA** در طی مرحله کامپایل کد **device** را از کد میزان جدا می‌کند. **Host code** در واقع زبان **C** استاندارد بوده و در ادامه توسط کامپایلر زبان **C** کامپایل خواهد شد. کد **device** با استفاده از کلمات کلیدی برای مشخص کردن توابع **data-parallel** جدا می‌شود که **kernel** نامیده می‌شود. در ادامه کد **device** بر روی **nvcc** کامپایل می‌شود. در مرحله **link**، کتابخانه‌ی **CUDA runtime** به فراخوان‌های **kernel** اضافه شده و به طور صریح بر روی **GPU** می‌تواند اجرا شود.

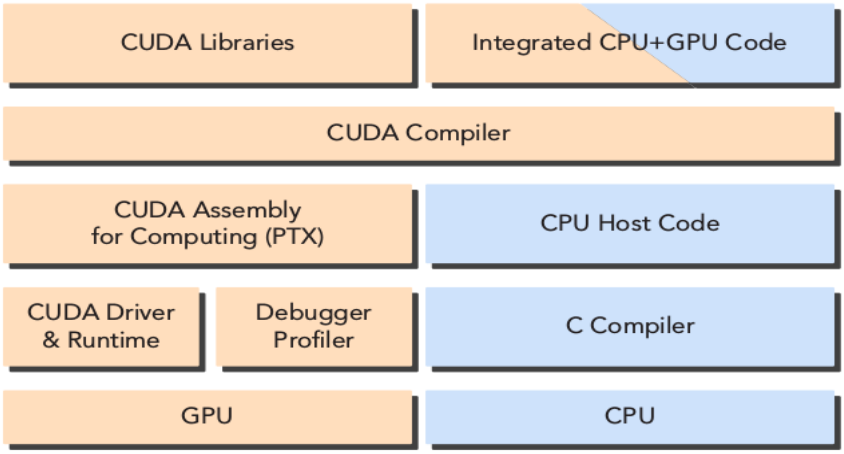

کامپایلر **nvcc** عمدتا بر اساس ;کامپایلر **LLVM** نوشته شده است. شما می‌توانید با استفاده از **CUDA Compiler SDK** یک زبان برنامه‌نویسی بسازید و یا توسعه دهید که از شتابدهنده‌ی **GPU** پشتیبانی کند.

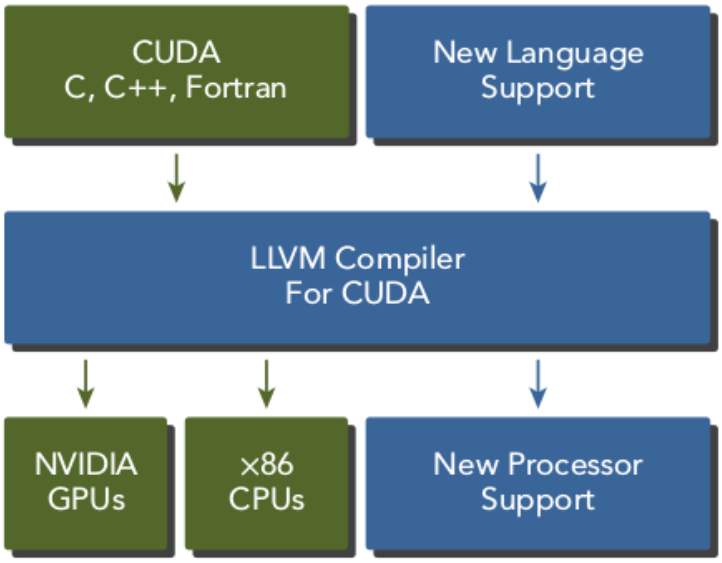

The CUDA platform is also a foundation that supports a diverse parallel computing ecosystem, as shown in Figure 1-16. Today, the CUDA ecosystem is growing rapidly as more and more companies provide world-class tools, services, and solutions. If you want to build your applications on GPUs,the easiest way to harness the performance of GPUs is with the CUDA Toolkit (https://developer.nvidia.com/cuda-toolkit), which provides a comprehensive development environment for C and C++ developers. The CUDA Toolkit includes a compiler, math libraries, and tools for debugging and optimizing the performance of your applications. You will also fi nd code samples,programming guides, user manuals, API references, and other documentation to help you get started.

اولین کدمان را به صورت زیر می‌نویسیم.

```
#include <stdio.h>
#include <iostream>
using namespace std;
__global__ void hellofromGPU(void)
{
    printf("Hello world from GPU!! \n");
}
int main()
{
    cout<<"Hello world from CPU!!"<<endl;
    hellofromGPU<<<1,1>>>();
    cudaDeviceReset();
    return 0;
}
```

در این کد ما تابع **hellofromGPU** را به صورت زیر تعریف کرده‌ایم.

```
__global__ void hellofromGPU(void)
{
   printf("Hello world from GPU!! \n");
}
```

این تابع یک تابع کرنل است که در آن **__global__** یک **qualifier** به حساب می‌آید. این **qualifier** به کامپایلر می‌گوید که این تابع از روی **CPU** خوانده می‌شود و روی **GPU** اجرا می‌شود. برای اجرا کردن تابع کرنل باید به صورت زیر عمل کنیم.

```
hellofromGPU<<<1,10>>>();
```

در این کد **triple angle bracket** یک فراخوانی از ترد میزبان به کدی که بر روی **device** قرار دارد مارک می‌کند. یک کرنل توسط آرایه‌ای از تردها اجرا شده و همه‌ی تردها یک کد یکسان را اجرا خواهند کرد. پارامترهایی که درون براکت سه‌گانه آورده شده است، پارامترهای تنظیمی برای اجرا می‌باشد، که مشخص کننده‌ی تعداد تردهایی است که تابع کرنل را اجرا می‌کنند. در این مثال، شما از ۱۰ ترد برای اجرای کرنل استفاده می‌کنید. و خروجی به صورت زیر خواهد بود.

```
Hello world from CPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
Hello world from GPU!!
```

تابع **cudaDeviceReset()** صریحا همه‌ی منابعی که این پردازش از **device** گرفته را تخریب و پاک می‌کند. برای کامپایل بر روی معماری **sm_20** به صورت زیر نیز می‌توانیم عمل کنیم.

```
nvcc -arch sm_20 hello.cu -o hello
```

یک برنامه‌ی عادی کودا شامل پنج قدم خواهد بود.

۱. اختصاص دادن حافظه‌ی **GPU**

۲. کپی کردن داده از روی حافظه‌ی **CPU** روی حافظه‌ی **GPU**.

۳. فراخوانی کردن یک تابع کرنل کودا برای انجام یک محاسبه‌ی خاص.

۴. کپی کردن داده از حافظه‌ی **GPU** روی حافظه‌ی **CPU**.

۵. نابود کردن حافظه‌ای که به **GPU** اختصاص داده بودیم.

۹ آیا برنامه‌نویسی با CUDA مشکل است؟

تفاوت عمده بین برنامه‌نویسی **CPU** و برنامه‌نویسی **GPU** در میزان آشنایی است که با ویژگی‌های معماری **GPU** باید کسب کرد. فکر کردن به صورت موازی و داشتن یک درک اولیه از معماری **GPU** به شما این امکان را میدهد که برنامه‌های موازی خودتان را بنویسید .

اگر می‌خواهید که به عنوان یک مهندس برنامه‌های موازی یک کد موثر و با سرعت بالا بنویسید، نیاز به یک آشنایی اولیه با معماری **CPU** نیز خواهید داشت. به طور مثال، **locality** یک مفهوم خیلی مهم در برنامه‌نویسی موازی است. در واقع **Locality** اشاره به استفاده مجدد از داده‌ها برای کاهش تاخیر دسترسی به حافظه می‌باشد. **Temporal Locality** یعنی این که داده و یا منابع به مدت زمان کوتاهی قابل استفاده مجدد باشد و **Spatial Locality** یعنی این که داده‌های یک المان در حافظه نزدیک به همدیگر باشند. **CPU** های مدرن از کش‌های بزرگ استفاده می‌کنند، تا برنامه‌هایی که **Spatial** و **Temporal locality** مناسبی دارند در بهترین حالت خود اجرا شوند. در واقع این مسوولیت برنامه‌نویس است که برنامه را طوری بنویسید که به بهترین نحو از **CPU cache** استفاده بکند. برنامه‌نویسان باید بهینه‌سازی‌های سطح پایین **cache** را در دست بگیرند، ولی نیازی به این نیست که در مورد تردهای **CPU** و چگونگی اجرای این تردها فکر کنند چون که **CPU** همچین اطلاعاتی را به ما نمیدهد.

CUDA در این مورد هم سلسله مراتب حافظه و هم سلسه مراتب تردها را در اختیار ما قرار میدهد، و توانایی کنترل اجرای تردها و برنامه‌ریزی تردها را به درجه‌ی بالاتری می‌رساند.

به طور مثال، ما یک حافظه‌ی خاص داریم که **shared memory** نامیده می‌شود، که توسط برنامه‌نویسی **CUDA** قابل کنترل است. **Shared memory** را می‌توان به عنوان کش قابل کنترل توسط برنامه دید، که افزایش سرعت قابل ملاحظه‌ای را با حفظ کردن پهنای باند **main memory** به ما میدهد. با استفاده از حافظه **share** شده، می‌توانید **locality** کدتان را مستقیما کنترل کنید.

وقتی که یک برنامه توسط **ANSI C** نوشته می‌شود، شما باید صریحا تردهای خودتان را با **pthreads** و یا **OpenMP** کنترل کنید، این دو تکنیک‌های شناخته شده‌ای هستند که برنامه‌نویسی موازی را در اکثر معماری‌ها و سیستم عامل‌ها پشتیبانی می‌کند. وقتی که یک برنامه در **CUDA C** نوشته می‌شود، در واقع یک تکه کد سریال نوشته‌اید که توسط یک ترد اجرا می‌شود. **GPU** این کرنل را گرفته و آن را با اجرا کردن بر روی هزاران ترد تبدیل به یک کد موازی می‌کند، در واقع همه‌ی تردها یک کد را اجرا می‌کنند.

مدل برنامه‌نویسی موازی **CUDA** راهی برای کنترل تردهـای معمـاری میدهـد. دسـتکاری مسـتقیم این سازماندهی روی ترتیب تردهایی که در **GPU** اجرا می‌شود تاثیر میگذارد. از آنجایی کـه **C CUDA** یـک افزونه از زبان **C** است، معمولا تبدیل کد زبان **C** به **CUDA C** کار سختی نخواهد بود.

CUDA جزییات سخت‌افزاری را خود حل می‌کند و نیازی نیست که برنامه به **API** سابق نگاشت شود. در هسته‌ی **CUDA** ما سه نوع مفهوم ابسترکت شده داریم: سلسله مراتب گروه‌های ترد، یک سلسله مـراتب از گروه‌های حافظه، و یک حایل سنکرون سازی، که به صورت حداقل چیزی که از افزونه‌هـا نیـاز داریـد ارایه شده است. با هر نسخه‌ی **CUDA**، برنامه‌نویسی موازی توسط **NVIDIA** سـاده‌تر شـده. البتـه بـرخی هنوز مفاهیم **CUDA** را سطح پایین می‌دانند، و بالا بردن این ابسترکت ممکن است که توانـایی شـما در کنترل برنامه تان را کاهش دهد. بدون این کنترل، کارآیی برنامه شما دیگر در کنترل شما نخواهـد بـود. بنابراین، چالشی که باید با آن روبه‌رو شوید آشنایی اولیه بـا معمـاری **GPU** و خـبره شـدن در ابزارهـای توسعه **CUDA** و محیط توسعه می‌باشد.

۱۰ محیط توسعه‌ی CUDA

NVIDIA محیط توسعه‌ی بزرگی را برای توسعه برنامه‌هایی که نیاز به **GPU** دارند، توسط **C** و **C++** آماده کرده است که شامل:

- NVIDIA NsightTM integrated development environment
- CUDA-GDB command line debugger
- Visual and command line profiler for performance analysis
- CUDA-MEMCHECK memory analyzer
- GPU device management tools

پس از آشنایی با این ابزارها، برنامه‌نویسی با زبان **C** یک کار آسان خواهد بود.

***Locality* in this sense is speaking mostly to *cache locality*. Writing data structures and algorithms to operate mostly out of cache makes the algorithm run as fast as it possibly can. Cache locality is one of the reasons *quick sort* is quick.**
For a data structure, you want to keep the parts of your data structure that refer to each other relatively close to each other, to avoid flushing out useful cache lines.
Also, you can rearrange your data structure so that the compiler will use the minimum amount of memory required to hold all the members and still efficiently access them. This helps make sure your data structure consumes the minimum number of cache lines.
A single cache line on a current x86-64 architecture (core i7) is 64 bytes.

فصل دوم : مدل برنامه‌نویسی CUDA

CUDA یک پلتفرم محاسبات موازی و یک مدل برنامه‌نویسی است که، مجموعه‌ی کوچکی از افزونه‌ها نیز با آن همراه شده و همه‌ی این‌ها به زبان **C** افزوده شده است. با استفاده از **CUDA**، می‌توان به سادگیه نوشتن یک برنامه به زبان **C**، کد نویسی کرد. با استفاده از **CUDA** می‌توانید برای هزاران نوع سیستم که از کارت گرافیک **NVIDIA** استفاده می‌کنند برنامه بنویسید، که محدوده‌ای از دیوایس‌های نهفته، تبلت‌ها، لپ‌تاپ‌ها، سیستم‌های دسکتاپ تا **workstation** برای سیستم‌های کلاستر **HPC** را شامل می‌شود.در **CUDA** ابزارهای برنامه‌نویسی مشابه با زبان **C** توسعه داده شده اند تا در امر تصحیح، دیباگ و آنالیز برنامه به شما کمک کنند. در این فصل، یاد خواهید گرفت تا چطور یک برنامه **CUDA** بنویسید، این کار را با دو مثال ساده توضیح خواهیم داد: **جمع برداری** و **جمع ماتریسی**.

۱ معرفی مدل برنامه‌نویسی CUDA

مدل برنامه‌نویسی یک **abstraction** از معماری کامپیوتر را بیان می‌کند که به عنوان یک پل فی ما بین برنامه و پیاده‌سازی روی سخت افزار عمل می‌کند. شکل زیر لایه‌های مهم این **abstraction** را که بین برنامه و پیاده‌سازی مدل برنامه‌نویسی خوابیده است را نشان می‌دهد.

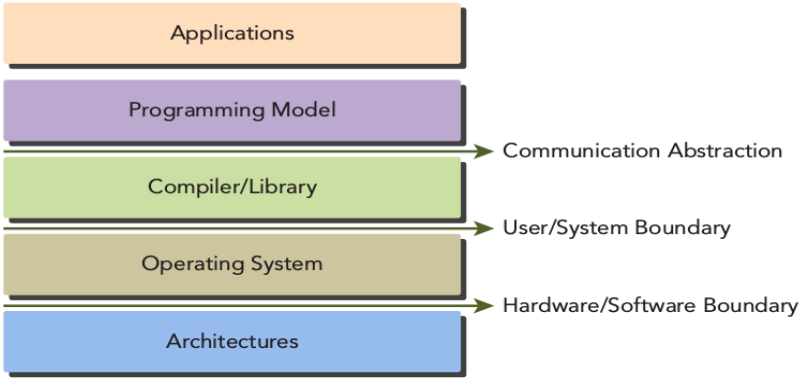

Abstraction ارتباط، یک مرز بین برنامه و پیاده‌سازی مدل برنامه‌نویسی است، که از طریق کامپایلر یا کتابخانه، توسط سخت افزار و سیستم عامل فهمیده می‌شود. برنامه ای که توسط مدل برنامه‌نویسی نوشته می‌شود، نشان‌دهنده‌ی کامپوننت‌هایی است که برنامه به اشتراک می‌گذارد. مدل برنامه‌نویسی یک دید منطقی از معماری محاسباتی مشخصی را ارایه میدهد. معمولا، آن را در زبان برنامه‌نویسی و یا محیط برنامه‌نویسی قرار داده است.

علاوه بر این **abstraction** هایی که با سایر مدل‌های برنامه‌نویسی موازی بـه اشـتراک گذاشـته می‌شـود، مدل برنامه‌نویسی **CUDA** ویژگی‌های خاص زیر را برای دسترسی به قدرت بیشتر محاسـباتی در اختیـار قرار میدهد.

- راهی برای مدیریت تردها بر روی **GPU** از طریق یک ساختار سلسله مراتبی.
- راهی برای دسترسی به حافظه بر روی **GPU** از طریق یک ساختار سلسله مراتبی.

ما در اولین بحثی که در این فصل و فصل بعد خواهیم داشت روی مورد اول تمرکز خواهیم کرد، و مـورد دوم را در فصل چهار و پنج مورد بررسی قرار خواهیم داد.

از دید یک برنامه‌نویس، می‌توانید برنامه‌نویسی موازی را در سطوح مختلفی ببینید، مثل:

- سطح **Domain**
- سطح منطقی
- سطح سخت افزاری

وقتی که دارید برنامه‌نویسی انجام میدهید و الگوریتم را طراحی میکنیـد، توجه‌تـان معطـوف بـه **سطح domain** می‌باشد: چطور داده‌ها را تقسیم کنیم و چطور توابع رو برای حل مساله مان در حالت موازی بـه صورت کارآمدی به کار بگیریم، این **سطح domain** است. وقتی که وارد فاز برنامه نویسی شدید، باید بـه این فکر کنید که چطور تردهای موازی را مدیریت کنیـد، در طی این فـاز شـما در **سطح منطقی** فکـر می‌کنید تا اطمینان حاصل کنیـد کـه تردهـا و محاسـباتمان مسـاله را درسـت حـل می‌کننـد. در زبـان برنامه‌نویسی موازی که توسط **C** عادی انجام می‌شود، شما باید به طور صریح از **pthreads** و یا **OpenMP** استفاده کنید. **CUDA** این **abstraction** ای که در مورد کنترل رفتار تردها وجود دارد را در اختیار ما قرار داده. وقتی که مثال‌های این کتاب رو می‌بینیم، خواهید دید که چنین **abstraction** ای چه مقیاس‌پذیری فوق‌العاده‌ای را به ما می‌دهد. در **سطح سخت افزار**، قادر به درک چگونگی نگاشت شدن تردها بـر روی هسته‌ها خواهیم بود، شاید این موضوع به بهبود کارآمدی سیستم کمک کند.

مدل ترد **CUDA** اطلاعات کافی را در اختیار شما قرار میدهد بدون این کـه شـما را مجبـور بـه دانسـتن جزییات سطح پایین کند. در این مورد در فصل ۳ بیشتر خواهیم دانست.

۲ ساختار برنامه‌نویسی CUDA

مدل برنامه‌نویسی **CUDA** به شما این امکان را میدهد که برنامه‌تان را بر روی سیستم‌های ناهمگون اجرا کنید، این کار با نشان‌دار کردن کد با یک مجموعه‌ی کوچک از افزونه‌هایی که بـه زبـان **C** افـزوده شـده انجام میپذیرد. یک محیط ناهمگون متشکل شده از **CPU** ها به همراه **GPU** می‌باشد، که هر کـدام دارای

حافظه‌ی اختصاصی است که با گذرگاه **PCI-Express** از همدیگر جدا شده‌اند. بنابراین، باید متوجه تفاوتی که این دو حافظه دارند باشید:

- **Host : CPU** و حافظه اختصاصی خودش(حافظه‌ی **host**)
- **Device : GPU** و حافظه‌ی اختصاصی(حافظه‌ی **device**)

برای مشخص شدن تفاوت این دو حافظه، متغیرهایی که با **h_** شروع می‌شوند برای حافظه‌ی **host** و متغیرهایی که با **d_** شروع می‌شوند برای حافظه‌ی **device** به کار می‌رود.

با شروع **CUDA 6**، **NVIDIA** یک بهبود در مدل برنامه‌نویسی اضافه کرد که **Unified Memory** (حافظه‌ی یکپارچه) نامیده می‌شود، که به عنوان یک پل بین حافظه‌ی **host** و **device** کار می‌کند. این توسعه به شما اجازه میدهد تا هم به حافظه‌ی **CPU** و هم **GPU** با یک اشاره‌گر دسترسی داشته باشید، در حالی که سیستم به صورت اتوماتیک داده‌ها را بین **host** و **device** جابه‌جا می‌کند. اطلاعات بیشتر در مورد این حافظه در فصل چهارم توضیح داده خواهد شد. قبل از آن شما نیاز دارید که یاد بگیرید چطور روی **host** و **device** حافظه اختصاص دهید، و صریحا داده را بین **CPU** و **GPU** جابه‌جا کنید. این کنترلی که برنامه‌نویس بر روی حافظه و داده دارد می‌تواند باعث بالابردن حداکثری کارآمدی سیستم و استفاده بیشینه از سخت افزار شود.

یک کامپوننت کلیدی در مدل برنامه‌نویسی **CUDA** ، **کرنل** می‌باشد(کرنل کدی است که بر روی **GPU** اجرا می‌شود.شما به عنوان یک توسعه دهنده، می‌توانید یک کرنل را به صورت یک برنامه‌ی ترتیبی بنویسید و در پشت صحنه، **CUDA** این کرنل که توسط شما نوشته شده را برای اجرا روی تردهای **GPU** مدیریت می‌کند. از طریق **host** ، تعریف می‌کنید که چطور **کرنل** روی **device** بر اساس معماری داده‌هایی که دارید نگاشت شود. در این صورت ما درگیر مدیریت هزاران ترد **GPU** نخواهیم شد.

Host می‌تواند برای بیشتر عملیات‌ها به طور مستقل از **device** کار کند. وقتی که یک **kernel** اجرا می‌شود، کنترل بلافاصله دست **host** میفتد، و **CPU** را آزاد نگه می‌دارد تا محاسبات موازی بر روی **device** اجرا شود. مدل برنامه‌نویسی **CUDA** یک پروسه **آسنکرون** می‌باشد، بنابراین محاسبات **GPU** می‌تواند بر روی **GPU** با پردازش‌های **host** همپوشانی پیدا کند. یک برنامه‌ی عادی **CUDA** متشکل از یک کد سریال هست که با یک کد موازی تکمیل شده است. همانطور که در شکل نمایش داده شده است، کد ترتیبی بر روی **host** اجرا می‌شود، ولی کد موازی بر روی دیوایس **GPU** اجرا می‌شود. کد **host** با استفاده از زبان **C** نوشته شده در حالی که کد **device** با استفاده از زبان **C CUDA** نوشته شده است. می‌توانید همه‌ی کد را در داخل یک سورس فایل بنویسید، یا این که می‌توانید چندین سورس فایل داشته باشد. کامپایلر **NVIDIA(NVCC)** هم برای **host** و هم برای **device** کد را تولید می‌کند.

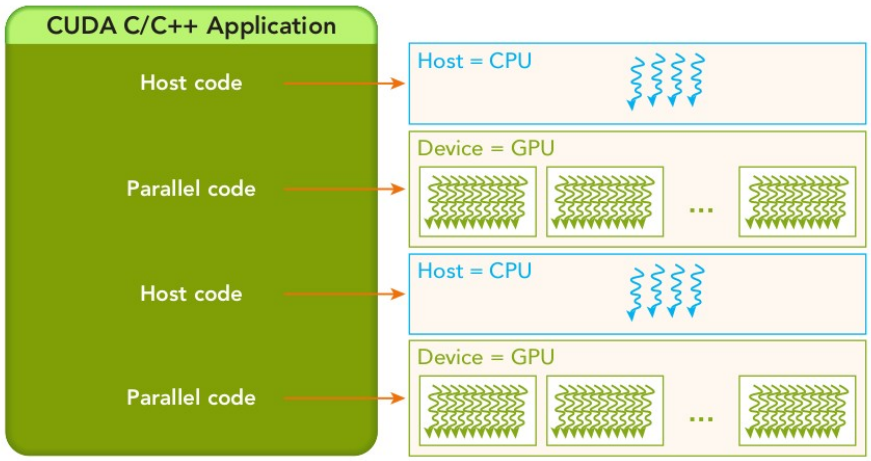

یک روش معمول برای پردازش برنامه **CUDA** روش زیر می‌باشد.

۱. کپی کردن داده از **CPU** بر روی حافظه‌ی **GPU**

۲. فراخوانی کردن کرنل برای پردازش داده‌هایی که در **GPU** ذخیره شده است.

۳. کپی کردن حافظه از **GPU** به **CPU** .

ما کار را با مدیریت حافظه و تبادل اطلاعات بین **host** و **device** آغاز خواهیم کرد. در ادامه فصل جزییات بیشتری در مورد کرنل‌های **GPU** خواهیم دید.

۳ مدیریت حافظه

مدل برنامه‌نویسی **CUDA** فرض می‌کند که سیستم از یک **host** و از یک **device** تشکیل شده است، که هر کدام دارای حافظه‌ی جداگانه خود هستند. کرنل در خارج از حافظه‌ی **device** اجرا می‌شود تا این امکان را به شما بدهد که کنترل کاملی روی برنامه داشته باشید و به بهترین کارآمدی برسید، **CUDA runtime** توابعی رو برای اختصاص حافظه‌ی **device**، رها کردن حافظه‌ی **device** ، و انتقال اطلاعات بین حافظه‌ی **host** و **device** را فراهم کرده است. جدول زیر یک لیست از توابع استاندارد **C** و تابع منطبق در **CUDA C** را فراهم کرده است.

TABLE 2-1: Host and Device Memory Functions

STANDARD C FUNCTIONS	CUDA C FUNCTIONS
malloc	cudaMalloc
memcpy	cudaMemcpy
memset	cudaMemset
free	cudaFree

تابعی که برای اختصاص حافظه در **GPU** استفاده می‌شود **cudaMalloc** می‌باشد، و نوع استفاده از تابع به صورت زیر می‌باشد.

```
cudaError_t cudaMalloc ( void** devPtr, size_t size );
```

این تابع یک رنج خطی از حافظه **device** و به میزانی که مشخص شده(یعنی **size**) میگیرد. توجه شود که حافظه گرفته شده به بایت می‌باشد. حافظه اختصاص داده شده نیز توسط **devPtr** قابل بازیابی خواهد بود. احتمالا متوجه تشابهی که بین **cuda-malloc** و **malloc** در زبان **C** است پی برده‌اید. این تشابه، عمدی بوده. با نزدیک نگه داشتن رابط زبان **CUDA** به زبان برنامه‌نویسی **C** ، استفاده از **CUDA** آسان تر خواهد بود.

تابعی که برای انتقال داده بین **host** و **device** مورد استفاده قرار میگیرد **cudaMemcpy** می‌باشد، و نحوه‌ی استفاده از این تابع نیز به صورت زیر می‌باشد.

```
cudaError_t cudaMemcpy(void* dst,const void* src,size_t count,cudaMemcpyKind kind);
```

این تابع به میزان بایت‌های مشخص شده از قسمت حافظه‌ی سورس، که توسط **src** به آن اشاره شده، به فضای حافظه‌ی مقصد که با **dst** به آن اشاره شده یک کپی انجام میدهد. توجه شود که نوع **cudaMemcpyKind** به چهار دسته زیر تقسیم می‌شود:

- cudaMemcpyHostToHost
- cudaMemcpyHostToDevice
- cudaMemcpyDeviceToHost
- cudaMemcpyDeviceToDevice

این تابع یک رفتار آسنکرون نخواهد داشت، چون برنامه‌ی **host** تا وقتی که تابع کارش تمام نشود بلاک می‌ماند. هر فراخوانی از **CUDA**، به جز فراخوانی کرنل، یک کد خطا به صورت **enumerated** شده در **cudaError_t** برمیگرداند. به طور مثال،اگر حافظه‌ی **GPU** به درستی تخصیص داده شده باشد، چیزی که این تابع برمیگرداند به صورت زیر خواهد بود.

cudaSuccess

در غیر این صورت چیزی که برمیگرداند به صورت زیر هست.

cudaErrorMemoryAllocation

برای تبدیل این کد خطا به چیزی که برای انسان قابل خواندن باشد می‌توانید از این تابع **run-time** **cudaGetErrorString** استفاده کنید.

```
const char* string=cudaGetErrorString(cudaError_t   Error);
```

تابع **cudaGetErrorString** مشابه تابع **strerror** در زبان **C** استاندارد می‌باشد.

مدل برنامه‌نویسی **CUDA** یک **abstraction** از سلسله مراتب حافظه از معماری **GPU** در اختیار میگذارد. شکل زیر یک ساختار ساده شده حافظه‌ی **GPU** را نشان میدهد، که شامل دو زیر شاخه‌ی مهم است: حافظه‌ی **global** و حافظه‌ی **share** شده. در مورد ساختار سلسله مراتبی **GPU** در فصل چهار و پنج بیشتر یاد خواهیم گرفت.

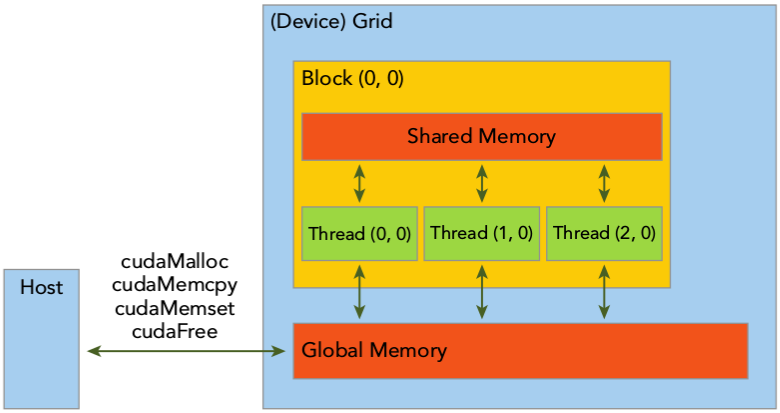

۳ سلسله مراتب حافظه **GPU** (خلاصه)

یکی از ویژگی‌های خیلی خاص برنامه‌نویسی **CUDA** اطلاعاتی است که در مورد سلسله مراتب حافظه در اختیار ما قرار داده شده. هر **GPU** دارای مجموعه حافظه‌ی متفاوتی می‌باشد که برای کاربردهای متفاوت انتخاب شده است. در مورد جزییات این بحث در فصل چهار و پنج بیشتر بحث خواهیم کرد.

در سلسله مراتب حافظه‌ی **GPU**، دو حافظه‌ی مهم وجود دارد که به عنوان حافظه‌ی **global** و **shared** شناخته می‌شود. حافظه‌ی **global** مشابه حافظه‌ی **CPU** بوده، در حالی که **shared memory** شبیه حافظه‌ی کش **CPU** می‌باشد. ولی با این تفاوت که، حافظه‌ی **shared** را می‌توان به طور مستقیم با کرنل کنترل کرد.

فعلا قرار هست که به مدیریت داده بین **host** و **device** بپردازیم، و یاد بگیریم که چطور از طریق **C CUDA** دو آرایه را با همدیگر جمع کنیم. همانطور که در شکل بعدی مشخص است، المان اول از آرایه‌ی **a** با المان اول از آرایه‌ی **b** جمع می‌شود، و نتیجه در المان اول در آرایه‌ی **c** گذاشته می‌شود. این محاسبات برای همه‌ی المان‌ها تکرار می‌شود.

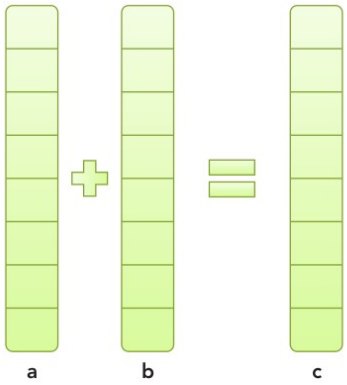

برای جمع زدن دو آرایه ابتدا با **host code** شروع می‌کنیم(**C** استاندارد).

```
#include <stdlib.h>
#include <string.h>
#include <time.h>
void sumArrayOnHost(float *A,float *B,float *C,const int N)
{
    for (int idx = 0; idx <N; ++idx)
    {
        C[idx]=A[idx] + B[idx];
    }
}
void initialData(float *ip,int size)
{
    //generate different seed for random number
    time_t t;
    srand((unsigned int) time(&t));
    for (int i = 0; i < size; ++i)
    {
        ip[i] = (float) (rand() & 0xFF) /10.0f;
    }
}
int main()
{
    int nElem=1024;
    size_t nBytes = nElem * sizeof (float);
```

```
    float *h_A,*h_B,*h_C;
    h_A = (float *)malloc(nBytes);
    h_B = (float *)malloc(nBytes);
    h_C = (float *)malloc(nBytes);
    initialData(h_A, nElem);
    initialData(h_B, nElem);
    sumArrayOnHost(h_A, h_B, h_C,nElem);
    free(h_A);
    free(h_B);
    free(h_C);
    return(0);
}
```

از آنجایی که این یک برنامه خالص زبان **C** هست، می‌تونید با کامپایلر زبان **C** کامپایلش کنید. همچنین می‌تونید با استفاده از **nvcc** به صورت زیر کامپایلش کنید.

```
$ nvcc -Xcompiler -std=c99 sumArraysOnHost.c –o sum
$ ./sum
```

کامپایلر **CUDA** به شما این امکان را میدهد که آپشن‌های فراوانی را به طور مستقیم به **nvcc** پاس دهید. فلگ **Xcompiler**- آپشن‌ها را مستقیما برای کامپایلر **C** مشخص می‌کند. در این مثال، **std=c99**- به کامپایلر پاس داده شده است چون کد نوشته شده طبق استاندارد **C99** نوشته شده است. شما می‌توانید این آپشن‌ها را در داکیومنت کامپایلر **CUDA** در آدرس زیر پیدا کنید.

```
http://docs.nvidia.com/cuda/cuda-compiler-driver-nvcc/index.html
```

حال می‌توانیم کد را به نحوی تغییر دهیم تا بر روی **GPU** اجرا شود.

```
    float *d_A, *d_B, *d_C;
    cudaMalloc((float**)&d_A, nBytes);
    cudaMalloc((float**)&d_B, nBytes);
    cudaMalloc((float**)&d_C, nBytes);
```

حال از تابع **cudaMemcpy** برای انتقال اطلاعات از حافظه‌ی **host** به حافظه‌ی **global** کارت گرافیک استفاده می‌کنیم، پارامتر **cudaMemcpyHostToDevice** مشخص کننده ی نوع انتقالی است که قرار است صورت بگیرد.

```
    cudaMemcpy(d_A,h_A,nElem,cudaMemcpyHostToDevice);
    cudaMemcpy(d_B,h_B,nElem,cudaMemcpyHostToDevice);
```

وقتی که داده به حافظه‌ی **global** کارت گرافیک انتقال داده شد، تابع کرنل می‌تواند از طرف **host** برای جمع دو آرایه بر روی **GPU** صدا زده شود. به محض این که کرنل صدا زده شود، سریعا کنترل به دست **host** برمیگردد. در این نقطه، **host** می‌تواند توابع دیگری را اجرا کند و در همین زمان **GPU** نیز پردازش خودش را انجام بدهد. بنابراین **kernel** نسبت به **host** یک پردازش آسنکرون انجام می‌دهد.

وقتی که کرنل کار پردازش بر روی همه‌ی المان‌ها را تمام کرد، نتیجه بر روی حافظه‌ی گلوبال **GPU** و در آرایه‌ی **d_c** ذخیره شده است. حال باید نتیجه‌ی عملیات **GPU** را به آرایه **gpuRef** بر روی **host** برگردانیم و این کار دوباره با استفاده از تابع **cudaMemcpy** انجام میپذیرد.

```
float *gpuRef;
cudaMemcpy(gpuRef, d_C, nBytes, cudaMemcpyDeviceToHost);
```

فراخوانی کردن **cudaMemcpy** موجب بلاک شدن پردازش **host** می‌شود. نتیجه‌ای که بر روی آرایه‌ی **d_c** بر روی **GPU** قرار داد به **gpuRef** کپی می‌شود، آرگومان **cudaMemcpyDeviceToHost** به این منظور استفاده شده. در نهایت، حافظه‌ای که بر روی **GPU** گرفته شده بود را با استفاده از تابع **cudaFree** آزاد می‌کنیم.

```
cudaFree(d_A);
cudaFree(d_B);
cudaFree(d_C);
```

۳ تفاوت فضای حافظه **host** و **device**

یکی از رایج‌ترین اشتباهاتی که یک برنامه‌نویس تازه کار در CUDA C انجام میدهد این است که به صورت اشتباهی بین حافظه‌های cpu و gpu عملیات dereference کردن را انجام بدهد. برای حافظه‌ای که بر روی GPU اختصاص داده شده، پوینتر ممکن است به درستی بر روی هاست dereference نشود. اگر کد شما به طرز اشتباهی عملیات انتساب زیر را انجام بدهد:

```
gpuRef=d_C;
```

به جای این که از شکل درست زیر استفاده کند:

```
cudaMemcpy(gpuRef, d_C, nBytes, cudaMemcpyDeviceToHost);
```

برنامه شما ممکن است در runtime با خطا روبه‌رو شده و کرش کند. برای کمک به این مشکل در CUDA 6 یک حافظه‌ی یکپارچه معرفی شده که به شما اجازه می‌دهد که هم بر روی CPU و هم بر روی GPU با استفاده از یک اشاره‌گر تنها دسترسی داشته باشید. در مورد این حافظه یکپارچه در فصل چهارم بیشتر یاد خواهیم گرفت.

۳ چرا در زبان **c** از **pointer to pointer** استفاده می‌شود.

ما می‌دانیم که یک اشاره‌گر متغیری است که به یک مکان حافظه اشاره می‌کند و ما از اشاره‌گرها برای ذخیره‌ی آدرس متغیرها استفاده می‌کنیم. بنابراین وقتی که از اشاره‌گر به اشاره‌گر استفاده می‌کنیم.

اشاره‌گر اول آدرس اشاره‌گر دوم را در خود ذخیره می‌کند. به همین دلیل آن‌ها را **double pointer** نیز می‌نامیم.

یک دلیل برای استفاده از **pointer to pointer** این است که می‌خواهید مقدار اشاره‌گری که به تابع پاس داده شده را به عنوان آرگومان تابع عوض کنید، بدین منظور نیاز به **pointer to pointer** خواهید داشت.

به بیان ساده‌تر فرض کنید که شما یک پوینتر دارید، برای تغییر دادن آدرس این پوینتر شما به سادگی می‌توانید این اشاره‌گر را برابر با یک اشاره‌گر دیگر قرار دهید، ولی چه می‌شود اگر بخواهیم آدرس این اشاره‌گر را در داخل یک تابع عوض کنیم، مثال زیر را ببینید،

```
int a=2,b=3;
int* pa=&a;
int* pb=&b;
```

در این مثال، ما دو متغیر به نام‌های **a,b** داریم و دو اشاره‌گر به نام **pa,pb** که اشاره‌گر به **a** و **b** هستند. اگر بخواهیم که **pa** مقدار **pb** را بگیرد به سادگی می‌توانیم این کار را با **pa=pb** قرار دادن انجام دهیم، ولی فرض کنید که بخواهیم این کار را درون یک تابع انجام بدهیم.

```
void change_location(int *add1,int* add2)
{
   add1=add2;
}
```

آیا پس از اجرای این تابع به صورت زیر

```
change_location(pa,pb);
```

آدرس **pa** برابر با **pb** خواهد بود؟ پاسخ نه می‌باشد. چون در نهایت **pa,pb** دو متغیر هستند که به صورت **local** مقدارشان عوض می‌شود و تاثیری در بیرون تابع نمی‌گذارند، پس چطور باید این کار را انجام بدهیم؟ پاسخ این است که باید از یک اشاره‌گر دیگر استفاده کنیم. یعنی تابع ما به صورت زیر تغییر پیدا خواهد کرد.

```
void change_location(int **add1,int **add2)
{
   *add1=*add2;
}
```

و نحوه‌ی فراخوانی این تابع نیز به صورت زیر خواهد بود.

```
change_location(&pa,&pb);
```

۴ مدیریت تردها

وقتی که یک تابع کرنل از سمت **host** اجرا می‌شود، وظیفه‌ی اجرای کرنل بر عهده‌ی **device** گذاشته می‌شود، جایی که تعداد زیادی ترد تولید شده و هر ترد عبارتی که توسط تابع کرنل مشخص شده را اجرا می‌کند. دانستن این که چطور این تردها را می‌توان کنترل کرد یک بخش خیلی مهم در زبان برنامه‌نویسی **CUDA** می‌باشد. **CUDA** در مورد سلسله مراتب این تردها دسترسی‌هایی به ما داده که بتوانیم تردها را مدیریت کنیم. در واقع ما دو سلسله مراتب ترد داریم که به **block ها** و **gridها** تقسیم می‌شود. شکل زیر را ببینید:

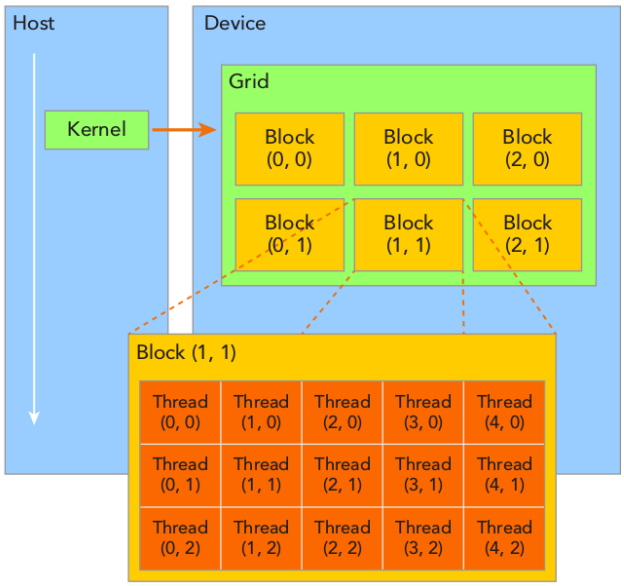

همه‌ی تردهایی که توسط یک کرنل اجرا می‌شوند را مجموعا **grid** می‌نامیم. همه‌ی تردها در درون یک **grid** ، یک حافظه‌ی **global** را با همدیگر سهیم هستند. یک **grid** از مجموعه‌ای از **block** ها **thread** ساخته شده. یک **block** گروهی از تردها هستند که می‌توانند با همدیگر **همکاری** کنند، این همکاری با استفاده از دو مورد زیر انجام می‌شود:

- Block-local synchronization
- Block-local shared memory

تردهایی که از بلاک‌های متفاوت هستند نمی‌توانند با همدیگر همکاری داشته باشند.

تردها از دو مختصات یکتای زیر برای مشخص کردن همدیگر استفاده می‌کنند، یعنی هر ترد را می‌توان با مشخص کردن این دو مختصات به صورت یکتا تعریف کرد، و ترد دیگری با این مختصات وجود ندارد:

- blockIdx (block index within a grid)
- threadIdx (thread index within a block)

این متغیرها به صورت داخلی ساخته شده‌اند، مقداردهی شده‌اند و می‌توان توسط تابع کرنل به این مقادیر دسترسی داشت.(یعنی چیزی نیست که ما بتوانیم برای یک ترد تغییرش دهیم). وقتی که یک تابع کرنل اجرا می‌شود، مختصات **blockIdx** و **threadIdx** توسط **CUDA runtime** به هر ترد انتصاب داده می‌شود. بر اساس این مختصات، می‌توانید قسمت‌های مختلف داده را به تردهای مختلف بدهید.

متغیرهای مختصاتی از نوع **uint3** هستند، این **type** توسط **CUDA** و به صورت داخلی ساخته شده و یک بردار می‌باشد، که از **integer** عادی مشتق شده. در ساختار این **type** جدید ما سه عدد **integer** داریم، و اولین،دومین و سومین عضو این بردار را می‌توان با فیلدهای **x,y** و **z** به ترتیب به دست آورد.

```
blockIdx.x
blockIdx.y
blockIdx.z
threadIdx.x
threadIdx.y
threadIdx.z
```

CUDA در سه بعد **grid** ها و **block** ها را سازماندهی می‌کند. شکل زیر یک مثال از ساختار سلسله مراتبی تردها در یک **grid** دو بعدی است که حاوی **block** های دو بعدی می‌باشد.

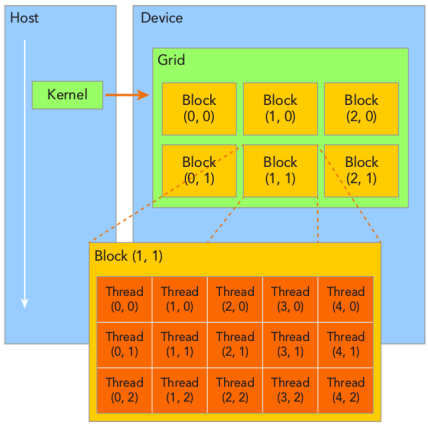

ابعاد **grid** و **block** را می‌توان توسط دو متغیر داخلی زیر به دست آورد.

- blockDim (block dimension, measured in threads)
- gridDim (grid dimension, measured in blocks)

این متغیرها از نوع **dim3** هستند، که یک بردار از اعداد صحیح هستند که بر اساس **uint3** ساخته شده است تا مشخص کننده‌ی ابعاد باشد. وقتی که یک متغیر از نوع **dim3** تعریف می‌کنید، هر کامپوننتی که نامشخص باشد به ۱ مقداردهی می‌شود. هر کامپوننت در متغیر از نوع **dim3** را می‌توان توسط **x,y** و فیلد **z** به دست آورد که در زیر نمایش داده شده است:

```
blockDim.x
```

```
blockDim.y
blockDim.z
```

۴ ابعاد GRID و BLOCK

معمولا، یک grid از آرایه‌های دو بعدی از block ها ساخته شده است، و یک block از یک ساختار سه بعدی تردها تشکیل یافته است.
هم grid ها و هم block ها از dim3 استفاده می‌کنند. Field هایی که مورد استفاده قرار نگیرد به ۱ انتساب داده می‌شود و نادیده گرفته می‌شود.

در برنامه‌ی **CUDA** دو مجموعه متغیر متفاوت وجود دارد: یکی نوع **dim3** می‌باشد که به صورت دستی تعریف می‌شود و یکی **uint3** هست که قبلا تعریف شده. در سمت **host**، می‌توانید ابعاد یک **grid** و **block** را با استفاده از نوع **dim3** به عنوان فراخوانی یک کرنل مشخص کنید. وقتی که کرنل اجرا می‌شود، **CUDA runtime** متغیرهای داخلی، و مقداردهی شده‌ای از **grid** و **block** و **thread** ها را تولید می‌کند که توسط توابع کرنل و به صورت **uint3** قابل دسترسی هستند. متغیرهای دستی **grid** و **block** که به صورت **dim3** هستند، تنها در سمت **host** قابل دیدن هستند، و متغیرهای **built-in**، که از نوع **uint3** هستند تنها برای **device** قابل رویت هستند.

ما این متغیرها را در برنامه‌ی جمع دو آرایه که قبلا به زبان **C** نوشتیم استفاده خواهیم کرد تا بدانید این متغیرها چطور کار می‌کنند. ابتدا، اندازه‌ی داده‌ای که باید در برنامه استفاده شود را مشخص می‌کنیم، به منظور این که توضیح خروجی راحت‌تر باشد، اندازه‌ی داده را کوچک در نظر می‌گیریم.

```
int nElem=6;
```

در ادامه، اندازه‌ی **block size** را تعریف می‌کنیم و **grid size** را بر حسب **block** و اندازه‌ی داده مشخص می‌کنیم. در مورد این مثال، یک **1D block** تعریف می‌شود که سه ترد دارد و یک **1D grid** با تعداد بلاک‌هایی که بر اساس اندازه‌ی **data** و اندازه‌ی **block** می‌باشد.

```
dim3 block(3);
dim3 grid((nElem+block.x-1)/block.x);
```

احتمالا متوجه شده‌اید که اندازه‌ی **grid** با استفاده از تعداد بلاک‌ها روند شده است. نگران نباشید، علت این که چرا باید **grid size** را به این شکل محاسبه کنید را در فصل بعد بحث خواهیم کرد. کد زیر در سمت **host** ابعاد **grid** و **block** را چک می‌کند.

```
printf("grid.x %d grid.y %d grid.z %d\n",grid.x, grid.y, grid.z);
printf("block.x %d block.y %d block.z %d\n",block.x, block.y, block.z);
```

در تابع کرنل، هر ترد اندیس خودش، اندیس **block**، ابعاد **block**، و ابعاد **grid** را می‌تواند به صورت زیر چاپ کند.

```
    printf("threadIdx:(%d, %d, %d) blockIdx:(%d, %d, %d) blockDim:(%d, %d, %d) "
        "gridDim:(%d, %d, %d)\n", threadIdx.x, threadIdx.y, threadIdx.z,
        blockIdx.x, blockIdx.y, blockIdx.z, blockDim.x, blockDim.y, blockDim.z,
        gridDim.x,gridDim.y,gridDim.z);
```

اگر کدها را در کنار هم قرار دهیم، کد جدیدمان به صورت زیر خواهد شد:

```
#include <cuda_runtime.h>
#include <stdio.h>
__global__ void checkIndex(void) {
    printf("threadIdx:(%d, %d, %d) blockIdx:(%d, %d, %d) blockDim:(%d, %d, %d) "
        "gridDim:(%d, %d, %d)\n", threadIdx.x, threadIdx.y, threadIdx.z,
        blockIdx.x, blockIdx.y, blockIdx.z, blockDim.x, blockDim.y, blockDim.z,
        gridDim.x,gridDim.y,gridDim.z);
}
int main(int argc, char **argv) {
    // define total data element
    int nElem = 6;
    // define grid and block structure
    dim3 block (3);
    dim3 grid ((nElem+block.x-1)/block.x);
    // check grid and block dimension from host side
    printf("grid.x %d grid.y %d grid.z %d\n",grid.x, grid.y, grid.z);
    printf("block.x %d block.y %d block.z %d\n",block.x, block.y, block.z);
    // check grid and block dimension from device side
    checkIndex <<<grid, block>>> ();
    // reset device before you leave
    cudaDeviceReset();
    return(0);
}
```

حال می‌توانید کد را به صورت زیر اجرا کنید:

```
$ nvcc -arch=sm_20 checkDimension.cu -o check
$ ./check
```

از آنجایی که تابع **printf** تنها بر روی معماری‌های بعد از **Fermi** جواب میدهد، آپشن **-arch=sm_20** را باید اضافه کنیم. به صورت پیش فرض، **nvcc** کد را برای پایین‌ترین معماری تولید می‌کند. نتیجه‌ی این برنامه به صورت زیر خواهد بود. می‌توانید ببینید که هر ترد مختصات خود را دارد، **و همه‌ی تردها دارای ابعاد یکسان block و grid هستند.**

```
grid.x 2 grid.y 1 grid.z 1
block.x 3 block.y 1 block.z 1
threadIdx:(0, 0, 0) blockIdx:(1, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
threadIdx:(1, 0, 0) blockIdx:(1, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
threadIdx:(2, 0, 0) blockIdx:(1, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
threadIdx:(0, 0, 0) blockIdx:(0, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
threadIdx:(1, 0, 0) blockIdx:(0, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
threadIdx:(2, 0, 0) blockIdx:(0, 0, 0) blockDim:(3, 1, 1) gridDim:(2, 1, 1)
```

۴ دسترسی به متغیرهای GRID/BLOCK از سمت HOST و DEVICE

این خیلی مهمه که بتونیم بین متغیرهای grid,block در سمت host و device تفاوت قایل شویم. به طور مثال، با استفاده از یک متغیر تعریف شده به عنوان block در سمت host، می‌توانیم مختصات را تعریف کرده و به شکل زیر به آن ها دسترسی داشته باشیم.

block.x , block.y *and* block.z

در سمت دیگر، شما یک سری متغیر از پیش مقداردهی شده، و داخلی دارید که به صورت زیر در دسترس می‌باشد.

blockDim.x, blockDim.y *and* blockDim.z

به طور خلاصه، شما متغیرها را برای grid و block روی host تعریف کرده، این کار قبل از اجرای یک کرنل صورت می‌پذیرد، و با استفاده از فیلدهای x,y و z به ساختار این بردار در سمت host دسترسی داشته باشیم. وقتی که کرنل اجرا شد، شما می‌توانید از متغیرهای داخلی و از پیش مقداردهی شده درون کرنل استفاده کنید.

برای یک اندازه‌ی داده خاص، گام‌های عمومی که برای مشخص کردن اندازه‌ی **grid** و **block** وجود دارد عبارت‌است از:

- تصمیم بگیرید که اندازه‌ی **block size** چقدر می‌باشد.
- ابعاد **grid** را بر اساس اندازه‌ی داده و **block size** مشخص کنید.

برای مشخص کردن ابعاد **block**، معمولا باید دو مورد زیر را لحاظ کنید:

- ➤ Performance characteristics of the kernel
- ➤ Limitations on GPU resources

در مورد این موضوع در مثال‌هایی که در ادامه در فصول مختلف خواهیم آورد صحبت خواهیم کرد. کدی که در ادامه خواهیم آورد از یک **grid** یک بعدی و **block** یک بعدی استفاده می‌کند، و **block size** تغییر می‌کند و به همین خاطر **grid size** نیز تغییر می‌کند.

```
#include <cuda_runtime.h>
#include <stdio.h>
int main(int argc, char **argv) {
   // define total data elements
   int nElem = 1024;
   // define grid and block structure
   dim3 block (1024);
   dim3 grid ((nElem+block.x-1)/block.x);
   printf("grid.x %d block.x %d \n",grid.x, block.x);
   // reset block
   block.x = 512;
   grid.x = (nElem+block.x-1)/block.x;
   printf("grid.x %d block.x %d \n",grid.x, block.x);
   // reset block
   block.x = 256;
   grid.x = (nElem+block.x-1)/block.x;
   printf("grid.x %d block.x %d \n",grid.x, block.x);
   // reset block
   block.x = 128;
   grid.x = (nElem+block.x-1)/block.x;
   printf("grid.x %d block.x %d \n",grid.x, block.x);
   // reset device before you leave
   cudaDeviceReset();
   return(0);
}
```

این برنامه را کامپایل کرده و با استفاده از دستور زیر آن را اجرا می‌کنیم:

```
$ nvcc defineGridBlock.cu -o block
$ ./block
```

خروجی به صورت زیر خواهد بود. از آنجایی که اندازه‌ی داده در این برنامه ثابت بود، وقتی که **block size** تغییر می‌کند، بایستی **grid size** نیز تغییر کند.

```
grid.x 1        block.x 1024
grid.x 2        block.x 512
grid.x 4        block.x 256
grid.x 8        block.x 128
```

۴ سلسله مراتب ترد

یکی از ویژگی‌هایی که CUDA را از سایر سیستم‌های چند تردی متمایز می‌کند، سلسله مراتب دو سطحی ترد در مدل برنامه‌نویسی آن هست. به این دلیل که ابعاد grid و block در کارآیی کرنلی که اجرا می‌شود، تاثیر دارد، در اختیار گذاشتن این abstraction به برنامه‌نویس، می‌تواند منجر به یک راه برای بهینه کردن شود.
چندین محدودیت روی ابعاد grid ها و block ها خواهیم داشت. یکی از بزرگترین محدودیت‌ها روی block size میزان منابع محاسباتی موجود است، مثل رجیسترها، حافظه‌ی اشتراکی، و مواردی از این دست. اطلاعات برخی از این محدودیت‌ها را می‌توان با فرستادن یک درخواست از خود GPU گرفت.
Grid ها و block ها در واقع یک روشی برای پیدا کردن دید از سلسله مراتب تردهای تابع کرنل است. در فصل ۳، خواهید دید که این نوع از سازماندهی تردها به شما اجازه میدهد که به طور کارآمدتری یک برنامه‌ی یکسان را بر روی device های متفاوت اجرا کنید، که هر کدام دارای میزان منابع و حافظه متفاوت هستند.

۵ راه‌اندازی یک کرنل CUDA

شما با **syntax** زیر از زبان **C** آشنا هستید:

```
function_name (argument list);
```

یک فراخوانی از کرنل **CUDA** در واقع یک افزونه‌ی مستقیم به زبان **C** هست که فقط تنظیمات کرنلی که قرار است اجرا شود را در داخل **triple-angle-brackets** میگیرد:

```
kernel_name <<<grid, block>>>(argument list);
```

همانطور که در قسمت قبلی توضیح داده شد، مدل برنامه‌نویسی **CUDA** سلسله مراتب ترد را در اختیار شما قرار میدهد، و می‌توانید مشخص کنید که چطور تردها برای اجرا روی **GPU** برنامه‌ریزی شوند. اولین مقداری که به کرنل پاس داده می‌شود ابعاد **grid** بود یعنی تعداد بلاک‌هایی که قرار است راه‌اندازی شود. مقدار دوم ابعاد **block** می‌باشد، یعنی تعداد تردهایی که قرار است روی هر **block** اجرا شود. با مشخص کردن ابعاد **grid** و **block** ، در واقع تنظیمات زیر را انجام داده‌اید:

- تعداد کل تردهایی که بر روی یک کرنل اجرا می‌شود.
- طرح تردهایی که می‌خواهید بر روی کرنل استفاده شود.

تردهایی که درون یک بلاک هستند به راحتی می‌توانند با همدیگر ارتباط داشته باشند، و تردهایی که متعلق به بلاک‌های مختلف هستند نمی‌توانند با همدیگر ارتباطی داشته باشند. برای یک مساله‌ی داده شده، شما می‌توانید از **grid** و **block** متفاوتی استفاده کنید. به طور مثال، فرض کنید که شما ۳۲ تا داده دارید که باید یک سری محاسبه بر روی آن انجام شود. شما می‌توانید این داده را به گروه‌های هشت‌تایی شکسته و هر گروه را به یک بلاک دهید، و چهار بلاک*(یعنی اندازه‌ی گرید چهار می‌باشد)* را راه اندازی کنید:

```
kernel_name<<<4, 8>>>(argument list);
```

شکل زیر طرح تردها را برای تنظیمات بالا نشان میدهد.

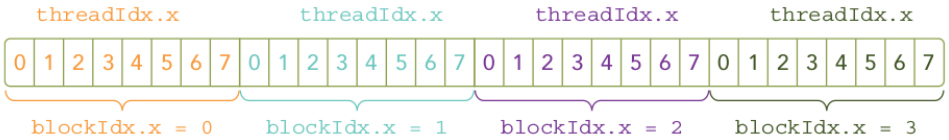

از آنجایی که داده به صورت خطی در حافظه‌ی **global** ذخیره می‌شود، می‌توانید از متغیرهای داخلی **blockIdx.x** و **threadIdx.x** برای دو منظور زیر استفاده کنید:

- مشخص کردن یک ترد خاص در یک **grid**
- مشخص کردن یک نگاشت بین تردها و المان‌های داده ها(یعنی برای هر داده‌ی خاص روی حافظه یک ترد خاص و یکتا انتساب می‌کنیم)

اگر ۳۲ المان را در یک بلاک قرار دهیم، در این صورت نحوه‌ی فراخوانی کرنل به صورت زیر تغییر خواهد کرد.

```
kernel_name<<<1, 32>>>(argument list);
```

اگر بخواهیم که به هر بلاک فقط یک المان از داده را بدهیم، در این صورت ۳۲ بلاک خواهیم داشت که به صورت زیر فراخوانی می‌شود.

```
kernel_name<<<32, 1>>>(argument list);
```

فراخوانی یک کرنل، یک پروسه آسنکرون نسبت به **host** می‌باشد. وقتی که یک کرنل فراخوانی شد، بلافاصله کنترل دوباره به دست **host** سپرده می‌شود. می‌توانید از دستور زیر استفاده کنید تا **host** را مجبور کنید که منتظر تمام شدن همه‌ی کرنل‌ها بشیند.

```
cudaError_t cudaDeviceSynchronize(void);
```

برخی از **API** های **CUDA runtime** یک سنکرون سازی غیر صریح بین **host** و **device** را انجام میدهند. وقتی که از دستور **cudaMemcpy** به منظور کپی کردن داده بین **host** و **device** استفاده می‌کنید، یک

سنکرون سازی غیر صریح در سمت **host** اتفاق می‌افتد و برنامه‌ی سمت **host** باید منتظر بماند تا داده به صورت کامل کپی شود.

```
cudaError_t cudaMemcpy(void* dst, const void* src, size_t count, cudaMemcpyKind kind);
```

وقتی این تابع شروع به کپی کردن می‌کند که همه‌ی فراخوانی‌های قبلی از کرنل کامل شده باشند. وقتی که کپی کامل شد، سریعا کنترل به سمت **host** برمیگردد.

۵ رفتار آسنکرون

برخلاف فراخوانی یک تابع C، همه‌ی توابع کرنل به صورت آسنکرون آغاز به کار می‌کنند، و بعد از آن کنترل سریعا دست CPU سپرده میشود.

۶ نوشتن کرنل

تابع کرنل تابعی است که در سمت **device** اجرا می‌شود. در تابع کرنل، شما یک محاسبه‌ای را برای اجرا بر روی یک ترد مشخص می‌کنید، و دیتایی که برای دسترسی به آن ترد نیاز دارید نیز مشخص می‌کنید. وقتی که کرنل فراخوانی می‌شود، تردهای مختلف **CUDA** همان محاسباتی که مشخص کرده بودید را بر به صورت پارالل اجرا می‌کنند. یک کرنل با استفاده از اعلان **__global__** مشخص می‌شود. که در ادامه یک لیست از این اعلان‌ها آورده‌ایم.

```
__global__ void kernel_name(argument list);
```

یک تابع کرنل حتما باید در خروجی **void** داشته باشد.

جدول زیر، یک خلاصه‌ای از این توابع مشخص‌کننده در برنامه‌نویسی **C** را نشان میدهد. در واقع **qualifier** مشخص می‌کند که یک تابع بر روی **host** اجرا شود و یا بر روی **device** و یا این که قابلیت این را داشته باشد که از دو سمت نیز فراخوانی شود.

TABLE 2-2: Function Type Qualifiers

QUALIFIERS	EXECUTION	CALLABLE	NOTES
`__global__`	Executed on the device	Callable from the host Callable from the device for devices of compute capability 3	Must have a `void` return type
`__device__`	Executed on the device	Callable from the device only	
`__host__`	Executed on the host	Callable from the host only	Can be omitted

Qualifiers های **__device__** و **__host__** می‌توانند با همدیگر استفاده شوند، و آن موقعی است که تابع هم برای **host** و هم برای **device** کامپایل شود.

۶ توابع کرنل، توابع دارای محدودیت هستند

محدودیت‌های زیر بر روی همه‌ی کرنل‌ها اعمال می‌شود:

- ✔ تنها به حافظه‌ی **device** دسترسی دارند.
- ✔ بایستی نوع خروجی **void** باشد.
- ✔ از تعداد آرگومان‌های متغیر پشتیبانی نمی‌کنند.
- ✔ از متغیرهای **static** پشتیبانی نمی‌کنند.
- ✔ از اشاره‌گر به تابع پشتیبانی نمی‌کنند.
- ✔ یک رفتار آسنکرون دارند.

به عنوان نمونه، یک مثال ساده از جمع کردن دو بردار **A,B** با سایز **N** را در نظر بگیرید. برنامه‌ای که برای جمع این دو بردار در زبان **C** نوشته شده بود به صورت زیر بود:

```
void sumArraysOnHost(float *A, float *B, float *C, const int N) {
    for (int i = 0; i < N; i++)
        C[i] = A[i] + B[i];
}
```

این یک برنامه‌ی ترتیبی است که که **N** بار یک کاری را انجام میدهد. با خلاص شدن از حلقه به منظور نوشتن یک کرنل برنامه به صورت زیر درمیآید.

```
__global__ void sumArraysOnGPU(float *A, float *B, float *C) {
    int i = threadIdx.x;
    C[i] = A[i] + B[i];
}
```

تفاوت بین تابع در زبان **C** و تابع کرنل چیست؟ واضح است تابع کرنل حلقه ندارد، مختصات تردها به منظور اندیس آرایه استفاده شده، و هیچ رفرنسی به **N** وجود ندارد، در واقع این کار به صورت غیر صریح و مشخص کردن **N** ترد برای اجرا قبلا مشخص شده است.

فرض کنید که یک بردار به طول ۳۲ داریم، شما می‌توانید یک کرنل با ۳۲ ترد به صورت زیر بر روی آن اجرا کنید.

```
sumArraysOnGPU<<<1,32>>>(float *A, float *B, float *C);
```

۷ صحت سنجی کرنل

بعد از این که کرنل را نوشتید، از کجا می‌توانیم بفهمیم که به درستی کار می‌کند؟ در این صورت نیاز به یک تابع **host** داریم که نتایج کرنل را تصدیق کند.

```
void checkResult(float *hostRef, float *gpuRef, const int N) {
    double epsilon = 1.0E-8;
    int match = 1;
    for (int i = 0; i < N; i++) {
        if (abs(hostRef[i] - gpuRef[i]) > epsilon) {
            match = 0;
            printf("Arrays do not match!\n");
            printf("host %5.2f gpu %5.2f at current %d\n",
                hostRef[i], gpuRef[i], i);
            break;
        }
    }
    if (match) printf("Arrays match.\n\n");
    return;
}
```

تصدیق کد کرنل ۷

در کنار، ابزارهای دیباگی که وجود دارد، دو روش ابتدایی برای تصدیق کد کرنل وجود دارد.
اول این که، می‌توانید از printf برای نسل Fermi و نسل‌های بعدتر استفاده کنید.
دوم، می‌تونید کانفیگ اجرای کرنل را بر روی <<<۱,۱>>> قرار دهید، یعنی کرنل را مجبور کنید که تنها بر روی یک بلاک و بر روی ترد کار کند. این یک پیاده‌سازی ترتیبی خواهد بود. این برای دیباگ کردن و صحت سنجی نتایج درست بسیار مفید خواهد بود. همچنین، این به شما کمک می‌کند تا راحت‌تر بتوانید مشخص کنید که نتایج به صورت بیت به بیت با هم یکسان هستند، مخصوصا اگر با مسایلی روبه‌رو هستید که حالت ترتیبی دارند.

۸ رسیدگی به خطاها

از آنجایی که بیشتر فراخوانی‌ها **CUDA** به صورت آسنکرون هستند، مشخص کردن این که کدام روتین منجر به خطا شده است مشکل است. مشخص کردن یک ماکرو برای رسیدگی به خطا که به عنوان پوششی برای **CUDA API** باشد منجر به سادگی چک کردن خطاها می‌شود.

```
#define CHECK(call)
{
    const cudaError_t error = call;
    if (error != cudaSuccess)
    {
        printf("Error: %s:%d, ", __FILE__, __LINE__);
        printf("code:%d, reason: %s\n", error, cudaGetErrorString(error));
        exit(1);
    }
}
```

به طور مثال، می‌توانید از این ماکرو برای چک کردن کد زیر استفاده کنید.

```
CHECK(cudaMemcpy(d_C, gpuRef, nBytes, cudaMemcpyHostToDevice));
```

اگر کپی کردن حافظه و یا عملیاتی آسنکرون قبلی منجر به یک خطا شود، ماکرو گزارش خطا را خواهد داد، و یک پیام که توسط انسان قابل خواندن است را گزارش می‌کند، و برنامه را متوقف می‌کند. همچنین می‌توانید از این برنامه اجرای کرنل‌ها نیز به صورت زیر استفاده کنید:

```
    kernel_function<<<grid, block>>>(argument list);
    CHECK(cudaDeviceSynchronize());
```

در اینجا، **CHECK(cudaDeviceSynchronize())** ترد **host** را متوقف می‌کند تا همه‌ی **task** های قبلی اجرا شوند، و اطمینان حاصل شود که هیچ خطایی در اجرای کرنل رخ نداده است. این تکنیک تنها باید در مرحله دیباگ اجرا شود، چرا که اضافه کردن این **check point** بعد از کرنل منجر به متوقف شدن ترد **host** می‌شود و به عنوان یک سد عمل خواهد کرد.

۹ کامپایل و اجرا

حال کل کدها را با هم در یک فایل به نام **sumArraysOnGPU_small_case.cu** جمع کرده، این کد به صورت زیر خواهد شد:

```
#include <cuda_runtime.h>
#include <stdio.h>
#define CHECK(call){gpu_error_checker((call),__FILE__,__LINE__);}
inline void gpu_error_checker(cudaError_t error,const char*file, int line)
{
    if (error != cudaSuccess)
    {
```

```
        printf("Error: %s:%d, ", __FILE__, __LINE__);
        printf("code:%d, reason: %s\n", error, cudaGetErrorString(error));
    }
}
void checkResult(float *hostRef, float *gpuRef, const int N) {
    double epsilon = 1.0E-8;
    bool match = 1;
    for (int i=0; i<N; i++) {
        if (abs(hostRef[i] - gpuRef[i]) > epsilon) {
            match = 0;
            printf("Arrays do not match!\n");
            printf("host %5.2f gpu %5.2f at current %d\n",hostRef[i],gpuRef[i],i);
            break;
        }
    }
    if (match) printf("Arrays match.\n\n");
}
void initialData(float *ip,int size) {
    // generate different seed for random number
    time_t t;
    srand((unsigned) time(&t));
    for (int i=0; i<size; i++) {
        ip[i] = (float)( rand() & 0xFF )/10.0f;
    }
}
void sumArraysOnHost(float *A, float *B, float *C, const int N) {
    for (int idx=0; idx<N; idx++)
        C[idx] = A[idx] + B[idx];
}
__global__ void sumArraysOnGPU(float *A, float *B, float *C) {
    int i = threadIdx.x;
    C[i] = A[i] + B[i];
}
int main(int argc, char **argv) {
    printf("%s Starting...\n", argv[0]);
    // set up device
    int dev = 0;
    cudaSetDevice(dev);
    // set up data size of vectors
```

```
int nElem = 32;
printf("Vector size %d\n", nElem);
// malloc host memory
size_t nBytes = nElem * sizeof(float);
float *h_A, *h_B, *hostRef, *gpuRef;
h_A= (float *)malloc(nBytes);
h_B= (float *)malloc(nBytes);
hostRef = (float *)malloc(nBytes);
gpuRef = (float *)malloc(nBytes);
// initialize data at host side
initialData(h_A, nElem);
initialData(h_B, nElem);
memset(hostRef, 0, nBytes);
memset(gpuRef, 0, nBytes);
// malloc device global memory
float *d_A, *d_B, *d_C;
cudaMalloc((float**)&d_A, nBytes);
cudaMalloc((float**)&d_B, nBytes);
cudaMalloc((float**)&d_C, nBytes);
// transfer data from host to device
cudaMemcpy(d_A, h_A, nBytes, cudaMemcpyHostToDevice);
cudaMemcpy(d_B, h_B, nBytes, cudaMemcpyHostToDevice);
// invoke kernel at host side
dim3 block (nElem);
dim3 grid (nElem/block.x);
sumArraysOnGPU<<< grid, block >>>(d_A, d_B, d_C);
printf("Execution configuration <<<%d, %d>>>\n",grid.x,block.x);
// copy kernel result back to host side
cudaMemcpy(gpuRef, d_C, nBytes, cudaMemcpyDeviceToHost);
// add vector at host side for result checks
sumArraysOnHost(h_A, h_B, hostRef, nElem);
// check device results
checkResult(hostRef, gpuRef, nElem);
// free device global memory
cudaFree(d_A);
cudaFree(d_B);
cudaFree(d_C);
// free host memory
free(h_A);
```

```
    free(h_B);
    free(hostRef);
    free(gpuRef);
    return(0);
}
```

تنظیمات اجرا در این مورد بر روی یک بلاک تنظیم شده است، که شامل ۳۲ المان می‌باشد:

```
dim3 block (nElem);
dim3 grid (nElem/block.x);
```

این کد را می‌توانید با استفاده از کامندهای زیر کامپایل و اجرا کنید:

```
$ nvcc sumArraysOnGPU-small-case.cu -o addvector
$ ./addvector
```

نتیجه‌ای که سیستم خروجی می‌دهد یک چیزی به مانند زیر است.

```
cuda_c_code Starting...
Vector size 32
Execution configuration <<<1, 32>>>
Arrays match.
```

اگر تنظیمات اجرا را بر روی ۳۲ بلاک قرار دهید، در این صورت هر بلاک تنها یک المان را میگیرد:

```
dim3 block (1);
dim3 grid (nElem);
```

در این صورت نیاز خواهید داشت که در تابع کرنل **sumArraysOnGPU** خط زیر را

```
int i = threadIdx.x;
```

با خط زیر جابه‌جا کنید:

```
int i = blockIdx.x;
```

در حالت کلی می‌توانید اندیس یکتایی را برای دسترسی به دیتا به صورت زیر تعریف کنید، باید توجه داشته باشید که این دستور بر اساس **grid** و **block** یک بعدی نوشته شده است:

```
__global__ void sumArraysOnGPU(float *A, float *B, float *C)
{
    int i = blockIdx.x*blockDim.x+threadIdx.x;
    C[i] = A[i] + B[i];
}
```

در واقع شما باید این تغییر رو لحاظ کنید تا مطمعن شوید که در حالت کلی جواب درستی به شما داده می‌شود.

۱۰ گرفتن تایم کرنل

این که بدانیم چه میزان زمان لازم است تا کرنل اجرا شود برای ما سودمند می‌باشد، همچنین موقع ارزیابی کارآمدی کرنل این یک کار ضروری به حساب می‌آید. چندین روش برای گرفتن زمان اجرای کرنل وجود دارد. ساده‌ترین راه استفاده از تایمر **CPU** و یا تایمر **GPU** می‌باشد، که از سمت **host** اندازه گیری می‌شود. در این قسمت ما یک تایمر **CPU** خواهیم ساخت، همچنین یاد خواهیم گرفت که چطور از **NVIDIA profiler** استفاده کنیم.

فصل شش به شما آموزش خواهد داد که چطور از روتین‌های گرفتن زمان **CUDA** استفاده کنید.

۱۱ گرفتن زمان اجرا با استفاده از تایمر CPU

تایمر **CPU** را می‌توان با استفاده از فراخوانی از سیستم **gettimeofday** گرفت، که تعداد ثانیه‌هایی که از مبدا تاریخ سیستم زده شده را برمیگرداند. برای این منظور لازم است که هدر فایل **sys/time.h** را نیز در برنامه بیاورید.

```
double cpuSecond(){
   struct timeval tp;
   gettimeofday(&tp,NULL);
   return ((double)tp.tv_sec+(double)tp.tv_usec*1.e-6);
}
```

حال می‌توانیم با استفاده از این تابع زمان اجرای کرنل را به صورت زیر به‌دست‌بیاوریم.

```
   double iStart=cpuSecond();
   sumArraysOnGPU<<< grid, block >>>(d_A, d_B, d_C);
   cudaDeviceSynchronize();
   double iElaps=cpuSecond()-iStart;
   printf("TIME ELAPSED=%f \n",iElaps);
```

که خروجی روی سیستم من به صورت زیر خواهد بود.

```
TIME ELAPSED=0.000023
```

از آنجایی که فراخوانی یک کرنل نسبت به **host** یک رفتار آسنکرون دارد، ما مجبوریم که از تابع سنکرون کردن یعنی تابع **cudaDeviceSynchronize** استفاده کنیم تا **host** منتظر اجرای همه‌ی تردهای **GPU** باشد. متغیر **iElaps** میزان زمان سپری شده را به ثانیه نمایش میدهد.

حال برنامه را با یک بردار ۱۶ میلیونی تست می‌کنیم

```
int nElem = 1<<24;
```

برای این منظور بایستی کرنل را به منظور مقیاس‌پذیری **GPU** با استفاده از اندیس **block** و **thread** تصحیح کنیم، و یک شرط نیز برای این اندیس‌ها قرار دهیم تا از مرز رد نشود (**i<N**):

```
__global__ void sumArraysOnGPU(float *A, float *B, float *C,const int N) {
    int i = blockIdx.x*blockDim.x+threadIdx.x;
    if(i<N) C[i] = A[i] + B[i];
}
```

با این تغییرات می‌توانیم کرنل را با تنظیمات مختلفی اجرا کنیم. حال ممکن است حالتی پیش بیاید که تعداد کل تردها بیشتر از تعداد کل بردار باشد، در این حالت باید کرنل را از دسترسی به حافظه‌ی غیر مجاز منع کنید. که در شکل زیر نمایش داده شده است:

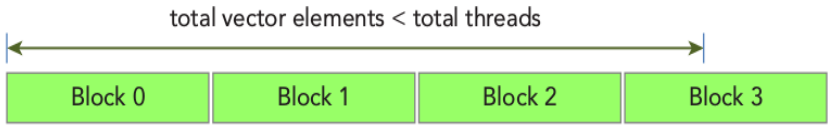

A grid with 4 blocks

در این صورت برنامه به صورت زیر در خواهد آمد.

```
int main(int argc, char **argv) {
    printf("%s Starting...\n", argv[0]);
    // set up device
    int dev = 0;
    cudaSetDevice(dev);
    // set up data size of vectors
    int nElem = 1<<24;
    printf("Vector size %d\n", nElem);
    // malloc host memory
    size_t nBytes = nElem * sizeof(float);
    float *h_A, *h_B, *hostRef, *gpuRef;
    h_A= (float *)malloc(nBytes);
    h_B= (float *)malloc(nBytes);
    hostRef = (float *)malloc(nBytes);
    gpuRef = (float *)malloc(nBytes);
```

```
// initialize data at host side
initialData(h_A, nElem);
initialData(h_B, nElem);
memset(hostRef, 0, nBytes);
memset(gpuRef, 0, nBytes);
// malloc device global memory
float *d_A, *d_B, *d_C;
cudaMalloc((float**)&d_A, nBytes);
cudaMalloc((float**)&d_B, nBytes);
cudaMalloc((float**)&d_C, nBytes);
// transfer data from host to device
cudaMemcpy(d_A, h_A, nBytes, cudaMemcpyHostToDevice);
cudaMemcpy(d_B, h_B, nBytes, cudaMemcpyHostToDevice);
// invoke kernel at host side
int iLen=1024;
dim3 block (iLen);
dim3 grid ((nElem+block.x-1)/block.x);
double iStart=cpuSecond();
sumArraysOnGPU<<< grid, block >>>(d_A, d_B, d_C,nElem);
cudaDeviceSynchronize();
double iElaps=cpuSecond()-iStart;
printf("TIME ELAPSED ON GPU=%f \n",iElaps);
printf("Execution configuration <<<%d, %d>>>\n",grid.x,block.x);
// copy kernel result back to host side
cudaMemcpy(gpuRef, d_C, nBytes, cudaMemcpyDeviceToHost);
// add vector at host side for result checks
iStart=cpuSecond();
sumArraysOnHost(h_A, h_B, hostRef, nElem);
iElaps=cpuSecond()-iStart;
printf("TIME ELAPSED ON CPU=%f \n",iElaps);
// check device results
checkResult(hostRef, gpuRef, nElem);
// free device global memory
cudaFree(d_A);
cudaFree(d_B);
cudaFree(d_C);
// free host memory
free(h_A);
free(h_B);
```

```
    free(hostRef);
    free(gpuRef);
    return(0);
}
```

پس از کامپایل و مشاهده‌ی برنامه می‌توانیم تفاوت پرفرمنس را در **GPU** و **CPU** را ببینیم.

```
Vector size 16777216
TIME ELAPSED ON GPU=0.000660
Execution configuration <<<16384, 1024>>>
TIME ELAPSED ON CPU=0.020561
Arrays match.
```

با کاهش ابعاد بلاک به ۵۱۲ باعث می‌شویم که تعداد کل بلاک‌هایی که ساخته می‌شود، دو برابر شود یعنی به ۳۲۷۶۸ افزایش پیدا کند. با این تنظیمات جدید، پرفرمنس سیستم به مقدار کمی بهبود پیدا کند.

اگر اندازه‌ی بلاک را تا حدود ۲۵۶ کاهش دهید، سیستم یک خطا به صورت زیر به شما میدهد که نشان میدهد که تعداد کل **block** ها از حد مجاز در حالت **1D grid** گذشته است.(ولی روی سیستم من که **1080ti** هستش این موضوع مصداقی ندارد و من تا اندازه‌ی **blocksize=1** نیز تونستم برسم).

۱ محدودیت‌هایی که وجود دارد را بشناسید

یک مفهوم کلیدی در تنظیماتی که برای کرنل داریم، دانستن همین محدودیت‌هایی هست که روی ابعاد grid و block داریم. بیشترین سایز برای هر کدام نسبت به device متغیر است.
CUDA این امکان را در اختیار ما قرار داده است که چنین محدودیت‌هایی را از خود GPU بپرسیم.
اطلاعات بیشتر در مورد این موضوع را می‌توانید در قسمت مدیریت device از این فصل، مطالعه کنید.
برای deviceهای Fermi، بیشترین تعداد ترد به ازای هر بلاک ۱۰۲۴ تا ترد است، و بیشترین ابعاد grid در راستای x,y,z برابر با ۶۵۵۳۵ می‌باشد.

۱۲ گرفتن زمان با استفاده از nvprof

از **CUDA 5.0** یک دستور کامندی برای گرفتن میزان زمان اجرای برنامه، معرفی شد که **nvprof** نامیده می‌شد، و به شما اجازه میدهد که اطلاعات زمان‌بندی فعالیت‌های **CPU** و **GPU** را بگیرین، این فعالیت‌ها شامل اجرای کرنل، حافظه‌ی انتقال داده شده و فراخوانی‌های **CUDA API** می‌شوند. نحوه‌ی استفاده از این دستور در خط زیر آورده شده است.

```
$ nvprof [nvprof_args] <application> [application_args]
```

اطلاعات بیشتر در مورد دستور **nvprof** را می‌توانید با استفاده از دستور زیر به دست بیاورید:

```
$ nvprof –help
```

همچنین می‌توانید با استفاده از **nvprof** کرنل را به صورت دقیق‌تری با استفاده از دستور زیر بررسی کنید:

```
$ nvprof ./sumArraysOnGPU-timer
```

خروجی‌ای که **nvprof** به ما میدهد بر اساس **gpu** ای که با آن کار می‌کنیم متغیر است. خروجی زیر بر روی **1080ti** گزارش می‌شود.

```
./cuda_c_code Starting...
==6316== NVPROF is profiling process 6316, command: ./cuda_c_code
Vector size 16777216
TIME ELAPSED ON GPU=0.000648
Execution configuration <<<32768, 512>>>
TIME ELAPSED ON CPU=0.023049
Arrays match.

==6316== Profiling application: ./cuda_c_code
==6316== Profiling result:
            Type  Time(%)      Time     Calls       Avg       Min       Max  Name
 GPU activities:   62.95%  29.582ms         2  14.791ms  14.777ms  14.804ms  [CUDA memcpy HtoD]
                   35.87%  16.860ms         1  16.860ms  16.860ms  16.860ms  [CUDA memcpy DtoH]
                    1.18%  554.35us         1  554.35us  554.35us  554.35us  sumArraysOnGPU(float*, float*, float*, int)
      API calls:   74.94%  157.10ms         3  52.366ms  259.62us  156.57ms  cudaMalloc
                   22.40%  46.947ms         3  15.649ms  14.943ms  17.054ms  cudaMemcpy
                    1.95%  4.0947ms         3  1.3649ms  297.67us  1.9007ms  cudaFree
                    0.29%  606.80us         1  606.80us  606.80us  606.80us  cudaDeviceSynchronize
                    0.27%  559.91us        94  5.9560us     146ns  248.28us  cuDeviceGetAttribute
                    0.11%  221.31us         1  221.31us  221.31us  221.31us  cuDeviceTotalMem
                    0.03%  58.024us         1  58.024us  58.024us  58.024us  cuDeviceGetName
                    0.01%  31.168us         1  31.168us  31.168us  31.168us  cudaLaunch
                    0.00%  6.1550us         1  6.1550us  6.1550us  6.1550us  cudaSetDevice
                    0.00%  3.2000us         4     800ns     189ns  2.2990us  cudaSetupArgument
                    0.00%  1.7500us         3     583ns     138ns  1.3260us  cuDeviceGetCount
                    0.00%  1.0640us         1  1.0640us  1.0640us  1.0640us  cudaConfigureCall
                    0.00%     998ns         2     499ns     199ns     799ns  cuDeviceGet
```

نیمه‌ی اول از پیام‌هایی که در خروجی آورده شده برای خود برنامه بوده، و قسمت دوم خروجی‌ای است که دستور **nvprof** به ما داده است. توجه کنید که **CPU timer** به ما گزارش زیر را داده است

```
TIME ELAPSED ON GPU=0.000648
```

ولی چیزی که **nvprof** گزارش کرده است به صورت زیر است:

```
1.18%  554.35us        1  554.35us  554.35us  554.35us  sumArraysOnGPU(float*, float*, float*, int)
```

در این مورد، عددی که **nvprof** گزارش می‌کند خیلی دقیق‌تر از قسمت **host** می‌باشد، چرا که اندازه‌گیری با **CPU** نسبت به **nvprof** دارای سربار می‌باشد.

در واقع، **nvprof** یک ابزار بسیار قدرتمند برای کمک به این هست که بفهمید چه میزان زمان برای هر قسمت از برنامه تلف شده است. در مورد این مثال، انتقال اطلاعات بین **host** و **device** زمان بیشتری از اجرای کرنل میبرد. شکل زیر یک زمان‌بندی برای : میزان زمان سپری شده بر روی **CPU** ، زمانی که برای انتقال اطلاعات سپری شده، و زمانی که برای محاسبه روی **GPU** سپری شده را نشان میدهد.

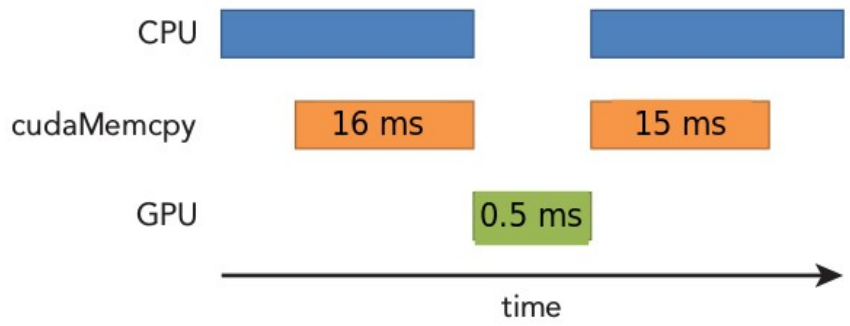

برای **HPC workloads**، این مهم هست که نسبت ارتباطات رو در یک برنامه محاسبه کنیم. اگر برنامه شما برای محاسبات زمان بیشتری از انتقال اطلاعات سپری می‌کند، در این صورت می‌توان این عملیات‌ها را با هم **overlap** کرد و این تاخیر را کاملا با یک انتقال اطلاعات مناسب پنهان کرد. اگر برنامه شما زمان کمتری برای محاسبات سپری می‌کند و انتقال اطلاعات تاخیر بیشتری دارد، در این صورت مهم است که انتقال اطلاعات بین **host** و **device** را به حداقل رساند. در فصل ۶، یاد خواهید گرفت که چطور محاسبات را با استفاده از ارتباطات **overlap** کنید.

۱ مقایسه‌ی پرفرمنس نرم‌افزار برای بیشینه کردن محدودیت‌های نظری

وقتی که در حال بهینه کردن یک نرم‌افزار هستیم، این مهم هست که برنامه چطور با محدودیت‌های تعوری مقایسه می‌شود. اطلاعاتی که از nvprof به دست آورده‌ایم می‌تواند در به دست آوردن دستورات و حافظه در برنامه به ما کمک کند. اگر برنامه را با مقادیر اندازه گیری شده با مقدار پیک تعوری مقایسه کنید، می‌توانید بفهمید که آیا برنامه محدودیت محاسباتی یا پهنای باند حافظه دارد یا خیر. این نسبت‌های تعوری بر روی Tesla K10 به صورت زیر آورده شده است:

➤ **Tesla K10 Peak Single Precision FLOPS:**
745 MHz core clock * 2 GPUs/board * (8 multiprocessors * 192 fp32 cores/ multiprocessor) * 2 ops/cycle = 4.58 TFLOPS
➤ **Tesla K10 Peak Memory Bandwidth:**
2 GPUs/board * 256 bit * 2500 MHz mem-clock * 2 DDR / 8 bits/ byte = 320 GB/s
➤ **Ratio of instruction:bytes:**
4.58 TFLOPS / 320 GB/s yields 13.6 instructions:1 byte

برای Tesla K10 ، اگر برنامه شما به ازای هر بایتی که دسترسی دارد، ۱۳.۶ دستور را انجام دهد، در این صورت برنامه شما به وسیله‌ی arithmetic performance محدود شده است. بیشتر HPC workload ها توسط پهنای باند حافظه محدود شده‌اند.

۱۳ سازماندهی کردن تردهای موازی

همین الان دیدیم که اگر اندازه‌ی **grid** و **block** را به درستی انتخاب کنیم، می‌تونیم تاثیر مناسبی روی کارآمدی برنامه در کرنل‌ها بگذاریم. در مثال جمع برداری، شما **block size** رو برای بهترین کارآیی انتخاب کردید، و اندازه‌ی **grid** بر اساس **block size** و اندازه‌ی بردار تعیین شد.

حال قرار است که این موضوع را با عمیق‌تر شدن در مثال جمع ماتریسی بیشتر مورد بررسی قرار دهیم. عملیات‌های ماتریسی، طبیعتا نیاز به یک طرح‌بندی که شامل **2D grid** و **2D block** است می‌باشد تا بتوان تردها را در کرنل مدیریت کرد. خواهید دید که حتما این رویکرد به بهترین پرفرمنس نخواهد رسید. بدین منظور ما قرار است که طرح‌بندی‌های زیر را برای جمع ماترسی و به منظور آشنایی با این موضوع در دستور کار قرار دهیم:

➤ 2D grid with 2D blocks
➤ 1D grid with 1D blocks
➤ 2D grid with 1D blocks

۱۴ اندیس‌گزاری ماتریس‌ها با بلاک‌ها و تردها

معمولا، یک ماتریس به صورت خطی در حافظه‌ی **global** ذخیره شده است. این ذخیره سازی با رویکرد **row-major** انجام می‌پذیرد. شکل پایین یک مثال کوچک را برای یک ماتریس [۸,۶] را نشان می‌دهد.

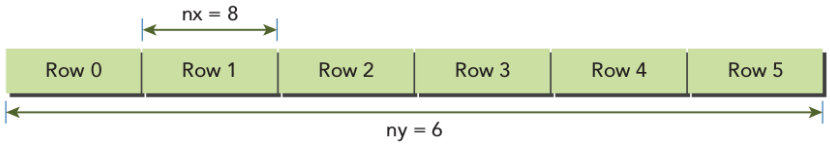

در کرنل جمع ماتریسی، یک ترد معمولا یک المان را برای پردازش برمیدارد. دسترسی به دیتای تعیین شده از حافظه‌ی **global** با استفاده کردن از اندیس **block** و **thread** اولین مشکلی هست که با آن روبه‌رو

هستیم و باید آن را حل کنیم. معمولا، سه نوع اندیس برای موردهای دو بعدی وجود دارد که شما نیاز دارید مدیریت کنید.

- اندیس ترد و بلاک
- موقعیت نقطه داده شده در ماتریس
- آفستی که در حافظه‌ی خطی **global** وجود دارد.

برای یک ترد داده شده، می‌توانید آفست مد نظر در حافظه‌ی **global** را با استفاده از اندیس **block** و **thread** به دست بیاورید، برای این منظور ابتدا اندیس ترد و بلاک را به موقعیت ماتریس نگاشت کنید، سپس این نگاشت‌ها را به موقعیت آن ماتریس در حافظه‌ی **global** ببرید.

پس در اولین گام، می‌توانید اندیس ترد و بلاک را به موقعیت ماتریس ببرید، این کار با فرمول‌های زیر قابل انجام است.

```
ix = threadIdx.x + blockIdx.x * blockDim.x
iy = threadIdx.y + blockIdx.y * blockDim.y
```

در گام دوم، می‌توانید موقعیتی که در ماتریس به دست آمده را به اندیس حافظه‌ی **global** با استفاده از فرمول زیر ببرید:

```
idx = iy * nx + ix
```

شکل زیر چنین رابطه‌ای که بین اندیس ترد و بلاک، موقعیت در ماتریس، و اندیس در حافظه‌ی **global** وجود دارد را نشان میدهد.

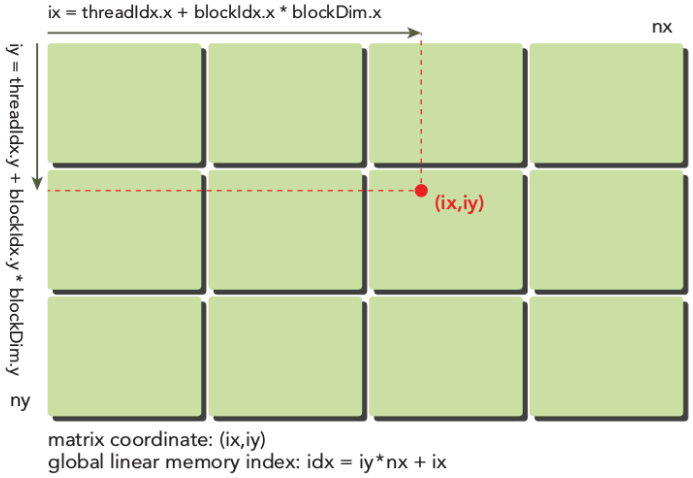

تابع **printThreadInfo** برای چاپ کردن اطلاعات زیر برای هر ترد استفاده می‌شود:

- اندیس ترد
- اندیس بلاک
- موقعیت ماتریس
- آفست حافظه‌ی خطی **global**
- مقدار المان در آن نقطه از حافظه

برنامه را کامپایل و اجرا می‌کنیم چیزی که در خروجی میگیریم به صورت زیر است:

```
thread_id (2,1) block_id (1,0) coordinate (6,1) global index 14 ival 14
```

شکل زیر رابطه‌ی بین این سه ترد را نشان میدهد.

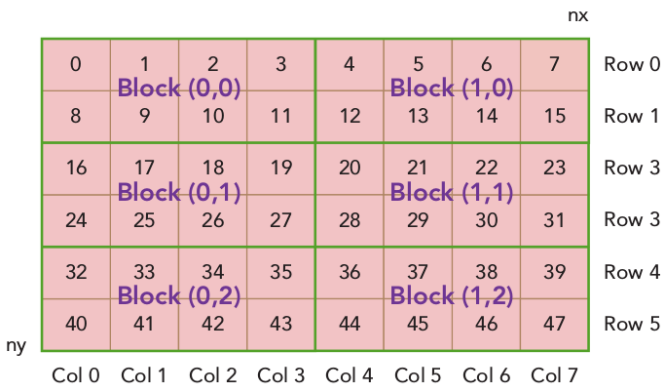

برنامه هم به صورت زیر می‌باشد:

```
#include <cuda_runtime.h>
#include <stdio.h>
#include <sys/time.h>
#define CHECK(call){gpu_error_checker((call),__FILE__,__LINE__);}
inline void gpu_error_checker(cudaError_t error,const char*file, int line)
{
    if (error != cudaSuccess)
    {
        printf("Error: %s:%d, ", __FILE__, __LINE__);
        printf("code:%d, reason: %s\n", error, cudaGetErrorString(error));
    }
}
void initialInt(int *ip, int size) {
```

```
    for (int i=0; i<size; i++) {
        ip[i] = i;
    }
}
void printMatrix(int *C, const int nx, const int ny) {
    int *ic = C;
    printf("\nMatrix: (%d.%d)\n",nx,ny);
    for (int iy=0; iy<ny; iy++) {
        for (int ix=0; ix<nx; ix++) {
            printf("%3d",ic[ix]);
        }
        ic += nx;
        printf("\n");
    }
    printf("\n");
}
__global__ void printThreadIndex(int *A, const int nx, const int ny)
{
    int ix = threadIdx.x + blockIdx.x * blockDim.x;
    int iy = threadIdx.y + blockIdx.y * blockDim.y;
    unsigned int idx = iy*nx + ix;
    printf("thread_id (%d,%d) block_id (%d,%d) coordinate (%d,%d) "
           "global index %2d ival %2d\n", threadIdx.x, threadIdx.y, blockIdx.x,
           blockIdx.y, ix, iy, idx, A[idx]);
}
int main(int argc, char **argv) {
    printf("%s Starting...\n", argv[0]);
    // get device information
    int dev = 0;
    cudaDeviceProp deviceProp;
    CHECK(cudaGetDeviceProperties(&deviceProp, dev));
    printf("Using Device %d: %s\n", dev, deviceProp.name);
    CHECK(cudaSetDevice(dev));
    // set matrix dimension
    int nx = 8;
    int ny = 6;
    int nxy = nx*ny;
    int nBytes = nxy * sizeof(float);
    // malloc host memory
```

```
    int *h_A;
    h_A = (int *)malloc(nBytes);
    // iniitialize host matrix with integer
    initialInt(h_A, nxy);
    printMatrix(h_A, nx, ny);
    // malloc device memory
    int *d_MatA;
    cudaMalloc((void **)&d_MatA, nBytes);
    // transfer data from host to device
    cudaMemcpy(d_MatA, h_A, nBytes, cudaMemcpyHostToDevice);
    // set up execution configuration
    dim3 block(4, 2);
    dim3 grid((nx+block.x-1)/block.x, (ny+block.y-1)/block.y);
    // invoke the kernel
    printThreadIndex <<< grid, block >>>(d_MatA, nx, ny);
    cudaDeviceSynchronize();
    // free host and devide memory
    cudaFree(d_MatA);
    free(h_A);
    // reset device
    cudaDeviceReset();
    return (0);
}
```

۱۵ جمع کردن ماتریس‌ها

در این بخش، شما یک کرنل برای جمع کردن ماتریسی خواهید نوشت که از یک گرید دو بعدی و بلاک‌های دو بعدی استفاده می‌کند. ابتدا یک تابع سمت **host** به عنوان تابع چک نتیجه می‌نویسیم که نتیجه‌ی نهایی جمع شده توسط کرنل را تایید کند.

```
void sumMatrixOnHost (float *A, float *B, float *C, const int nx, const int ny) {
    float *ia = A;
    float *ib = B;
    float *ic = C;
    for (int iy=0; iy<ny; iy++) {
        for (int ix=0; ix<nx; ix++) {
            ic[ix] = ia[ix] + ib[ix];
        }
        ia += nx; ib += nx; ic += nx;
```

```
    }
}
```

سپس، یک کرنل جدید برای جمع ماتریسی می‌سازیم که از **block** های دو بعدی استفاده می‌کند.

```
__global__ void sumMatrixOnGPU2D(float *MatA, float *MatB, float *MatC,
                                 int nx, int ny) {
    unsigned int ix = threadIdx.x + blockIdx.x * blockDim.x;
    unsigned int iy = threadIdx.y + blockIdx.y * blockDim.y;
    unsigned int idx = iy*nx + ix;
    if (ix < nx && iy < ny)
        MatC[idx] = MatA[idx] + MatB[idx];
}
```

کلید اصلی در این کرنل نحوه‌ی نگاشت هر ترد از اندیس ترد به اندیس حافظه‌ی خطی می‌باشد، که در شکل زیر نمایش داده شده است.

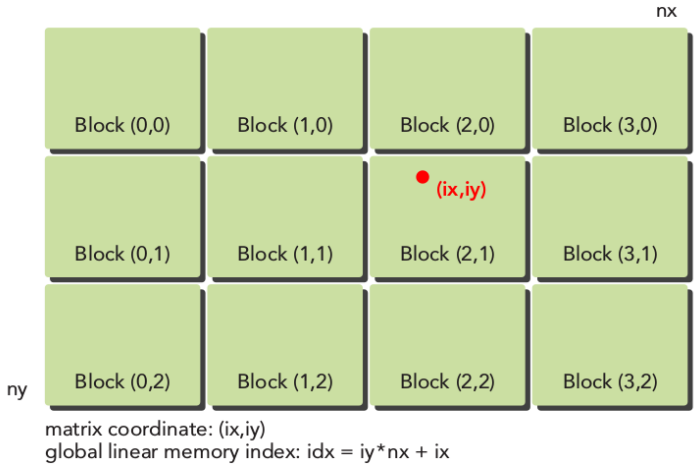

می‌توان ابعاد ماتریس را برابر با ۱۶۳۸۴ قرار داد که این کار به صورت زیر انجام می‌شود.

```
int nx = 1<<14;
int ny = 1<<14;
```

سپس، تنظیمات کرنل برای اجرا به صورت **grid** دو بعدی و **block** دو بعدی ست می‌شود.

```
int dimx = 32;
int dimy = 32;
dim3 block(dimx, dimy);
dim3 grid((nx + block.x - 1) / block.x, (ny + block.y - 1) / block.y);
```

حال همه‌ی این چیزهایی که گفتیم را در یک فایل کنار همدیگر جمع می‌کنیم.

```
#include <cuda_runtime.h>
```

```
#include <stdio.h>
#include <sys/time.h>
#include <math.h>
#define CHECK(call){gpu_error_checker((call),__FILE__,__LINE__);}
inline void gpu_error_checker(cudaError_t error,const char*file, int line)
{
    if (error != cudaSuccess)
    {
        printf("Error: %s:%d, ", __FILE__, __LINE__);
        printf("code:%d, reason: %s\n", error, cudaGetErrorString(error));
    }
}
double cpuSecond() {
    struct timeval tp;
    gettimeofday(&tp,NULL);
    return ((double)tp.tv_sec + (double)tp.tv_usec*1.e-6);
}
void initialData(float *ip,int size) {
    // generate different seed for random number
    time_t t;
    srand((unsigned) time(&t));
    for (int i=0; i<size; i++) {
        ip[i] = (float)( rand() & 0xFF )/10.0f;
    }
}
void checkResult(float *hostRef, float *gpuRef, const int N) {
    double epsilon = 1.0E-8;
    bool match = 1;
    for (int i=0; i<N; i++) {
        if (abs(hostRef[i] - gpuRef[i]) > epsilon) {
            match = 0;
            printf("Arrays do not match!\n");
            printf("host %5.2f gpu %5.2f at current %d\n",hostRef[i],gpuRef[i],i);
            break;
        }
    }
    if (match) printf("Arrays match.\n\n");
}
void printMatrix(int *C, const int nx, const int ny) {
```

```
    int *ic = C;
    printf("\nMatrix: (%d.%d)\n",nx,ny);
    for (int iy=0; iy<ny; iy++) {
        for (int ix=0; ix<nx; ix++) {
            printf("%3d",ic[ix]);
        }
        ic += nx;
        printf("\n");
    }
    printf("\n");
}
void sumMatrixOnHost (float *A, float *B, float *C, const int nx, const int ny) {
    float *ia = A;
    float *ib = B;
    float *ic = C;
    for (int iy=0; iy<ny; iy++) {
        for (int ix=0; ix<nx; ix++) {
            ic[ix] = ia[ix] + ib[ix];
        }
        ia += nx; ib += nx; ic += nx;
    }
}
__global__ void sumMatrixOnGPU2D(float *MatA, float *MatB, float *MatC,
                                 int nx, int ny) {
    unsigned int ix = threadIdx.x + blockIdx.x * blockDim.x;
    unsigned int iy = threadIdx.y + blockIdx.y * blockDim.y;
    unsigned int idx = iy*nx + ix;
    if (ix < nx && iy < ny)
        MatC[idx] = MatA[idx] + MatB[idx];
}
int main(int argc, char **argv) {
    printf("%s Starting...\n", argv[0]);
    // set up device
    int dev = 0;
    cudaDeviceProp deviceProp;
    CHECK(cudaGetDeviceProperties(&deviceProp, dev));
    printf("Using Device %d: %s\n", dev, deviceProp.name);
    CHECK(cudaSetDevice(dev));
    // set up date size of matrix
```

```
int nx = 1<<14;
int ny = 1<<14;
int nxy = nx*ny;
int nBytes = nxy * sizeof(float);
printf("Matrix size: nx %d ny %d\n",nx, ny);
// malloc host memory
float *h_A, *h_B, *hostRef, *gpuRef;
h_A = (float *)malloc(nBytes);
h_B = (float *)malloc(nBytes);
hostRef = (float *)malloc(nBytes);
gpuRef = (float *)malloc(nBytes);
// initialize data at host side
double iStart = cpuSecond();
initialData (h_A, nxy);
initialData (h_B, nxy);
double iElaps = cpuSecond() - iStart;
memset(hostRef, 0, nBytes);
memset(gpuRef, 0, nBytes);
// add matrix at host side for result checks
iStart = cpuSecond();
sumMatrixOnHost (h_A, h_B, hostRef, nx,ny);
iElaps = cpuSecond() - iStart;
// malloc device global memory
float *d_MatA, *d_MatB, *d_MatC;
cudaMalloc((void **)&d_MatA, nBytes);
cudaMalloc((void **)&d_MatB, nBytes);
cudaMalloc((void **)&d_MatC, nBytes);
// transfer data from host to device
CHECK(cudaMemcpy(d_MatA, h_A, nBytes, cudaMemcpyHostToDevice));
CHECK(cudaMemcpy(d_MatB, h_B, nBytes, cudaMemcpyHostToDevice));
// invoke kernel at host side
int dimx = 32;
int dimy = 32;
dim3 block(dimx, dimy);
dim3 grid((nx+block.x-1)/block.x, (ny+block.y-1)/block.y);
iStart = cpuSecond();
sumMatrixOnGPU2D <<< grid, block >>>(d_MatA, d_MatB, d_MatC, nx, ny);
cudaDeviceSynchronize();
iElaps = cpuSecond() - iStart;
```

```
    printf("sumMatrixOnGPU2D <<<(%d,%d), (%d,%d)>>> elapsed %f sec\n", grid.x,
          grid.y, block.x, block.y, iElaps);
    // copy kernel result back to host side
    cudaMemcpy(gpuRef, d_MatC, nBytes, cudaMemcpyDeviceToHost);
    // check device results
    checkResult(hostRef, gpuRef, nxy);
    // free device global memory
    cudaFree(d_MatA);
    cudaFree(d_MatB);
    cudaFree(d_MatC);
    // free host memory
    free(h_A);
    free(h_B);
    free(hostRef);
    free(gpuRef);
    // reset device
    cudaDeviceReset();
    return (0);
}
```

خروجی بر روی **gpu 1080** به صورت زیر می‌باشد.

```
Using Device 0: GeForce GTX 1080 Ti
Matrix size: nx 16384 ny 16384
sumMatrixOnGPU2D 0.313547
sumMatrixOnGPU2D <<<(512,512), (32,32)>>> elapsed 0.009157 sec
Arrays match.
```

در مرحله بعد ابعاد بلاک را به **32x16** تغییر داده و دوباره آن را کامپایل کنید.

۱۶ جمع کردن ماتریس‌ها با استفاده از 1D grid and 1D block

برای استفاده از **1D grid** با **block**های یک بعدی، نیاز دارید که کرنلی بنویسید که در آن هر ترد **ny** المان را پردازش کند، که در شکل زیر نمایش داده شده است.

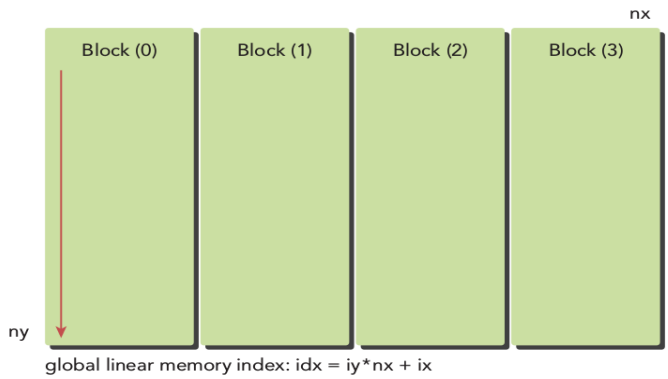

از آنجایی که هر ترد در کرنل جدید **ny** المان را پردازش می‌کند، نحوه‌ی نگاشت از اندیس ترد و بلاک به حافظه‌ی خطی متفاوت از قبل خواهد بود. چرا که یک بلاک **1D** برای کرنل مشخص می‌کنیم، و تنها **threadIdx.x** در اینجا مفید خواهد بود و یک حلقه در داخل کرنل به ازای هر ترد برای حرکت روی **ny** المان نیاز خواهیم داشت.

```
__global__ void sumMatrixOnGPU1D(float *MatA, float *MatB, float *MatC,
                                 int nx, int ny) {
    unsigned int ix = threadIdx.x + blockIdx.x * blockDim.x;
    if (ix < nx ) {
        for (int iy=0; iy<ny; iy++) {
            int idx = iy*nx + ix;
            MatC[idx] = MatA[idx] + MatB[idx];
        }
    }
}
```

در ادامه، یک گرید و بلاک یک بعدی را به صورت زیر تنظیم می‌کنیم.

```
dim3 block(32,1);
dim3 grid((nx+block.x-1)/block.x,1);
```

و کرنل را به صورت زیر فراخوانی می‌کنیم:

```
sumMatrixOnGPU1D <<< grid, block >>>(d_MatA, d_MatB, d_MatC, nx, ny);
```

کد را به صورت زیر کامپایل کرده و اجرا می‌کنیم:

```
$ nvcc -arch=sm_20 sumMatrixOnGPU-1D-grid-1D-block.cu -o matrix1D
$ ./matrix1D
```

نتیجه به صورت زیر می‌باشد:

```
Using Device 0: GeForce GTX 1080 Ti
Matrix size: nx 16384 ny 16384
sumMatrixOnCPU 0.314964
sumMatrixOnGPU1D <<<(512,1), (32,1)>>> elapsed 0.012409 sec
Arrays match.
```

همانطور که مشخص است استفاده از گرید و بلاک یک بعدی دارای پرفرمنس کمتری می‌باشد. در ادامه **block size** را تا ۱۲۸ افزایش میدهیم که خروجی زیر را به دست میآوریم.

```
sumMatrixOnGPU1D <<<(128,1), (128,1)>>> elapsed 0.011926 sec
```

که به مقدار کمی بهبود پیدا کرده.

۱۷ جمع ماتریس‌ها با استفاده از گرید 2D و بلاک 1D

وقتی که از یک گرید دو بعدی استفاده می‌کنیم که بلاک‌ها یک بعدی دارد، هر ترد مسوول تنها یک المان از داده می‌شود و بعد دوم از گرید برابر با **ny** می‌باشد که در تصویر زیر نشان داده شده است:

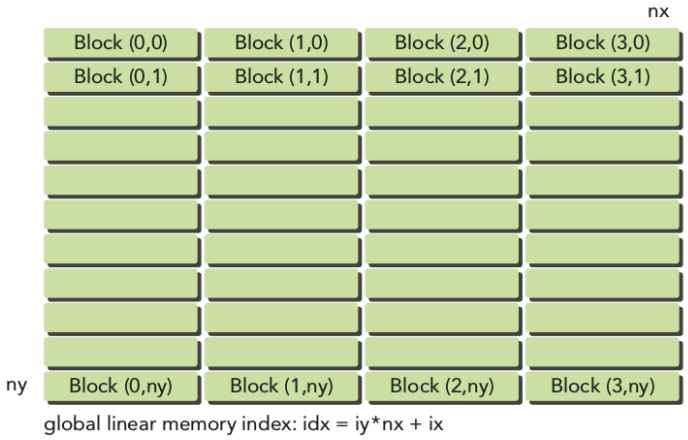

این حالت رو میشه به عنوان یک حالت خاص از گرید دو بعدی و بلاک دو بعدی دید، جایی که بعد دوم از بلاک ۱ می‌باشد. بنابراین، نگاشتی که از اندیس ترد و بلاک بر روی مختصات ماتریس صورت می‌پذیرد به صورت زیر می‌باشد.

```
ix = threadIdx.x + blockIdx.x * blockDim.x;
iy = blockIdx.y;
```

نگاشتی که از مختصات ماتریس به حافظه انجام میپذیرد نیز ثابت می‌ماند. در این صورت کرنل جدید به صورت زیر در خواهد آمد.

```
__global__ void sumMatrixOnGPUMix(float *MatA, float *MatB, float *MatC,
                                  int nx, int ny) {
    unsigned int ix = threadIdx.x + blockIdx.x * blockDim.x;
    unsigned int iy = blockIdx.y;
    unsigned int idx = iy*nx + ix;
    if (ix < nx && iy < ny)
        MatC[idx] = MatA[idx] + MatB[idx];
}
```

توجه داشته باشید که تابع **sumMatrixOnGPU2D** برای این حالت نیز می‌تواند جواب بدهد. ولی ما یک تابع جدید نوشتیم تا کرنل جدید یک ضرب صحیح و یک جمع صحیح به ازای هر ترد کمتر داشته باشد.

در این صورت ابعاد بلاک را برابر با ۳۲ قرار میدهیم و **grid size** را بر اساس آن محاسبه می‌کنیم:

```
dim3 block(32);
dim3 grid((nx + block.x - 1) / block.x,ny);
```

و کرنل را فراخوانی و اجرا می‌کنیم خروجی به صورت زیر خواهد بود:

```
Using Device 0: GeForce GTX 1080 Ti
Matrix size: nx 16384 ny 16384
sumMatrixOnCPU 0.314207
sumMatrixOnGPU1D <<<(512,16384), (32,1)>>> elapsed 0.010683 sec
Arrays match.
```

حال یکبار دیگر، **block size** را افزایش میدهیم.

```
dim3 block(256);
```

خروجی به صورت زیر خواهد بود.

```
Using Device 0: GeForce GTX 1080 Ti
Matrix size: nx 16384 ny 16384
sumMatrixOnCPU 0.315198
sumMatrixOnGPU1D <<<(64,16384), (256,1)>>> elapsed 0.027825 sec
Arrays match.
```

خب از این مثال جمع ماتریسی می‌توانیم چند نکته را می‌توان فهمید:

- تغییر دادن تنظیمات کرنل بر روی پرفرمنس تاثیر می‌گذارد.
- یک پیاده‌سازی مشابه حتما بهترین پرفرمنس را به ما نخواهد داد.

- برای یک کرنل خاص، امتحان کردن گرید و بلاک با ابعاد متفاوت ممکن است به پرفرمنس بهتری برسد.

در فصل سوم، در مورد این که چه مواردی باعث افزایش و یا کاهش پرفرمنس خواهد شد را از نگاه سخت افزاری خواهیم دید.

۱۸ مدیریت device

NVIDIA چندین ابزار برای اطلاعات گرفتن از **GPU** را فراهم کرده است. این مهم است که بدانیم چطور می‌توانیم چنین اطلاعاتی را بگیریم، چرا می‌توانیم از آن استفاده کنیم تا در لحظه‌ی اجرای کد تنظیمات کرنل را عوض کنیم.

در اینجا ما دو ابزار مقدماتی ولی قوی برای گرفتن اطلاعات را معرفی خواهیم کرد:

- توابع **CUDA runtime**
- **nvidia-smi** یا **NVIDIA Systems Management Interface**

۱۹ استفاده از runtime API برای اطلاعات گرفتن از GPU

توابع بسیاری در **CUDA runtime** وجود دارد که برای مدیریت **device** می‌تواند به ما کمک کند. می‌توانید از تابع زیر برای گرفتن همه ی اطلاعات در مورد یک **GPU** کمک بگیرید.

```
cudaError_t cudaGetDeviceProperties(cudaDeviceProp* prop, int device);
```

ویژگی‌های **GPU** در ساختار **cudaDeviceProp** برگردانده می‌شود، که محتویات آن را می‌توانید به صورت آنلاین در آدرس زیر نیز ببینید.

```
http://docs.nvidia.com/cuda/cuda-runtime-api/index.html#structcudaDeviceProp
```

کد زیر به منظور گرفتن این اطلاعات از **GPU** مورد استفاده قرار میگیرد.

```
#include <cuda_runtime.h>
#include <stdio.h>
int main(int argc, char **argv) {
    printf("%s Starting...\n", argv[0]);
    int deviceCount = 0;
    cudaError_t error_id = cudaGetDeviceCount(&deviceCount);
    if (error_id != cudaSuccess) {
        printf("cudaGetDeviceCount returned %d\n-> %s\n",
```

```
            (int)error_id, cudaGetErrorString(error_id));
    printf("Result = FAIL\n");
    exit(EXIT_FAILURE);
}
if (deviceCount == 0) {
    printf("There are no available device(s) that support CUDA\n");
} else {
    printf("Detected %d CUDA Capable device(s)\n", deviceCount);
}
int dev, driverVersion = 0, runtimeVersion = 0;
dev =0;
cudaSetDevice(dev);
cudaDeviceProp deviceProp;
cudaGetDeviceProperties(&deviceProp, dev);
printf("Device %d: \"%s\"\n", dev, deviceProp.name);
cudaDriverGetVersion(&driverVersion);
cudaRuntimeGetVersion(&runtimeVersion);
printf(" CUDA Driver Version / Runtime Version %d.%d / %d.%d\n",
       driverVersion/1000, (driverVersion%100)/10,
       runtimeVersion/1000, (runtimeVersion%100)/10);
printf(" CUDA Capability Major/Minor version number:%d.%d\n",
       deviceProp.major, deviceProp.minor);
printf(" Total amount of global memory:%.2f MBytes (%llu bytes)\n",
       (float)deviceProp.totalGlobalMem/(pow(1024.0,3)),
       (unsigned long long) deviceProp.totalGlobalMem);
printf(" GPU Clock rate:%.0f MHz (%0.2f GHz)\n",
       deviceProp.clockRate * 1e-3f, deviceProp.clockRate * 1e-6f);
printf(" Memory Clock rate:%.0f Mhz\n",
       deviceProp.memoryClockRate * 1e-3f);
printf(" Memory Bus Width:%d-bit\n",
       deviceProp.memoryBusWidth);
if (deviceProp.l2CacheSize) {
    printf(" L2 Cache Size:%d bytes\n",
            deviceProp.l2CacheSize);
}
printf(" Max Texture Dimension Size (x,y,z) 1D=(%d), 2D=(%d,%d), 3D=(%d,%d,%d)\n",
       deviceProp.maxTexture1D
       , deviceProp.maxTexture2D[0],
       deviceProp.maxTexture2D[1],
```

```
        deviceProp.maxTexture3D[0], deviceProp.maxTexture3D[1],
        deviceProp.maxTexture3D[2]);
    printf(" Max Layered Texture Size (dim) x layers 1D=(%d) x %d, 2D=(%d,%d) x %d\n",
        deviceProp.maxTexture1DLayered[0], deviceProp.maxTexture1DLayered[1],
        deviceProp.maxTexture2DLayered[0], deviceProp.maxTexture2DLayered[1],
        deviceProp.maxTexture2DLayered[2]);
    printf(" Total amount of constant memory:%lu bytes\n",
        deviceProp.totalConstMem);
    printf(" Total amount of shared memory per block:%lu bytes\n",
        deviceProp.sharedMemPerBlock);
    printf(" Total number of registers available per block:%d\n",
        deviceProp.regsPerBlock);
    printf(" Warp size:%d\n", deviceProp.warpSize);
    printf(" Maximum number of threads per multiprocessor:%d\n",
        deviceProp.maxThreadsPerMultiProcessor);
    printf(" Maximum number of threads per block:%d\n",
        deviceProp.maxThreadsPerBlock);
    printf(" Maximum sizes of each dimension of a block:%d x %d x %d\n",
        deviceProp.maxThreadsDim[0],
        deviceProp.maxThreadsDim[1],
        deviceProp.maxThreadsDim[2]);
    printf(" Maximum sizes of each dimension of a grid:%d x %d x %d\n",
        deviceProp.maxGridSize[0],
        deviceProp.maxGridSize[1],
        deviceProp.maxGridSize[2]);
    printf(" Maximum memory pitch:%lu bytes\n", deviceProp.
                                    memPitch);
    exit(EXIT_SUCCESS);
}
```

که خروجی زیر را به ما می‌دهد.

```
Detected 1 CUDA Capable device(s)
Device 0: "GeForce GTX 1080 Ti"
 CUDA Driver Version / Runtime Version 9.2 / 9.0
 CUDA Capability Major/Minor version number:6.1
 Total amount of global memory:10.92 MBytes (11720130560 bytes)
 GPU Clock rate:1683 MHz (1.68 GHz)
 Memory Clock rate:5505 Mhz
 Memory Bus Width:352-bit
```

```
L2 Cache Size:2883584 bytes
Max Texture Dimension Size (x,y,z) 1D=(131072), 2D=(131072,65536), 3D=(16384,16384,16384)
Max Layered Texture Size (dim) x layers 1D=(32768) x 2048, 2D=(32768,32768) x 2048
Total amount of constant memory:65536 bytes
Total amount of shared memory per block:49152 bytes
Total number of registers available per block:65536
Warp size:32
Maximum number of threads per multiprocessor:2048
Maximum number of threads per block:1024
Maximum sizes of each dimension of a block:1024 x 1024 x 64
Maximum sizes of each dimension of a grid:2147483647 x 65535 x 65535
Maximum memory pitch:2147483647 bytes
```

۲۰ مشخص کردن بهترین GPU

برخی از سیستم‌ها از چندین **GPU** پشتیبانی می‌کنند. در مواردی که **GPU** ها با هم متفاوت هستند، این مهم است که بهترین **GPU** را برای کرنلمان انتخاب کنیم. یک راه برای مشخص کردن **GPU** با بیشترین قدرت محاسباتی به دست آوردن تعداد **multiprocessor** هایی است که دارد. در این صورت می‌تونیم از کد زیر استفاده کنیم:

```
int numDevices = 0;
cudaGetDeviceCount(&numDevices);
if (numDevices > 1) {
    int maxMultiprocessors = 0, maxDevice = 0;
    for (int device=0; device<numDevices; device++) {
        cudaDeviceProp props;
        cudaGetDeviceProperties(&props, device);
        if (maxMultiprocessors < props.multiProcessorCount) {
            maxMultiprocessors = props.multiProcessorCount;
            maxDevice = device;
        }
    }
    cudaSetDevice(maxDevice);
}
```

۲۱ استفاده از nvidia-smi برای گرفتن اطلاعات GPU

استفاده از ابزار کامندی **nvidia-smi** به شما در مدیریت و مانیتور کردن **GPU** ها کمک می‌کند، و به شما اجازه میدهد که حالت **device** را گرفته و تصحیح کنید.

دستور **nvidia-smi** را می‌توانید در **command-line** اجرا کنید. به طور مثال، برای مشخص کردن این کــه چه تعداد **GPU** بر روی سیستم نصب است و **device ID** هر **GPU** چیست می‌توانید از دستور زیر استفاده کنید.

```
$ nvidia-smi -L
GPU 0: GeForce GTX 1080 Ti (UUID: GPU-45d39bef-479d-417d-cde8-d32ea906c283)
```

از دستور زیر می‌توانید استفاده کنید تا جزییات بیشتری در مورد **GPU 0** به شما بدهد:

```
$ nvidia-smi -q -i 1
```

همچنین می‌توانید این اطلاعات را محدود به گزینه‌های زیر کنید.

```
➤ MEMORY
➤ UTILIZATION
➤ ECC
➤ TEMPERATURE
➤ POWER
➤ CLOCK
➤ COMPUTE
➤ PIDS
➤ PERFORMANCE
➤ SUPPORTED_CLOCKS
➤ PAGE_RETIREMENT
➤ ACCOUNTING
```

به طور مثال، برای نمایش دادن اطلاعات **memory** ، از دستور زیر استفاده شود:

```
$ nvidia-smi -q -i 0 -d MEMORY

==============NVSMI LOG==============

Timestamp                           : Tue Apr 23 09:43:06 2019
Driver Version                      : 396.24

Attached GPUs                       : 1
```

```
GPU 00000000:01:00.0
    FB Memory Usage
        Total                   : 11178 MiB
        Used                    : 544 MiB
        Free                    : 10634 MiB
    BAR1 Memory Usage
        Total                   : 256 MiB
        Used                    : 6 MiB
        Free                    : 250 MiB
```

برای نمایش میزان کارکرد **device** از دستور زیر استفاده می‌کنیم:

```
$ nvidia-smi -q -i 0 -d UTILIZATION

==============NVSMI LOG==============

Timestamp                           : Tue Apr 23 09:45:26 2019
Driver Version                      : 396.24

Attached GPUs                       : 1
GPU 00000000:01:00.0
    Utilization
        Gpu                         : 3 %
        Memory                      : 0 %
        Encoder                     : 0 %
        Decoder                     : 0 %
    GPU Utilization Samples
        Duration                    : 18446744073709.21 sec
        Number of Samples           : 99
        Max                         : 58 %
        Min                         : 0 %
        Avg                         : 0 %
    Memory Utilization Samples
        Duration                    : 18446744073709.21 sec
        Number of Samples           : 99
        Max                         : 10 %
        Min                         : 0 %
        Avg                         : 0 %
    ENC Utilization Samples
        Duration                    : 18446744073709.21 sec
```

```
        Number of Samples          : 99
        Max                        : 0 %
        Min                        : 0 %
        Avg                        : 0 %
    DEC Utilization Samples
        Duration                   : 18446744073709.21 sec
        Number of Samples          : 99
        Max                        : 0 %
        Min                        : 0 %
        Avg                        : 0 %
```

۲۲ تنظیم کردن device در runtime

سیستم‌هایی که از چندین **GPU** پشتیبانی می‌کنند، متداول هستند. برای یک سیستم که **N** تا **GPU** دارد، **ID** هر **GPU** که توسط **nvidia-smi** گزارش می‌شود از **0** تا **N-1** می‌باشد. با استفاده از متغیر محیطی **CUDA_VISIBLE_DEVICES** می‌توان مشخص کردن که کدام **GPU** در **runtime** استفاده شود، بدون این که برنامه‌مان را عوض کنیم.

می‌توان متغیر محیطی **CUDA_VISIBLE_DEVICES=2** قرار داد. درایور **nvidia** سایر **gpu** ها را **mask** می‌کند تا تنها **device** شماره ۲ به عنوان **device 0** برای برنامه شما دیده شود. همچنین می‌توانید از این متغیر برای مشخص کردن چندین **GPU** استفاده کنید، به طور مثال اگر می‌خواهید از **GPU** های شماره ۲و۳ استفاده کنید، در این صورت باید **CUDA_VISIBLE_DEVICES=2,3** قرار بگیرد. سپس، در لحظه‌ی اجرا، درایور **nvidia** تنها از **ID** های ۲,۳ به عنوان ۰,۱ استفاده می‌کند.

فصل سوم: مدل اجرایی CUDA

با تمریناتی که در فصل قبلی انجام دادیم، یاد گرفتیم که چطور تردها را روی گریدها و بلاک‌ها مدیریت کنیم تا بهترین پرفرمنس ممکن را بگیریم. ما می‌توانیم با سعی و خطا، بهترین تنظیمات مدل اجرایی را پیدا کنیم، ولی این سوال پیش میآید که چرا برخی تنظیمات کرنل از تنظیمات دیگر بهتر کار می‌کنند. برای این منظور ابتدا بهتر است که توصیه‌هایی که برای بهبود سرعت کرنل وجود دارد را ببینیم. این فصل به این سوالات پاسخ داده و یک دید عمیق از کرنلی که اجرا می‌شود و همچنین نحوه‌ی آنالیز پرفرمنس را به شما یاد میدهیم، و این موارد از زاویه و دید سخت افزار خواهد بود.

۱ معرفی مدل اجرایی CUDA

به صورت کلی، مدل اجرایی یک دید از این که چطور دستورات بر روی یک معماری محاسباتی اجرا می‌شود را میدهد. مدل اجرایی **CUDA** یک دید **abstract** از معماری موازی **GPU** را میدهد، که به شما در فهمیدن منطق تردهای موازی کمک می‌کند. در فصل دوم، یاد گرفتیم که مدل برنامه‌نویسی **CUDA** دو مفهوم **abstract** را در اختیار ما قرار داده: یکی سلسله‌مراتب حافظه و دیگری سلسله‌مراتب ترد که این دو به ما اجازه‌ی کنترل زیادی روی محاسبات **GPU** را میدهند. متعاقبا، مدل اجرایی **CUDA** یک دید مناسب از نحوه نوشتن کد کارآمد هم در مورد توان مصرفی و هم دسترسی به حافظه را به دست میدهد.

در این فصل روی توان مصرفی دستورالعمل‌ها تمرکز خواهیم کرد و در مورد دسترسی مؤثر و کارآ به حافظه نیز در فصل ۴,۵ بحث خواهیم کرد.

۲ گذری بر معماری GPU

معماری **GPU** حول آرایه‌ی مقیاس‌پذیری از **streaming multiprocessor** ها ساخته شده که اصطلاحا **SM** نامیده می‌شود. موازی‌سازی سخت‌افزاری **GPU** با تکرار این معماری بلاکی امکان‌پذیر می‌شود. شکل زیر قسمت‌های کلیدی یک **SM** روی سری **Fermi** را نشان میدهد.

- CUDA Cores
- Shared Memory/L1 Cache
- Register File
- Load/Store Units
- Special Function Units
- Warp Scheduler

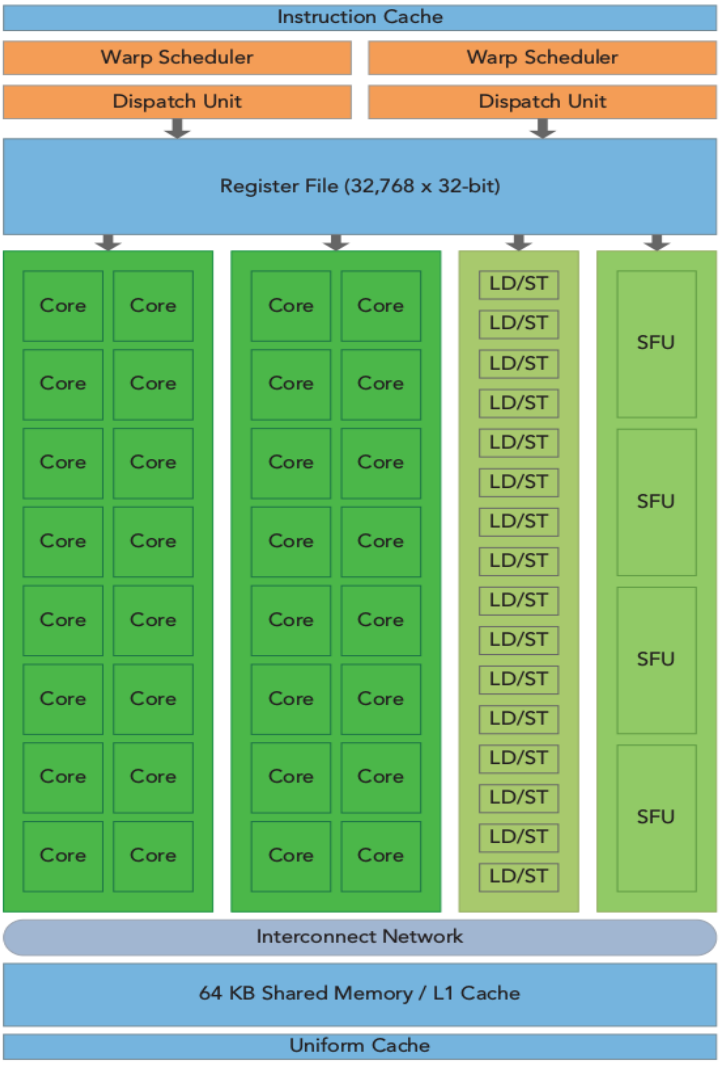

هر **SM** ای در **GPU** به این منظور طراحی شده که بتواند صدها ترد را بـه صـورت مـوازی اجـرا بکنـد، و عموما هر **GPU** از چندین **SM** برخوردار می‌باشـد. وقـتی کـه یـک **grid kernel** اجـرا می‌شـود، **thread block**ها از آن کرنل روی **SM** های موجود توزیع می‌شود تا اجرا شود. وقـتی کـه یـک **SM** بـرای کـاری برنامه‌ریزی شد، تردهای آن **block thread** به صورت همروند تنها بر روی آن **SM** اجرا می‌شـوند. ممکن است که چندین **thread block** بر روی یک **SM** انتساب داده شود، و این موضوع بستگی به میزان منابع **SM** موجود دارد. دستورات داخل یک ترد تنها **pipeline** شده تا در سطح دسـتورات موازی‌سـازی وجـود داشته باشد، علاوه این که ما در سطح ترد نیز موازی سازی داریم که شما با آن آشنا شده‌اید.

CUDA از معماری **یک دستورالعمل چند ترد** (**SIMT**) استفاده می‌کند تـا تردهـا را در گروه‌هـای ۳۲ تایی که رشته یا **warps** نامیده می‌شود، اجرا و مدیریت کنـد. همه‌ی تردهـا در داخـل یـک رشـته، یـک دستورالعمل یکسان را در لحظه اجرا می‌کنند. هر ترد دارای شمارنده آدرس دستور و حـالت رجیسـتری مخصوص به خود می‌باشد. هر **SM** منابع **thread block**ای که در اختیار دارد را به رشـته‌های ۳۲ تـردی تقسیم می‌کند، سپس برای اجرا روی منابع سخت‌افزاری موجود آن را زمان‌بندی می‌کند.

معماری **SIMT** مشـابه معمـاری **SIMD (Single Instruction,Multiple Data)** می‌باشـد. هـر دوی این معماری‌ها برای این که موازی‌سازی را پیاده‌سازی کنند، یک دستورالعمل را بر روی چندین واحد به طور

همزمان اجرا می‌کنند. تفاوت کلیدی در این است که همه‌ی اعضای بردار در یک گروه سنکرون شده با هم اجرا شوند، در حالی که **SIMT** اجازه میدهد که چندین ترد در یک رشته بتوانند مستقل از هم اجرا شوند. حتی با این وجود که همه‌ی تردهای یک رشته از **program address** یکسان شروع به کار می‌کنند، این امکان وجود دارد که برخی از تردها رفتار متفاوتی داشته باشند. **SIMT** سه ویژگی خاص دارد که **SIMD** آن‌ها را ندارد:

- هر ترد شمارنده آدرس دستورات خودش را دارد. (**instruction address counter**)
- هر ترد حالت رجیستر خودش را دارد. (**register state**)
- هر ترد می‌تواند یک مسیر اجرایی متفاوت داشته باشد.

۲ عدد جادویی : ۳۲

عدد ۳۲ در برنامه‌نویسی CUDA، عدد جادویی است. که از سخت‌افزار آمده است، و تاثیر خیلی زیادی روی کارآیی برنامه دارد. در واقع با بهینه‌کردن کارتان برای جا گرفتن در رشته‌ها(گروه‌های ۳۲ تردی) باعث افزایش پرفرمنس محاسبات GPU می‌شوید. در این مورد در فصل بعد بیشتر یاد خواهیم گرفت.

یک **thread block** تنها می‌تواند روی یک **SM** برنامه‌ریزی شود. به محض این که یک **thread block** بر روی یک **SM** برنامه‌ریزی شد، آن **thread block** روی آن **SM** باقی می‌ماند تا این که اجرا پایان یابد. یک **SM** می‌تواند بیشتر از یک **thread block** را در هر لحظه داشته باشد. شکل زیر کامپونت‌های نظیر را از دید سخت‌افزار و برنامه‌نویسی **CUDA** را بیان می‌کند.

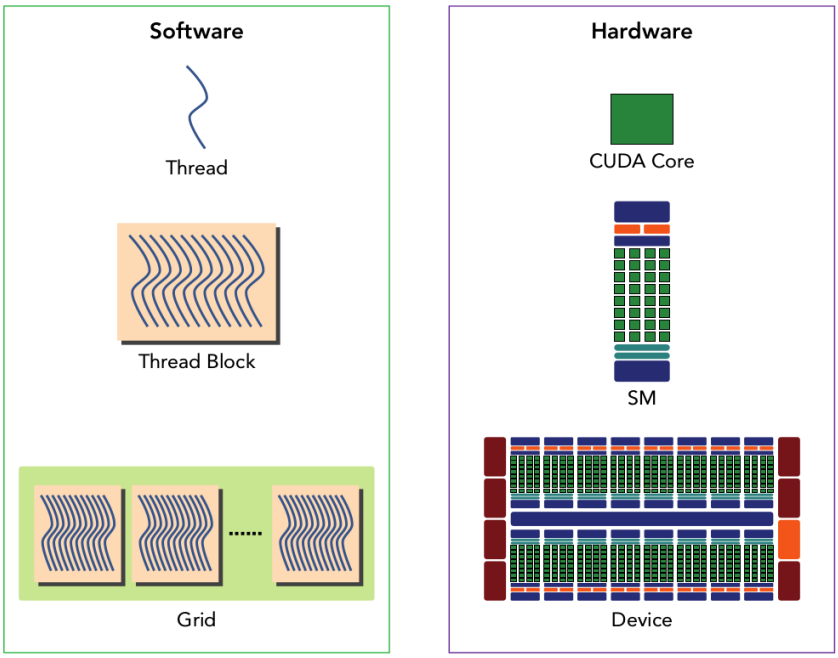

حافظه اشتراکی و رجیسترها منابع خیلی مهمی از یک **SM** به حساب می‌آیند. حافظه‌ی اشتراکی بین **thread block** های واقع در **SM** تقسیم شده و رجیسترها بین تردها تقسیم می‌شوند. تردها درون یک **thread block** می‌توانند با استفاده از حافظه‌ی اشتراکی و رجیسترها با همدیگر ارتباط داشته باشند و همکاری کنند. در حالی که همه‌ی تردها در **thread block** به صورت موازی با هم کار می‌کنند، همه‌ی تردها نمی‌توانند به صورت فیزیکی در یک زمان اجرا شوند. بنابراین، تردهای مختلف در یک **thread block** ممکن است که سرعت پیشرفت کارشان با هم متفاوت باشد.

این که داده‌ها را بین تردهای موازی به اشتراک بگذاریم ممکن است که باعث وقوع شرایط مسابقه یا **race condition** شود: **یعنی چندین ترد به یک دیتای یکسان دسترسی پیدا کنند، ولی ترتیب دسترسی آن‌ها حتی برای ما هم مشخص نباشد، که از لحاظ برنامه‌نویسی رفتار برنامه نامشخص خواهد بود**. **CUDA** ابزاری برای سنکرون کردن تردها درون یک **thread block** آماده کرده تا اطمینان حاصل شود که همه‌ی تردها به یک نقطه‌ی خاص رسیده‌اند و هیچ تردی نمی‌تواند قبل از آن ادامه‌ی برنامه‌ی خودش را اجرا کند مگر این که همه‌ی تردها به آن نقطه خاص رسیده باشند. اگر چه، ابزاری برای سنکرون کردن بین **block**ها وجود ندارد.

در حالی که رشته‌ها داخل یک **thread block** می‌توانند به هر ترتیبی اجرا شوند، تعداد رشته‌های فعال محدود به منابع **SM** می‌باشد. وقتی که یک رشته به هر دلیلی متوقف شده باشد(به طور مثال منتظر باشد که یک مقداری از حافظه‌ی **device** خوانده شود)، **SM** می‌تواند یک رشته دیگر را از هر **thread block** دیگری که در همان **SM** است را برنامه‌ریزی و اجرا کند. این به این شکل رشته‌ها را تعویض کنیم، هیچگونه **overhead**ای نخواهد داشت، چون منابع سخت‌افزاری بین همه‌ی تردها و بلاک‌های روی یک **SM** به اشتراک گذاشته شده است، بنابراین وضعیت رشته برنامه‌ریزی شده‌ی جدید نیز هم‌اکنون در داخل **SM** می‌باشد و ما برای **load** کردن آن بهایی پرداخت نخواهیم کرد.

۲ **SM** : قلب معماری **GPU**

SM یا streaming multiprocessor به عنوان قلب معماری GPU شناخته می‌شود. رجیسترها و حافظه‌ی اشتراکی به عنوان منابع محدود روی SM شناخته می‌شوند. CUDA این منابع را بین تردهای واقع در یک SM تقسیم می‌کند. بنابراین، این محدودیت منابع موجب محدود شدن تعداد رشته‌های فعال در یک SM می‌شود، که معادل مقدار موازی‌سازی موجود بر روی یک SM است. دانستن برخی حقیقت‌های ابتدایی در مورد کامپوننت‌های سخت‌افزاری به شما کمک می‌کند تا تردها و تنظیمات اجرای کرنل را برای بهترین بازدهی تنظیم کنید.

در بخش بعدی، یک مشاهده‌ی اجمالی بر روی دو ورژن مختلف **GPU** و معماری آن‌ها خواهیم داشت: معماری **Fermi** و **Kepler** . توجه اصلی بر روی منابع سخت‌افزاری این معماری‌ها خواهد بود. ما از

مثال‌ها و تمرین‌ها استفاده خواهیم کرد تا ویژگی‌های سخت افزاری این دو معماری را بیشتر یاد بگیرید، که به شما کمک خواهد کرد که دید بهتری برای افزایش پرفرمنس کرنل به دست بیاورید.

۳ معماری Fermi

معماری **Fermi** اولین معماری محاسباتی **GPU** بود که ویژگی‌های مورد نیاز برنامه‌های **HPC** را برآورده میکرد. **Fermi** به طور گسترده برای سرعت بخشیدن به محصولات انطباق داده شده بود.

شکل زیر یک دید بلاکی از معماری **Fermi** را ارایه میدهد که تمرکز آن بر روی محاسبات **GPU** بوده و جزییات نادیده گرفته شده است.

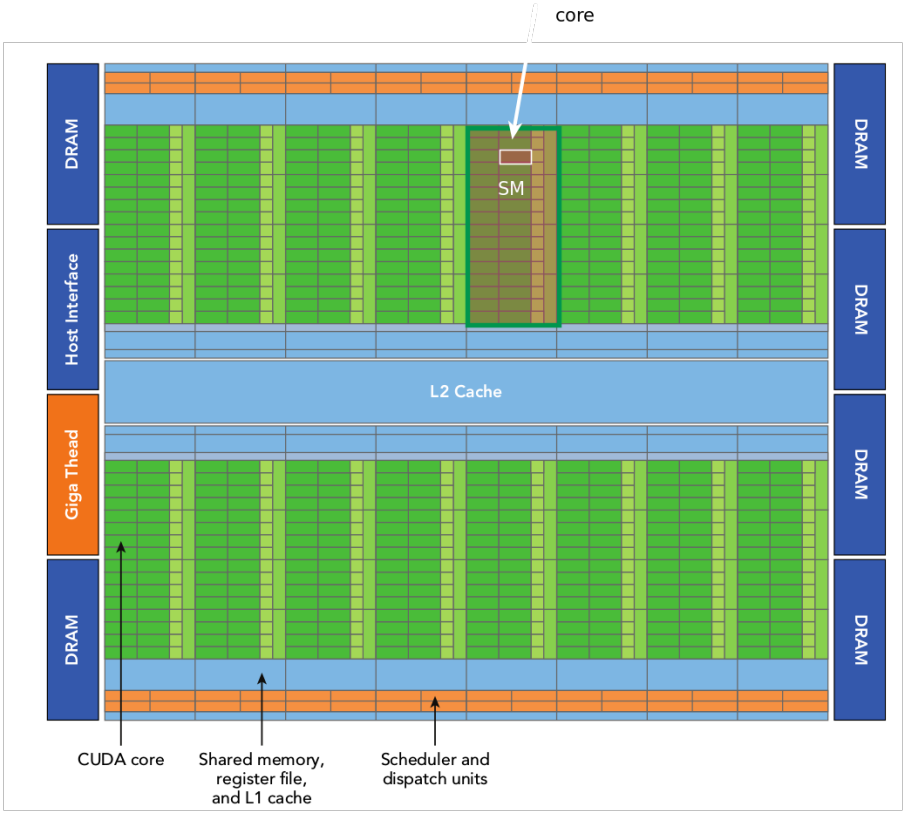

معماری **Fermi** دارای ۵۱۲ تا هسته بوده که **CUDA core** نامیده می‌شود. هر هسته‌ی **CUDA** دارای یک واحد محاسبات صحیح **ALU** و یک واحد محاسبات ممیز شناور **FPU** می‌باشد که کاملا به صورت **pipeline** شده هستند، و می‌توانند یک دستورالعمل صحیح و یا ممیز شناور را در یک سیکل اجرا کنند. هسته‌های **CUDA** روی۱۶ تا **SM** تقسیم شده، که سهم هر **SM** برابر با ۳۲ **CODA core** می‌باشد.

Fermi دارای شش حافظه‌ی **GDDR5 384bit** بوده که تا ۶ گیگابایت حافظه‌ی **global** را پشتیبانی می‌کند، که این حافظه یک منبع محاسباتی کلیدی در بسیاری از برنامه‌ها می‌باشد. رابط بین **host** و **device** با استفاده از گذرگاه **PCI-Express** انجام می‌شود. موتور **GigaThread** (که در شکل، در سمت

چپ و به رنگ نارنجی دیده می‌شود) مسوول توزیع **thread block**ها روی برنامه‌ریزی کننده‌های رشته‌ها در **SM** می‌باشد.

معماری **Fermi** یک کش **L2** با سایز **768KB** داشت، که بین همه‌ی این ۱۶ تا **SM** ها مشترک بود. هر **SM** که در شکل قبلی با نوارهای عمودی نمایش داده شده شامل:

- واحد اجرایی (هسته‌های **CUDA**)
- واحد برنامه‌ریزی و توزیع که مسوول برنامه‌ریزی رشته‌هاست.
- حافظه‌ی اشتراکی، فایل رجیستر، و کش **L1**

هر **multiprocessor** دارای ۱۶ تا واحد بارگزاری/ذخیره می‌باشد، که در هر سیکل به آدرس‌های مقصد و مبدا اجازه محاسبه با ۱۶ ترد را میدهد. واحد توابع خاص یا **SFU (Special Function Unit)** برای اجرای توابع خاص مثل **square root** ، **cosine** ، **sine** و درونیابی استفاده می‌شود. هر **SFU** می‌تواند یک دستورالعمل از موارد گفته شده را در یک سیکل و به ازای هر ترد اجرا کند.

هر **SM** دارای دو برنامه‌ریز رشته (**warp schedulers**)و دو واحد توزیع دستورالعمل می‌باشد. وقتی که یک **thread block** روی یک **SM** قرار داده می‌شود، همه‌ی تردهای واقع در **thread block** به رشته‌ها تقسیم می‌شود. دو برنامه‌ریز رشته، از رشته‌های موجود دو رشته را انتخاب کرده و یک دستورالعمل را از هر رشته گرفته و بر روی گروه ۱۶ تایی هسته، ۱۶ واحد ذخیره/بارگزاری و یا واحد محاسبات خاص که در شکل زیر نشان داده شده قرار میدهد. معماری **Fermi**، که دارای قدرت محاسباتی ۲ می‌باشد، می‌تواند به طور موازی ۴۸ رشته را به ازای هر **SM** بکار ببرد، که در کل ۱۵۳۶ ترد واقع در هر **SM** می‌شود.

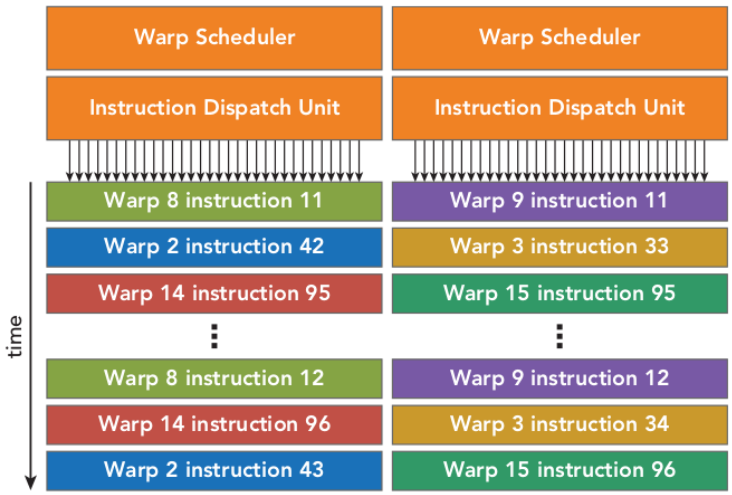

یک ویژگی کلیدی بر روی معماری **Fermi** حافظه‌ی **64KB** قابل تنظیم **on-chip** می‌باشد، که بین حافظه‌ی اشتراکی و **L1 cache** تقسیم می‌شود. برای بسیاری از برنامه‌های با **performance** بالا، حافظه‌ی

اشتراکی یک کلید برای دستیابی به پرفرمنس می‌باشد. حافظه‌ی اشتراکی بـه تردهـای درون یـک بلاک اجازه میدهد که با همدیگر همکاری داشته باشند، و استفاده مجدد از دیتای روی چیپ را تسهیل کـرده و منجر به کاهش ترافیک روی چیپ می‌شود. **CUDA** یـک **runtime API** دارد کـه بـرای تنظیم مـیزان حافظه‌ی اشتراکی و **L1 cache** مورد استفاده قرار میگیرد. تصحیح تنظیمات حافظه می‌توانـد منجـر بـه افزایش پرفرمنس شود، این افزایش پرفرمنس بر اساس میزان استفاده از حافظه‌ی اشتراکی و یـا کش در کرنل می‌باشد. این موضوع در فصل ۴و۵ به تفصیل مورد بررسی قرار خواهد گرفت.

Fermi همچنین از اجرای همزمان چندین کرنل نیز پشتیبانی می‌کند: چندین کرنل کـه از یـک برنامـه خاص اجرا شده و بر روی یک **GPU** در یـک زمـان اجـرا می‌شـوند. اجـرای همزمـان چنـدین کرنـل بـه برنامه‌نویس این اجازه را میدهد که چندین کرنل کوچک را بـه طـور همزمـان اجـرا کنـد و از **GPU** بـه بهترین نحو استفاده کند، که در شکل زیر نشان داده شده. **Fermi** اجازه‌ی اجـرای ۱۶ کرنـل همزمـان را میدهد. اجرای همزمان چندین کرنل باعث می‌شود که از دید برنامه‌نویس معماری **GPU** بیشتر شبیه بـه **MIMD** باشد.

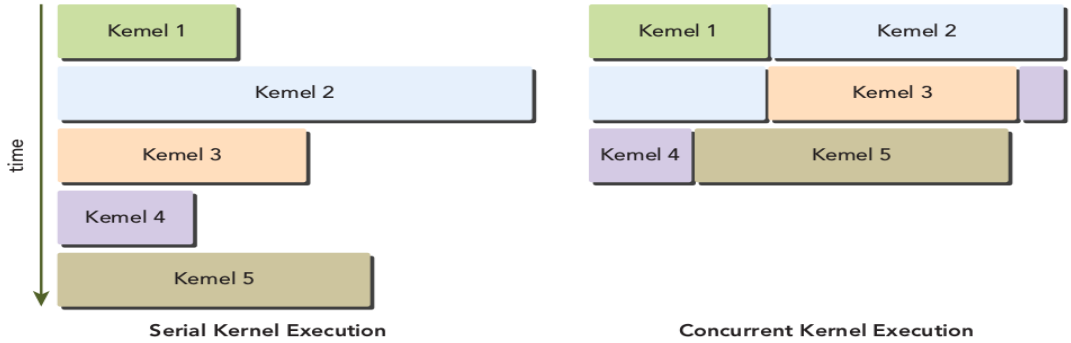

۴ معماری Kepler

معماری **Kepler**، در پاییز ۲۰۱۲ معرفی شد، که یک معماری سـریع، خیلی کارآمـد و مـوثر محاسـباتی است. ویژگی‌های **Kepler** به شما اجازه میدهد که به محاسبات هیبریدی بیش از پیش دسترسی داشـته باشید. شکل زیر بلاک دیاگرام چیپ **K20X** کپلر را نشان میدهد، که شـامل **۱۵** تـا **SM** و شـش کنـترل کننده‌ی حافظه‌ی **64bit** می‌باشد. سه نوآوری جدید در معماری **Kepler** شامل موارد زیر می‌شود:

- **SM**های توسعه داده شده
- موازی‌سازی داینامیک
- **Hyper-Q**

در قلب **Kepler K20X** یک واحد **SM** جدید وجود دارد که شامل چندین نوع‌آوری در معماری است که باعث بهبود قابلیت برنامه‌نویسی و توان مصرفی می‌شود. هر واحد **SM** در معماری **Kepler** متشکل از ۱۹۲ تا هسته‌ی محاسبات **single-precision** ، و ۶۴ تا واحد محاسبات **double-precision** و ۳۲ تا واحد محاسبات خاص، و ۳۲ تا واحد **load/store** یا **LD/ST** می‌باشد که در شکل زیر همه نشان داده شده.

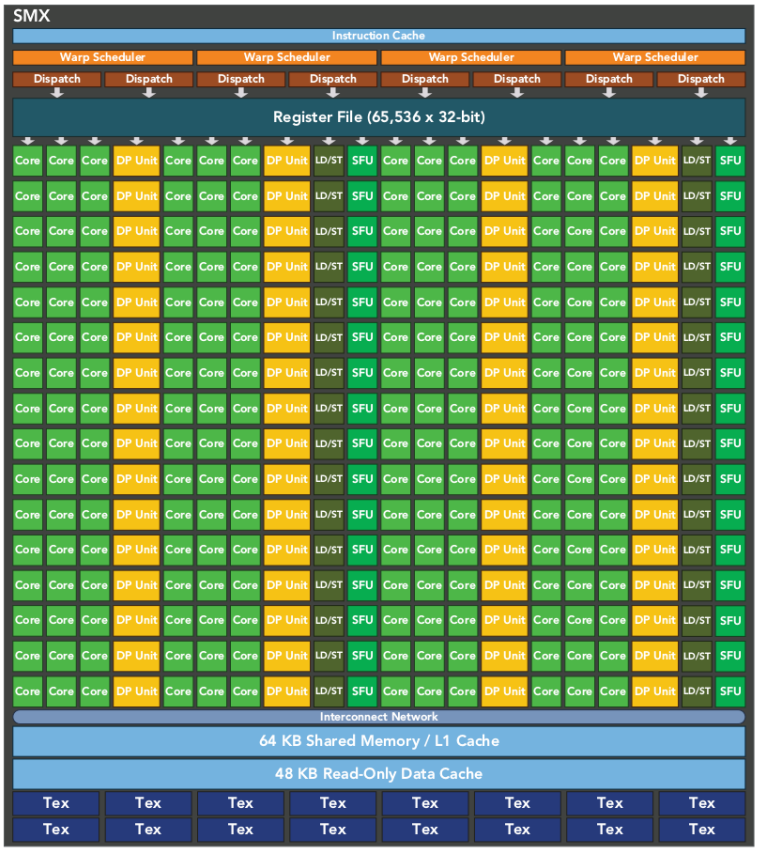

هر واحد **SM** در **Kepler** شامل چهار تا برنامه‌ریز رشته و هشت تا توزیع‌کننده‌ی دستور می‌باشد، که می‌تواند چهار تا رشته را به طور همزمان بر روی یک **SM** اجرا کند. معماری **Kepler K20X** (با قدرت محاسباتی ۳.۵) می‌تواند ۶۴ تا رشته را به ازای هر **SM** برای ۲۰۴۸ تا هسته‌ی واقع در یک **SM** در یک زمان برنامه‌ریزی کند.معماری **K20X** اندازه‌ی **register file** را به **64KB** افزایش داده، در معماری **Fermi** اندازه‌ی **register file** معماری **32KB** بود. همچنین **K20X** اجازه‌ی تقسیم بیشتری روی حافظه‌ی **on-chip** بین حافظه‌ی اشتراکی و **L1 cache** را میدهد. **K20X** همچنین دارای توان حداکثر محاسباتی **double-precision** به اندازه‌ی **1TFLOP** می‌باشد، و این کار را با ۸۰ درصد بهینه‌سازی در توان و سه برابر پرفرمنس نسبت به وات مصرفی نسبت به معماری **Fermi** انجام داده است.

موازی‌سازی داینامیک یک ویژگی جدید می‌باشد که در **GPU**های **Kepler** معرفی شده که به **GPU** اجازه‌ی اجرای گریدهای جدید را به صورت پویا می‌دهد. با این ویژگی، هر کرنلی می‌تواند کرنل دیگر را اجرا کرده و وابستگی‌های درون کرنلی را مدیریت کرده تا کارهای اضافه به طرز صحیحی انجام پذیرد. این ویژگی به شما اجازه‌ی ساختن و بهینه‌کردن الگوهای بازگشتی و وابسته به داده را میدهد.همچنانکه در شکل زیر نمایش داده شده، بدون این که موازی‌سازی پویا وجود داشته باشد، **host** باید هر کرنل را اجرا کند، ولی با موازی‌سازی پویا هر کرنل می‌تواند کرنل‌های دیگری را اجرا کند، و این که دیگر به **CPU** برای اجرای این کرنل‌ها نیاز نداریم. موازی‌سازی پویا قابلیت‌های **GPU** را در خیلی زمینه‌ها بالا میبرد. در این صورت می‌توانید کارهای موازی کوچک را به صورت پویا اجرا کنید که در گذشته این کار خیلی هزینه‌بر بود.

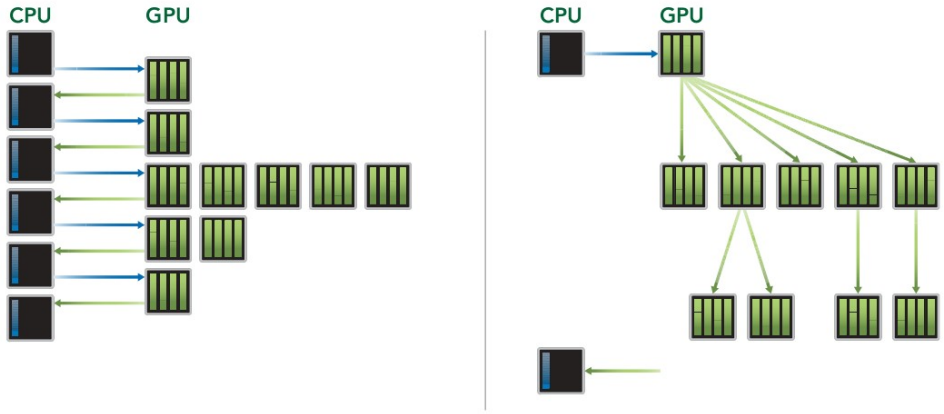

Hyper-Q سخت‌افزارهای ارتباطی بیشتری را بین **CPU** و **GPU** اضافه می‌کند، ک باعث می‌شود که هسته‌های **CPU** بتوانند وظایف بیشتری را به صورت موازی روی **GPU** داشته باشند. در نتیجه، شما می‌توانید از **GPU** بیشتر استفاده کنید، و حالت بدون کار **CPU** را به حداقل کاهش دهید. **Fermi** از یک سازکار سخت‌افزاری **single** برای صف وظایف بین **CPU** و **GPU** استفاده می‌کند، که باعث می‌شود که یک **task** تنها باعث متوقف شدن همه‌ی **task**های دیگر موجود در صف شود. ویژگی **Hyper-Q** در **Kepler** باعث حذف شدن این محدودیت شده است. همانطور که در شکل نشان داده شده است،

GPUهای **Kepler** دارای ۳۲ سخت افزار ارتباطی بین **host** و **GPU** هستند. **Hyper-Q** باعث افـزایش هـر چه بیشتر همروندی بر روی **GPU** شده، و باعث افزایش پرفرمنس کلی می‌شود.

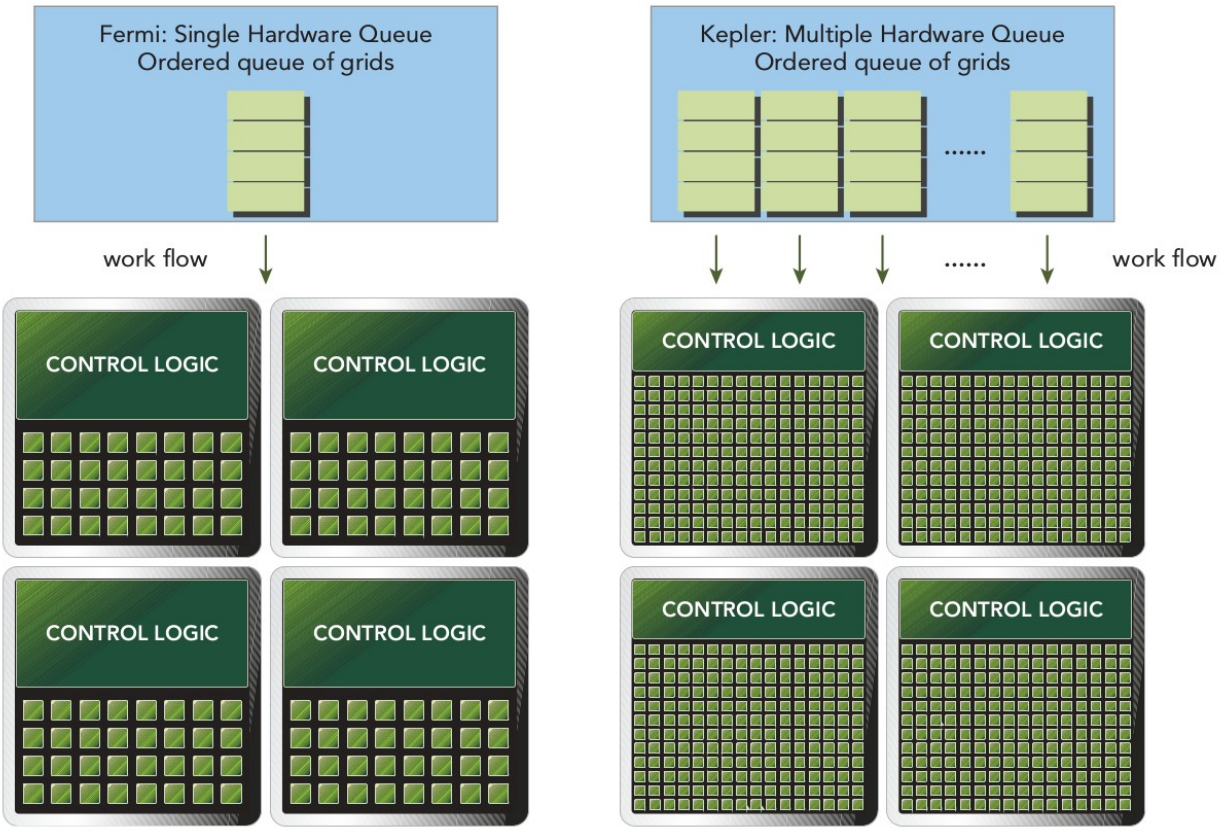

تفاوت‌های کلی بین **GPU**ها با قدرت‌های محاسباتی مختلف در جدول زیر آورده شده است:

ARCHITECTURE SPECIFICATIONS	COMPUTE CAPABILITY			
	2.0	2.1	3.0	3.5
Number of cores for integer and floating-point arithmetic function operations per multiprocessor	32	48	192	
Number of special function units for single-precision floating-point transcendental functions per multiprocessor	4	8	32	
Number of warp schedulers per multiprocessor	2		4	
Number of instructions issued at once by scheduler	1	2	2	
Number of load/store units per multiprocessor	16		32	

ARCHITECTURE SPECIFICATIONS	COMPUTE CAPABILITY			
	2.0	2.1	3.0	3.5
Load/Store address width	64 B		64 B	
L2 cache	768 K		1,536 K	
On-chip memory per multiprocessor	64 K		64 K	
Shared memory per multiprocessor (configurable)	48 K or 16 K		48 K/32 K/16 K	
L1 cache per multiprocessor (configurable)	16 K or 48 K		48 K/32 K/16 K	
Read-only data cache	N/A		48 K	
Global memory	Up to 6 GB		Up to 12 GB	

۵ بهینه‌سازی بر اساس profiling

profiling به منظور آنالیز برنامه و پرفرمنس می‌باشد که با اندازه‌گیری موارد زیر انجام میپذیرد:

- میزان فضای حافظه و یا پیچیدگی زمانی کد
- استفاده از یک سری دستورات خاص
- تناوب و میزان فراخوانی یک تابع

profiling یک گام حیاتی در توسعه‌ی برنامه، مخصوصا برای بهینه‌سازی کد **HPC** می‌باشد. **Profiling** معمولا نیازمند درک ابتدایی از مدل اجرایی پلتفرم می‌باشد. توسعه‌ی برنامه‌ی **HPC** معمولا درگیر دو گام کلی می‌باشد:

- توسعه‌ی کد به صورتی که درست کار کند.
- توسعه‌ی کد برای رسیدن به بهترین کارآیی.

استفاده از روش‌های **profiling** برای گام دوم یک روش رایج می‌باشد. روش‌های مبتنی بر **profiling** در برنامه‌نویسی **CUDA** از چند لحاظ اهمیت دارد:

- یک پیاده‌سازی کرنل مشابه ساختاری که داده دارد، معمولا منجر به بهترین پرفرمنس نخواهد شد. ابزار **profiling** می‌تواند در پیدا کردن نواحی حساس در کد که گلوگاه پرفرمنس هست کمک کند.

- **CUDA** منابع محاسباتی موجود روی یک **SM** را بر روی چندین **thread block** تقسیم می‌کند. تقسیم کردن این منابع ممکن است باعث محدود شدن پرفرمنس شود. ابزار **profiling** می‌تواند به شما کمک کند که بدانید منابع محاسباتی چطور استفاده شده‌اند.
- **CUDA** یک **abstraction** از معماری سخت‌افزاری را در اختیار شما قرار میدهد تا بتوانید همروندی تردها را مدیریت کنید. **Profiling** می‌تواند در اندازه‌گیری، مصورکردن و هدایت کردن بهینه‌سازی کمک کند.

ابزار **profiling** می‌تواند یک دید عمیق در مورد پرفرمنس کرنل به شما بدهد، و به شما کمک کند تا گلوگاه‌های کرنل را به دست بیاورید. **CUDA** دارای دو ابزار ابتدایی برای **profiling** می‌باشد: یکی **nvvp** ، یک ابزار مصور برای **profiling** و دیگری **nvprof**، یک ابزار کامندی.

nvvp یک ابزار مصور برای **profiling** بوده، که به شما کمک می‌کند تا به صورت بصری برنامه‌تان را مشاهده و بهینه کنید. این ابزار یک مسیر زمانی از فعالیت‌هایی که برنامه هم روی **CPU** و هم روی **GPU** داشته را نشان میدهد، و به شما کمک می‌کند تا موقعیت‌های مورد نظر برای افزایش کارآیی برنامه را پیدا کنید. به علاوه، **nvvp** برنامه شما را برای پیدا کردن گلوگاه‌های احتمالی نیز آنالیز می‌کند و پیشنهاداتی به منظور کاهش و یا حذف این گلوگاه را میدهد. این ابزار هم به صورت **standalone** و هم به عنوان بخشی از **Nsight Eclipse Edition (nsight)** وجود دارد.

Nvprof داده‌های **profiling** را جمع‌آوری کرده و به صورت کامندی نمایش میدهد. **Nvprof** همزمان با **CUDA 5** معرفی شد و تکامل یافته‌ی یک ابزار کامندی دیگر می‌باشد. همانند **nvvp**، این ابزار نیز فعالیت‌هایی که **CPU** و **GPU** انجام داده‌اند را جمع‌اوری کرده و نمایش میدهد، که شامل اجرای کرنل، کپی‌های حافظه و فراخوانی از **CUDA API** می‌باشد.

۶ درک طبیعت اجرای رشته

وقتی که یک کرنل اجرا می‌شود، از دید نرم‌افزاری چه چیزی می‌بینید؟ شما فکر می‌کنید که همه‌ی تردها در درون کرنل به صورت موازی اجرا می‌شود. از دید منطقی این چیزی که دیده می‌شود درست است، ولی از دید سخت‌افزاری همه‌ی تردها امکان اجرای همزمان را ندارند. در این فصل این مفهوم را که تردها در گروه‌های ۳۲ تایی تشکیل و به عنوان یک واحد اجرایی تنها دیده می‌شوند را پوشش داده‌ایم: که آن را رشته می‌نامیم. در اینجا یک دید عمیق‌تر به نحوه‌ی اجرای رشته از لحاظ سخت‌افزاری می‌اندازیم، و به درکی میرسیم که به ما در طراحی کرنل کمک می‌کند.

۷ رشته‌ها و thread block ها

رشته‌ها به عنوان ابتدایی‌ترین واحد اجرایی در یک **SM** هستند. وقتی که ما یک **grid** از **thread block** ها را اجرا می‌کنیم، **thread block** های درون گرید بر روی **SM** ها تقسیم می‌شوند. وقتی که یک **thread block** بر روی یک **SM** برنامه‌ریزی شد، تردهای درون آن **thread block** به رشته‌ها شکسته می‌شوند. یک رشته از ۳۲ تا ترد متوالی تشکیل شده است و همه‌ی تردها در درون یک رشته به صورت **SIMT** اجرا می‌شوند (**Single Instruction Multiple Thread**) . خب این دقیقا چیزی است که اتفاق می‌افتد، همه‌ی تردهای درون رشته یک دستورالعمل یکسان را اجرا می‌کنند، و هر کدام از این تردها عملیات را بر روی دیتای خصوصی خود انجام می‌دهد. شکل زیر رابطه‌ی بین دید منطقی و دید سخت‌افزاری از **thread block** را نشان می‌دهد.

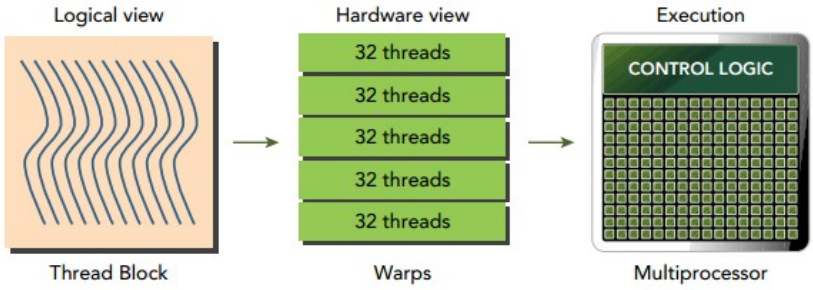

Thread block ها می‌توانند یک، دو و یا سه بعدی تنظیم شوند. اگر چه، از لحاظ سخت‌افزاری، همه‌ی تردها یک بعدی تنظیم شده‌اند. هر ترد دارای یک **unique ID** در بلاک می‌باشد. برای یک **thread block** یک بعدی، این شناسه درون یک متغیر داخلی به نام **threadIdx.x** ذخیره شده است، و تردها با مقادیر متوالی (کنار هم) درون رشته‌ها قرار میگیرند. به طور مثال، یک **thread block** یک بعدی با ۱۲۸ ترد می‌تواند به چهار تا رشته به صورت زیر تقسیم شود:

```
Warp 0: thread 0, thread 1, thread 2, ... thread 31
Warp 1: thread 32, thread 33, thread 34, ... thread 63
```

```
Warp 3: thread 64, thread 65, thread 66, ... thread 95
Warp 4: thread 96, thread 97, thread 98, ... thread 127
```

طرح دوبعدی و یا سه بعدی از **thread block** ها را که به صورت نرم‌افزاری تعیین گردیده است که را می‌شود به فرم یک بعدی (فیزیکی) تبدیل کرد، بعد **x** به عنوان داخلی‌ترین بعد، بعد **y** به عنوان بعد دوم و **z** به عنوان خارجی‌ترین بعد شناخته می‌شود. به طور مثال، برای یک **thread block** دو بعدی، شناسه‌ی یکتای هر ترد را می‌توان با استفاده از متغیرهای **threadIdx** و **blockDim** مشخص کرد:

```
threadIdx.y * blockDim.x + threadIdx.x
```

همین محاسبه برای یک **thread block** سه بعدی به صورت زیر می‌باشد:

```
threadIdx.z * blockDim.y * blockDim.x + threadIdx.y * blockDim.x + threadIdx.x
```

تعداد رشته‌ها برای هر **thread block** را می‌توان از طریق رابطه‌ی زیر محاسبه کرد:

```
WarpsPerBlock=ceil(threadsPerBlock  /  warpSize)
```

بنابراین، سخت افزار همیشه یک تعداد گسسته از تعداد رشته‌ها را برای یک **thread block** در نظر میگیرد. یک رشته هرگز بین **thread block** های دیگر تقسیم نمی‌شود. اگر اندازه‌ی **thread block** برابر با مضربی از اندازه‌ی رشته نباشید، برخی از تردها در آخرین رشته، غیر فعال خواهند بود. تصویر زیر یک **thread block** دو بعدی را نشان میدهد که ۴۰ ترد در راستای **x** داشته و دو ترد در راستای **y** دارد. از دید برنامه، ۸۰ ترد وجود دارد که در یک گرید دو بعدی قرار گرفته.

سخت افزار برای این **thread block** سه رشته را اختصاص می‌دهد، که در نتیجه ۹۶ ترد سخت‌افزاری داریم که به منظور پوشش دادن ۸۰ ترد نرم‌افزاری ایجاد شده‌اند. دقت کنید که از رشته‌ی آخر نصف تردها غیر فعال هستند. با وجود این که این تردها غیر فعال هستند، باز هم در حال مصرف منابع **SM** هستند که شامل رجیسترهای **SM** نیز می‌شود.

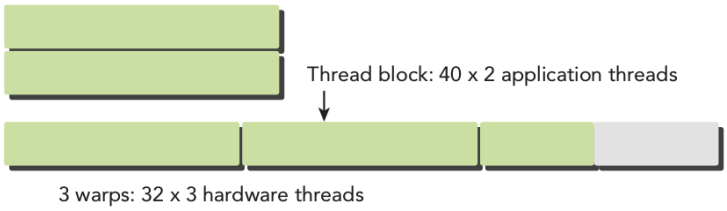

از دید منطقی، یک thread block مجموعه‌ای از تردهاست که در طرح‌های 1D 2D 3D قرار گرفته است. از دید سخت‌افزاری، یک thread block یک مجموعه‌ی 1D بعدی از رشته‌هاست. تردها در thread block در یک طرح‌بندی 1D قرار گرفته‌اند، و هر مجموعه‌ی ۳۲ تردی متوالی تشکیل یک رشته را میدهند.

۸ انشعاب رشته

کنترل جریان محاسبات یکی از ابتدایی‌ترین ساختارها در هر زبان برنامه‌نویسی سطح بالا به شمار میآید. **GPU** ها از ساختارهای سنتی کنترل جریان محاسبات پشتیبانی می‌کنند، ساختارهایی مثل **if then else,** **for** و **while**.

CPU ها شامل یک سخت‌افزار پیچیده برای پیش‌بینی انشعاب در جریان کد هستند، که به منظور پیش‌بینی این که برنامه چه انشعابی را دنبال خواهد کرد، استفاده می‌شوند. اگر تشخیص درست باشد، ایجاد انشعاب متحمل ضرر کمی در پرفرمنس خواهد شد. و اگر این تشخیص اشتباه باشد، **CPU** مجبور است که به مدت چند سیکل منتظر بماند تا دستوراتی که در انشعاب است لود شود. این خیلی ضروری است که به طور کامل بفهمید چرا **CPU** در کار کردن با ساختارهای پیچیده خوب است.

در مقابل، **GPU** ها سخت‌افزارهای ساده‌ای هستند که مکانیزم تشخیص انشعاب را ندارند. چرا که همه‌ی تردها در یک رشته می‌بایست دقیقا یک دستورالعمل یکسان را در سیکل یکسان انجام دهند، اگر یک ترد یک دستورالعمل را انجام دهد، همه‌ی تردها در آن رشته باید دقیقا آن دستورالعمل را اجرا کنند. این خصوصیت ممکن است در مسایلی که تردهای درون یک رشته، مسیرهای متفاوتی را انتخاب می‌کنند مشکل ساز شود. به طور مثال، عبارت زیر را در نظر بگیرید:

```
if (cond) {
...
} else {
...
}
```

فرض کنید که برای۱۶ تردی که در یک رشته هستند، **cond** درست باشد، و برای ۱۶ ترد باقی‌مانده در رشته **cond** نادرست باشد. در این صورت نصف رشته باید عباراتی را اجرا کنند که **cond** درست است و نصف دیگر باید قسمت **else** را اجرا کنند. این که تردهای یک رشته، دستورات متفاوتی را اجرا کنند اصطلاحا انشعاب رشته و یا **warp divergence** نامیده می‌شود. انشعاب رشته موجب ایجاد یک تناقض می‌شود، و آن هم این است که مگر قرار نبود که همه‌ی تردهای درون یک رشته باید یک دستورالعمل یکسان را در هر سیکل انجام دهند؟

اگر تردهای یک رشته دچار انشعاب شوند، در این صورت رشته به صورت سریال هر شاخه را اجرا کرده، و تردهایی که آن مسیر را انتخاب نکرده‌اند را لغو می‌کند. انشعاب رشته می‌تواند منجر به کاهش پرفرمنس شود. در مثال قبلی، مقدار موازی‌سازی به نصف کاهش پیدا خواهد کرد: تنها ۱۶ ترد در آن واحد می‌توانند فعال باشند و ۱۶ ترد دیگر در آن لحظه لغو شده است. با بیشتر شدن این **if else** ها، ممکن است مقدار موازی‌سازی به میزان زیادی کاهش پیدا کند.

توجه داشته باشد که انشعاب تنها درون یک رشته اتفاق می‌افتد. مقادیر شرطی متفاوت در رشته‌های مختلف بر روی همدیگر تاثیری ندارند.

شکل زیر انشعاب رشته‌ها را به طور مصور نشان می‌دهد. همه‌ی تردهای درون رشته باید هر دو انشعاب **if ...then** را بپذیرند. اگر شرط برای یک ترد **true** باشد، در این صورت ترد عبارت **if** را اجرا می‌کند، در غیر این صورت، ترد منتظر می‌ماند تا اجرای تردهای عبارت **if** پایان پذیرد.

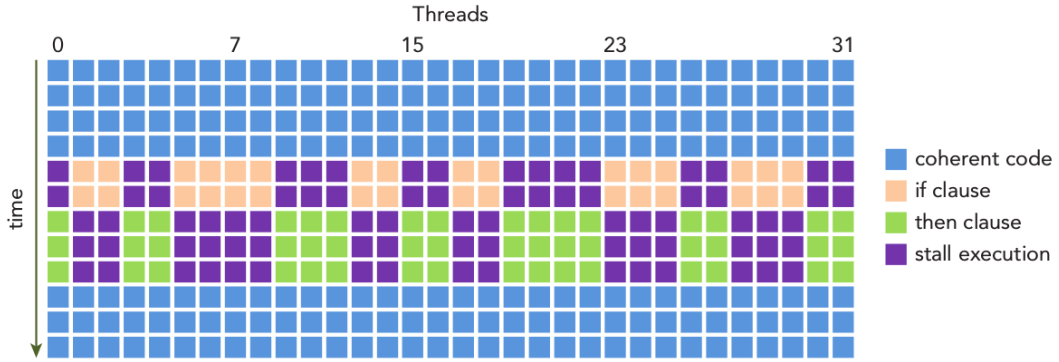

برای دستیابی به بهترین پرفرمنس، باید از وقوع مسیرهای متفاوت در یک رشته جلوگیری کنید. توجه داشته باشید که انتساب رشته‌های درون یک **thread block** مشخص است. در نتیجه، ممکن است راهی وجود داشته باشد که بتوانیم داده را به گونه‌ای تقسیم کنیم که همه‌ی تردهای درون یک رشته، مسیر محاسباتی یکسانی داشته باشند.

به طور مثال، فرض کنید که کد ما دارای دو شاخه باشد، که در کرنل زیر نمایش داده شده است. شما می‌توانید یک تقسیم بندی ضعیف از داده‌ها را ببینید که بین تردهای زوج و فرد تقسیم شده است، که باعث انشعاب رشته می‌شود. شرط **tid%2==0** باعث می‌شود که تردهای زوج عبارت **if** را اجرا کنند و تردهای فرد عبارت **else** را اجرا کنند.

```
__global__ void mathKernel1(float *c) {
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float a, b;
    a = b = 0.0f;
    if (tid % 2 == 0) {
        a = 100.0f;
```

```
    } else {
        b = 200.0f;
    }
    c[tid] = a + b;
}
```

اگر به جای استفاده از رویکرد ترد از رویکرد رشته استفاده کنیم، می‌توانیم از انشعاب رشته جلوگیری کرده و از ۱۰۰ درصد توان **device** استفاده کنیم. شرط **(tid/warpSize%2==0** باعث می‌شود که رشته‌های فرد عبارت **if** را اجرا کنند و رشته‌های فرد عبارت **else** را اجرا کنند. خروجی کرنل همانند خروجی قبلی است.

```
__global__ void mathKernel2(void) {
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float a, b;
    a = b = 0.0f;
    if ((tid / warpSize) % 2 == 0) {
        a = 100.0f;
    } else {
        b = 200.0f;
    }
    c[tid] = a + b;
}
```

حال می‌توانید پرفرمنس این دو کد را اندازه بگیرید. از آنجایی که اولین اجرا ممکن است که **overhead** داشته باشد، در این صورت یک کرنل اضافه نیز لانچ می‌شود تا این **overhead** را حذف کند:

```
//#include "../common/common.h"
#include <cuda_runtime.h>
#include <stdio.h>
#include <sys/time.h>
#define CHECK(call){gpu_error_checker((call),__FILE__,__LINE__);}
inline void gpu_error_checker(cudaError_t error,const char*file, int line)
{
    if (error != cudaSuccess)
    {
        printf("Error: %s:%d, ", __FILE__, __LINE__);
        printf("code:%d, reason: %s\n", error, cudaGetErrorString(error));
    }
}
double seconds() {
```

```
    struct timeval tp;
    gettimeofday(&tp,NULL);
    return ((double)tp.tv_sec + (double)tp.tv_usec*1.e-6);
}
__global__ void mathKernel1(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
    if (tid % 2 == 0)
    {
        ia = 100.0f;
    }
    else
    {
        ib = 200.0f;
    }
    c[tid] = ia + ib;
}
__global__ void mathKernel2(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
    if ((tid / warpSize) % 2 == 0)
    {
        ia = 100.0f;
    }
    else
    {
        ib = 200.0f;
    }
    c[tid] = ia + ib;
}
__global__ void mathKernel3(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
```

```
    bool ipred = (tid % 2 == 0);
    if (ipred)
    {
        ia = 100.0f;
    }
    if (!ipred)
    {
        ib = 200.0f;
    }
    c[tid] = ia + ib;
}
__global__ void mathKernel4(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
    int itid = tid >> 5;
    if (itid & 0x01 == 0)
    {
        ia = 100.0f;
    }
    else
    {
        ib = 200.0f;
    }
    c[tid] = ia + ib;
}
__global__ void warmingup(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
    if ((tid / warpSize) % 2 == 0)
    {
        ia = 100.0f;
    }
    else
    {
        ib = 200.0f;
```

```
    }
    c[tid] = ia + ib;
}
int main(int argc, char **argv)
{
    // set up device
    int dev = 0;
    cudaDeviceProp deviceProp;
    CHECK(cudaGetDeviceProperties(&deviceProp, dev));
    printf("%s using Device %d: %s\n", argv[0], dev, deviceProp.name);
    // set up data size
    int size = 64;
    int blocksize = 64;
    if(argc > 1) blocksize = atoi(argv[1]);
    if(argc > 2) size      = atoi(argv[2]);
    printf("Data size %d ", size);
    // set up execution configuration
    dim3 block (blocksize, 1);
    dim3 grid  ((size + block.x - 1) / block.x, 1);
    printf("Execution Configure (block %d grid %d)\n", block.x, grid.x);
    // allocate gpu memory
    float *d_C;
    size_t nBytes = size * sizeof(float);
    CHECK(cudaMalloc((float**)&d_C, nBytes));
    // run a warmup kernel to remove overhead
    size_t iStart, iElaps;
    CHECK(cudaDeviceSynchronize());
    iStart = seconds();
    warmingup<<<grid, block>>>(d_C);
    CHECK(cudaDeviceSynchronize());
    iElaps = seconds() - iStart;
    printf("warmup      <<< %4d %4d >>> elapsed %d sec \n", grid.x, block.x,
          iElaps );
    CHECK(cudaGetLastError());
    // run kernel 1
    iStart = seconds();
    mathKernel1<<<grid, block>>>(d_C);
    CHECK(cudaDeviceSynchronize());
    iElaps = seconds() - iStart;
```

```
    printf("mathKernel1 <<< %4d %4d >>> elapsed %d sec \n", grid.x, block.x,
        iElaps );
    CHECK(cudaGetLastError());
    // run kernel 3
    iStart = seconds();
    mathKernel2<<<grid, block>>>(d_C);
    CHECK(cudaDeviceSynchronize());
    iElaps = seconds() - iStart;
    printf("mathKernel2 <<< %4d %4d >>> elapsed %d sec \n", grid.x, block.x,
        iElaps );
    CHECK(cudaGetLastError());
    // run kernel 3
    iStart = seconds();
    mathKernel3<<<grid, block>>>(d_C);
    CHECK(cudaDeviceSynchronize());
    iElaps = seconds() - iStart;
    printf("mathKernel3 <<< %4d %4d >>> elapsed %d sec \n", grid.x, block.x,
        iElaps);
    CHECK(cudaGetLastError());
    // run kernel 4
    iStart = seconds();
    mathKernel4<<<grid, block>>>(d_C);
    CHECK(cudaDeviceSynchronize());
    iElaps = seconds() - iStart;
    printf("mathKernel4 <<< %4d %4d >>> elapsed %d sec \n", grid.x, block.x,
        iElaps);
    CHECK(cudaGetLastError());
    // free gpu memory and reset divece
    CHECK(cudaFree(d_C));
    CHECK(cudaDeviceReset());
    return EXIT_SUCCESS;
}
```

روی **GPU 1080** من همه‌ی کرنل‌ها زمان صفر رو گزارش کردند، به همین خاطر یک **benchmark** دیگر رو اینجا قرار میدم.

```
Warmingup
elapsed 0.000040 sec
mathKernel1 elapsed 0.000016 sec
```

```
mathKernel2 elapsed 0.000014 sec
```

همچنین می‌توانیم انشعاب رشته‌ها را با استفاده از **nvprof** و جمع‌آوری اندازه‌گیری‌های انجام شده توسط آن، انشعاب رشته را به دست بیاوریم. در اینجا، **nvprof** برای محاسبه‌ی **branch_efficiency** و با استفاده از دستور زیر باید انجام بپذیرد:

```
$ nvprof --metrics branch_efficiency ./simpleDivergence
```

```
Kernel: mathKernel1(float*)
    1          branch_efficiency          Branch Efficiency    100.00%    100.00%
Kernel: mathKernel2(float*)
    1          branch_efficiency          Branch Efficiency    100.00%    100.00%
```

branch efficiency نسبت شاخه‌های انشعاب شده به تعداد کل شاخه‌ها می‌باشد، و آن را می‌توان توسط فرمول زیر محاسبه کرد:

$$Branch\ Efficiency = 100 \times \left(\frac{\#\ Branches - \#\ Divergent\ Branches}{\#\ Branches} \right)$$

در مورد کد خودمان، این که هیچگونه انشعابی گزارش نشده یه مقداری عجیبه(چون **branch efficiency** برابر با ۱۰۰ گزارش شده است). این به خاطر بهینه‌سازی است که توسط کامپایلر **CUDA** انجام می‌شود که دستورات انشعابی را که منجر به انشعاب رشته می‌شد را با دستورات پیش‌بینی شده جایگزین می‌کند.

در پیش‌بینی شاخه، یک متغیر پیش‌بینی شده وجود دارد که برای هر ترد ست می‌شود و می‌تواند دو مقدار ۰و۱ را بگیرد و این بستگی به شرط دارد. هر دوی مسیرهای شرطی اجرا می‌شوند، اما تنها دستوراتی که مقدار ۱ دارند اجرا می‌شوند. دستوراتی که ۰ دارند اجرا نمی‌شوند، اما این تردها متوقف نمی‌شوند. فهمیدن این موضوع خیلی مهم است که چطور کامپایلر دستورات شرطی را با دستورات پیش‌بینی شده جایگزین می‌کند.

می‌توان **kernel1** را همانند **kernel3** نوشت تا به صورت دستی از انشعاب رشته جلوگیری کرد:

```
__global__ void mathKernel3(float *c)
{
    int tid = blockIdx.x * blockDim.x + threadIdx.x;
    float ia, ib;
    ia = ib = 0.0f;
    bool ipred = (tid % 2 == 0);
    if (ipred)
```

```
    {
        ia = 100.0f;
    }
    if (!ipred)
    {
        ib = 200.0f;
    }
    c[tid] = ia + ib;
}
```

شما می‌توانید کامپایلر **CUDA** را مجبور کنید که کد را بهینه نکند، تا از پیش‌بینی **branch** جلوگیری کند:

```
$ nvcc -g -G -arch=sm_20 simpleDivergence.cu -o simpleDivergence
```

دوباره انشعاب را با استفاده از **nvprof** و کرنل‌های بهینه نشده را محاسبه کنیم:

```
$ nvprof --metrics branch_efficiency ./simpleDivergence
```

```
Kernel: mathKernel1(float*)   Branch Efficiency    83.33%
Kernel: mathKernel2(float*)   Branch Efficiency   100.00%
Kernel: mathKernel3(float*)   Branch Efficiency   100.00%
```

بهینه‌ساز کامپایلر **nvcc** باز هم بهینه‌سازی‌های محدودی روی **mathKernel1** انجام می‌دهد تا **branch efficiency** را بالای ۵۰ درصد نگه دارد. توجه داشته باشید که تنها دلیلی که باعث شده که **mathKernel2** انشعاب نداشته باشد، این است که انشعاب رشته مضربی از اندازه‌ی رشته باشد.

۸ نکات کلیدی

- **انشعاب رشته وقتی اتفاق می‌افتد که تردهای درون یک رشته مسیرهای متفاوتی را طی کنند.**
- **انشعاب‌های مختلف if-then-else به صورت سریالی اجرا می‌شوند.**
- **از شاخه‌های بزرگ‌تر و مضربی از اندازه‌ی رشته استفاده کنید تا از انشعاب رشته جلوگیری کنید.**
- **رشته‌های متفاوت می‌توانند کدهای مختلف را بدون این که تاثیر بدی در پرفرمنس داشته باشند اجرا کنند.**

هر اجرای محلی از یک رشته، دارای یک محتویی است که معمولا دارای منابع زیر می‌باشد:

- Program counters
- Registers
- Shared memory

محتوای اجرای هر رشته توسط **SM** پردازش می‌شود و بر روی حافظه‌ی **on-chip** نگه‌داری می‌شود. بنابراین، سوییچ کردن بین محتواهای مختلف رشته‌ها هزینه‌ای دربرنخواهد داشت.

هر **SM** دارای مجموعه‌ای از رجیسترهای ۳۲ بیتی است که در **register file** ذخیره شده و بین تردها تقسیم می‌شود، و یک مقدار ثابت از حافظه‌ی اشتراکی که بین **thread block** های مختلف تقسیم شده است. تعداد **thread block** ها و رشته‌هایی که برای یک کرنل می‌توانند همزمان بر روی **SM** قرار بگیرند، وابسته به تعداد رجیسترها و میزان حافظه‌ی اشتراکی بر روی **SM** و میزانی است که کرنل نیاز دارد.

شکل زیر نشان میدهد که وقتی هر ترد از رجیسترهای بیشتری استفاده کند، رشته‌های کمتری می‌توانند بر روی یک **SM** قرار بگیرند. اگر بتوانید تعداد رجیسترهایی که یک کرنل استفاده می‌کند را کاهش دهید، تعداد رشته‌های بیشتری را می‌توان به صورت موازی اجرا کرد.

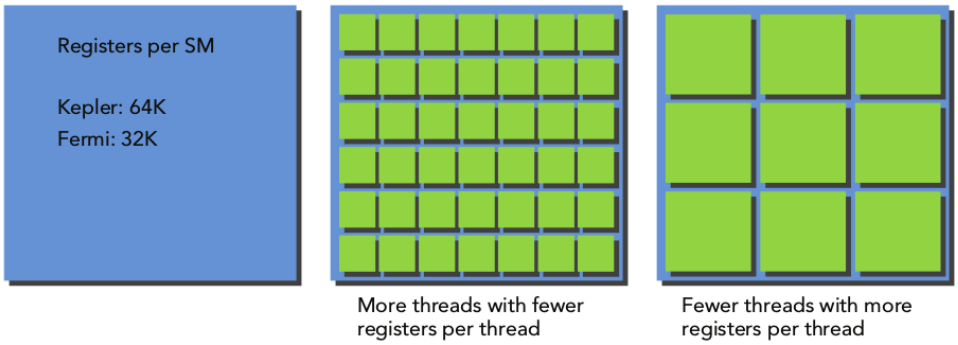

و شکل زیر نشان می‌دهد که وقتی یک **thread block** حافظه‌ی اشتراکی بیشتری مصرف کند، تعداد **thread block**های کمتری قادر خواهند بود به طور همزمان بر روی **SM** پردازش شوند.

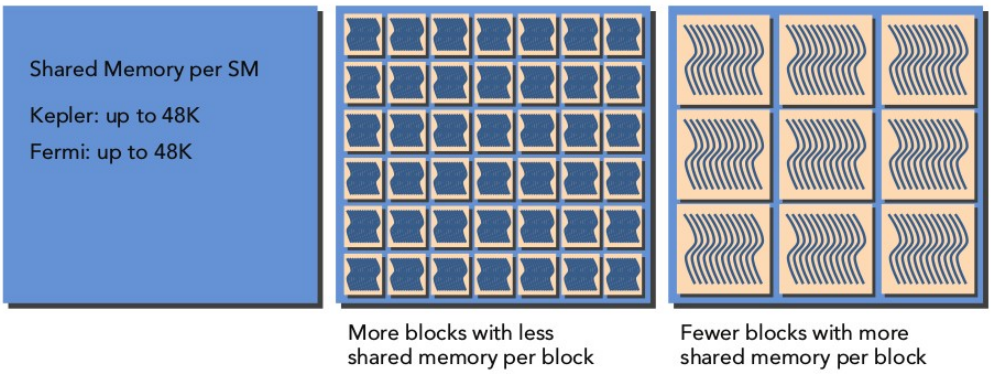

میزان منابع معمولا محدود کننده‌ی تعداد **thread block** ها در **SM** است. تعداد رجیسترها و میزان حافظه‌ی اشتراکی به ازای هر **SM** در هر **device** متفاوت است و بستگی به قدرت محاسباتی آن دارد. اگر تعداد رجیسترها و یا حافظه‌ی اشتراکی بر روی هر **SM** ناکافی باشد، فراخوانی کرنل **fail** خواهد شد. برخی از این محدودیت‌ها که مهم هستند در زیر لیست شده‌اند:

TABLE 3-2: Resource Limits Pertaining to Compute Capability

TECHNICAL SPECIFICATIONS	COMPUTE CAPABILITY			
	2.0	2.1	3.0	3.5
Maximum number of threads per block	1,024			
Maximum number of concurrent blocks per multiprocessor	8		16	
Maximum number of concurrent warps per multiprocessor	48		64	
Maximum number of concurrent threads per multiprocessor	1,536		2,048	
Number of 32-bit registers per multiprocessor	32 K		64 K	
Maximum number of 32-bit registers per thread	63		255	
Maximum amount of shared memory per multiprocessor	48 K			

یک **thread block** وقتی که منابع به آن تخصیص داده می‌شود به عنوان **active block** شناخته می‌شود، این منابع شامل رجیسترها و حافظه‌ی اشتراکی می‌باشند. و رشته‌هایی که دارد را **active warps** می‌نامند. رشته‌های فعال را می‌توان به سه نوع زیر دسته‌بندی کرد:

- ➤ Selected warp
- ➤ Stalled warp
- ➤ Eligible warp

برنامه‌ریز رشته **SM** وظیفه دارد که رشته‌های فعال را در هر سیکل انتخاب کند و آن‌ها را روی واحدهای اجرایی تقسیم کند. یک رشته که در حال حاضر در هر حال اجراست را **selected warp** می‌گویند. اگر یک رشته برای اجرا آماده باشد، ولی در همان لحظه چیزی را اجرا نکند، آن را **eligible warp** می‌نامیم. اگر یک رشته برای اجرا آماده نباشد، آن را **stalled warp** می‌نامیم. یک رشته **eligible** می‌باشد اگر دو شرط زیر به وقوع پیوسته باشد:

- ۳۲ هسته‌ی کودا برای اجرا در دسترس باشد.
- همه‌ی آرگومان‌ها برای اجرای دستورات آماده باشند.

به طور مثال، تعداد رشته‌های فعال بر روی **SM** در معماری **Kepler** در هر زمانی کوچکتر مساوی با حد معماری است که ۶۴ تا رشته‌ی موازی است. تعداد **selected warp** در هر سیکل کمتر و یا مساوی با ۴ می‌باشد. اگر یک رشته متوقف شود، برنامه‌ریز رشته یک **eligible warp** را به جای آن برای اجرا انتخاب می‌کند. از آنجایی که منابع محاسباتی بین رشته‌ها بر روی **on-chip** نگه‌داری می‌شود، سوییچ کردن بین رشته‌ها خیلی سریع خواهد بود. در بخش بعدی، یاد خواهید گرفت که نیاز دارید که تعداد رشته‌های

زیادی را فعال نگه دارید تا تاخیر را مخفی کنید که این تاخیر به خاطر **warp stalling** به وجود میآید. بنابراین برای بکارگیری حداکثر توان **GPU** نیاز داریم که تعداد رشته‌های فعال را بیشینه کنیم.

۱۰ Latency Hiding

یک **SM** مبتنی بر موازی‌سازی در سطح ترد می‌باشد تا بتواند بیشترین استفاده را از واحدهای **GPU** بگیرد. بر این اساس، میزان بکارگیری **GPU** به طور مستقیم با تعداد رشته‌های موجود رابطه دارد. **Instruction latency** به میزان کلاک‌ها از زمان اجرای دستورالعمل تا پایان آن گفته می‌شود. میزان بکارگیری از **GPU** وقتی کامل می‌شود که همه‌ی برنامه‌ریزهای رشته در هر کلاک یک **eligible warp** داشته باشند. این می‌تواند اطمینانی باشد که تاخیر هر دستورالعمل را بتوان با فراخوانی کردن دستورالعمل‌های دیگر در رشته‌های دیگر مخفی کرد.

در مقایسه با برنامه‌نویسی **C** بر روی **CPU**، مخفی کردن این تاخیر روی برنامه نویسی **CUDA** پراهمیت است. هسته‌های **CPU** به این منظور طراحی شده‌اند که تاخیر یک یا دو ترد را به حداقل برسانند، در حالی که **GPU** ها به این منظور طراحی شده‌اند که تعداد زیادی ترد سبک را به منظور بیشینه کردن توان عملیاتی (**throughput**) مدیریت کنند. **Instruction latency** در **GPU** را میتوان با اجرای محاسبات در سایر رشته‌ها مخفی کرد.

با در نظر گرفتن **instruction latency** ، می‌توان دستورالعمل‌ها را به دو گروه زیر تقسیم کرد:

- دستورات محاسباتی
- دستورات حافظه

تاخیر دستورات محاسباتی به میزان زمانی اطلاق می‌شود که یک دستورالعمل محاسباتی شروع شده و خروجی آن تولید شده باشد. تاخیر دستورات حافظه‌ای به میزان زمانی اطلاق می‌شود که یک دستورالعمل **load** و یا **store** اجرا شده و داده بر روی مقصد مورد نظر قرار گرفته باشد. تاخیر متناظر هر مورد به طور تقریبی به این صورت است:

- ۲۰-۱۰ سیکل برای دستورات محاسباتی
- ۸۰۰-۴۰۰ سیکل برای دسترسی به حافظه‌ی **global**

در زیر به صورت تصویری یک مورد ساده از **pipeline** شدن دستورات را نشان داده‌ایم که در آن رشته‌ی **0** متوقف شده است. برنامه‌ریز رشته، در این جا، رشته‌های دیگر را برای اجرا برداشته تا رشته‌ی **0** دوباره **eligible** شود.

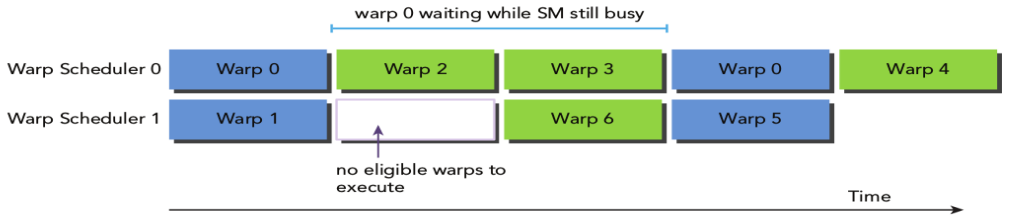

شاید این سوال پیش آمده باشد که چطور می‌توانیم تعداد رشته‌های فعال برای مخفی کـردن این تـاخیر را بدست بیاوریم. **Little law** تقریب خوبی برای این مورد می‌باشد. در نظریه صف یک رابطه وجـود دارد که بر روی **GPU** نیز می‌توان آن را اعمال کرد:

```
Number of Required Warps = Latency × Throughput
```

شکل زیر این **little law** را به خوبی بیان می‌کند. فرض کنید که تاخیر میانگین برای دستورات شما ۵ سیکل باشد. برای این که بتونید میزان **throughput** را شش رشته به ازای هر سیکل نگه‌دارید، نیاز دارید که حداقل ۳۰ رشته داشته باشید.

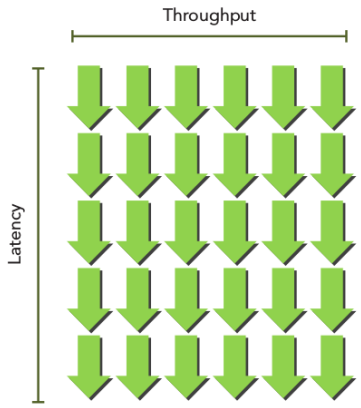

FIGURE 3-16

۱ توان عملیاتی و پهنای باند

پهنای باند و توان عملیاتی معمولا اشتباه فهمیده می‌شوند، اما ممکن است بنابر شرایط به جـای همـدیگر استفاده شوند. هم توان عملیاتی و هم پهنای باند را می‌توان به عنـوان یـک متریـک بـرای انـدازه‌گیری پرفرمنس به حساب آورد.
پهنای باند معمولا به مقدار پیک در حالت تعوری اطلاق می‌شود، در حالی که توان عملیاتی به مقداری کـه به آن رسیده‌ایم اطلاق می‌شود.
پهنای باند معمولا به بیشترین مقداری از داده که در واحد زمان می‌توان منتقـل کـرد اطلاق می‌شـود، در حالی که توان عملیاتی به نرخ هر گونه اطلاعات و یا عملیات‌هایی که در واحد زمان منتقل می‌شـود اطلاق می‌شود، مثلا، چه میزان دستورالعمل را می‌توان در هر سیکل کامل کرد.

برای عملیات‌های محاسباتی، میزان موازی‌سازی مورد نیاز را می‌توان به عنـوان تعـداد عملیات‌هـایی کـه برای مخفی کردن تاخیر محاسباتی مورد نیاز است شناخت. جدول زیر میزان عملیات‌های مورد نیاز برای معماری **Fermi** و **Kepler** را لیست کرده است.

TABLE 3-3: SM Parallelism Required to Maintain Full Arithmetic Utilization

GPU MODEL	INSTRUCTION LATENCY (CYCLES)	THROUGHPUT (OPERATIONS/CYCLE)	PARALLELISM (OPERATIONS)
Fermi	20	32	640
Kepler	20	192	3,840

عملیات محاسباتی که در اینجا به عنوان مثال آورده شده(**a+b*c** ؛ **multiply-add** به صورت **32bit float** می‌باشد، که تحت عنوان تعداد دستورها به ازای هر کلاک به ازای هر **SM** شناخته می‌شود. توان عملیاتی برای دستورالعمل‌های محاسباتی مختلف متفاوت است.

توان عملیاتی در تعداد عملیات‌هایی که در هر سیکل به ازای هر **SM** انجام می‌پذیرد، مشخص می‌شود، و یک رشته، یک دستورالعمل متناظر به ۳۲ عملیات را اجرا می‌کند. بنابراین، تعداد رشته‌های مورد نیاز به ازای هر **SM** به منظور استفاده کامل از **GPU** را می‌توان بر روی معماری **Fermi** به صورت **20=640/32** محاسبه کرد. از این رو، میزان موازی‌سازی مورد نیاز برای عملیات‌های محاسباتی را می‌توان هم با استفاده از تعداد عملیات‌ها و هم با تعداد رشته‌ها بیان کرد. این تبدیل ساده تلویحا نشان‌دهنده‌ی این است که دو روش برای افزایش موازی‌سازی وجود دارد:

- Instruction-level parallelism (ILP): More independent instructions within a thread
- Thread-level parallelism (TLP): More concurrently eligible threads

برای عملیات‌های حافظه، میزان موازی‌سازی را می‌توان تحت عنوان تعداد بایت بر سیکل مورد نیاز برای مخفی کردن تاخیر حافظه بیان کرد. جدول زیر اندازه‌گیری‌های لازم را برای معماری **Fermi** و **Kepler** را نشان میدهد.

TABLE 3-4: Device Parallelism Required to Maintain Full Memory Utilization

GPU MODEL	INSTRUCTION LATENCY (CYCLES)	BANDWIDTH (GB/SEC)	BANDWIDTH (B/CYCLE)	PARALLELISM (KB)
Fermi	800	144	92	74
Kepler	800	250	96	77

از آنجایی که توان عملیاتی را می‌توان با **gigabytes per second** بیان کرد، در ابتدا نیاز داریم که توان عملیاتی را به **gigabytes per cycle** تبدیل کنیم. می‌توانید فرکانس حافظه‌ی خود را با استفاده از دستور زیر چک کنید.

```
nvidia-smi -a -q -d CLOCK | fgrep -A 3 "Max Clocks" | fgrep "Memory"
```

به طور مثال فرکانس حافظه بر روی **Tesla C2070** برابر با **1.566GHz** می‌باشد و یا بر روی **1080ti** برابر با **5505MHz** می‌باشد. از آنجایی که **1Hz** یعنی یک سیکل بر ثانیه، در این صورت می‌توانید پهنای باند را از **gigabytes per second** به **gigabytes per cycle** تبدیل کنید:

```
144 GB/Sec ÷ 1.566 GHz ≅ 92 Bytes/Cycle
```

با ضرب کردن **bytes per cycle** به دست آمده در تاخیر حافظه، می‌توانید میزان موازی‌سازی مورد نیاز برای دستورالعمل‌های حافظه‌ی **Fermi** را به دست بیاورید که حدودا **74KB** می‌باشد. این مقدار برای کل **device** بوده، و برای هر **SM** محاسبه نشده، چرا که پهنای باند برای کل **device** داده می‌شود نه برای کل **device**.

حال با کنار هم قرار دادن همه‌ی این ها به تعداد رشته‌ها و یا تردهایی که نیاز داریم دست پیدا می‌کنیم. فرض کنید که هر ترد یک داده‌ی **float** را که **4byte** می‌باشد را از حافظه‌ی **global** به **SM** جابه‌جا کند، در این صورت نیاز به ۱۸۵۰۰ ترد و یا ۵۷۹ رشته خواهیم داشت تا همه‌ی این تاخیر حافظه را مخفی کنیم.

```
74 KB ÷ 4 bytes/thread ≅ 18,500 threads
18,500 threads ÷ 32 threads/warp ≅ 579 warps
```

معماری **Fermi** دارای ۱۶ تا **SM** بوده. بنابراین، **579warps / 16SMs= 36WarpsPerSM** نیاز داریم تا همه‌ی این تاخیر حافظه را از بین ببریم. اگر هر ترد بیشتر از **4bytes** را **load** کند، تردهای کمتری برای مخفی کردن تاخیر حافظه نیاز خواهیم داشت.

همانند تاخیر دستورالعمل، می‌توانید میزان موازی‌سازی در دسترس را با ایجاد عملیات‌های حافظه مستقل بیشتر در ترد/رشته افزایش دهید و یا این که تعداد ترد/رشته‌های فعال را افزایش دهید.

مخفی کردن تاخیر مبتنی بر تعداد رشته‌های فعال در هر **SM** ، به صورت غیر مستقیم توسط تنظیمات کرنل و محدودیت‌های منابع مشخص می‌شود(رجیسترها و حافظه‌ی اشتراکی مورد استفاده در کرنل). انتخاب یک تنظیمات بهینه، در واقع ایجاد تعادل بین مخفی کردن تاخیر و استفاده کامل از منابع است. این مورد را به صورت خیلی ریزتری در بخش بعد مورد بررسی قرار خواهیم داد.

۱۱ تصرف یا Occupancy

در هر هسته‌ی کودا، دستورالعمل‌ها به صورت سریال اجرا می‌شوند. وقتی که یک رشته متوقف می‌شود، **SM** روی رشته‌ی دیگری سوییچ می‌کند که به صورت **eligible** باشد و آن را اجرا می‌کند. به صورت ایده‌ال، دلخواه شما این است که تعداد رشته‌های کافی برای تصرف **device** را داشته باشیم. تصرف یا **occupancy** در واقع نسبت تعداد رشته‌های فعال به ماکسیمم رشته‌ها به ازای هر **SM** می‌باشد.

$$occupancy = \frac{active\ warps}{maximum\ warps}$$

می‌توانید بیشترین تعداد رشته در هر **SM** را با استفاده از تابع زیر به دست بیاورید:

```
cudaDeviceProp deviceProp;
CHECK(cudaGetDeviceProperties(&deviceProp, dev));
```

اطلاعات زیادی از **device** در استراکچر **deviceProp** ذخیره می‌شود. بیشترین تعداد ترد بـه ازای هـر **SM** در متغیر زیر برگشت داده می‌شود:

```
maxThreadsPerMultiProcessor
```

که برای سیستم من که **1080ti** هست خروجی به صورت زیر درمیآید.

```
printf("maximum number of threads per SM:%d\n",deviceProp.maxThreadsPerMultiProcessor);


maximum number of threads per SM:2048
```

شما می‌توانید بیشترین تعداد رشته‌ها را با تقسیم کردن **maxThreadsPerMultiProcessor** بر ۳۲ بدست بیاورید. کد زیر نشان میدهد که چطور تنظیمات **GPU** را بدست بیاورید.

```
int main(int argc, char **argv)
{
    int iDev = 0;
    cudaDeviceProp iProp;
    cudaGetDeviceProperties(&iProp, iDev);
    printf("Device %d: %s\n", iDev, iProp.name);
    printf("Number of multiprocessors: %d\n", iProp.multiProcessorCount);
    printf("Total amount of constant memory: %4.2f KB\n",iProp.totalConstMem/1024.0);
    printf("Total amount of shared memory per block: %4.2f KB\n",iProp.sharedMemPerBlock/1024.0);
    printf("Total number of registers available per block: %d\n",iProp.regsPerBlock);
    printf("Warp size%d\n", iProp.warpSize);
    printf("Maximum number of threads per block: %d\n", iProp.maxThreadsPerBlock);
    printf("Maximum number of threads per multiprocessor: %d\n",iProp.maxThreadsPerMultiProcessor);
    printf("Maximum number of warps per multiprocessor: %d\n",iProp.maxThreadsPerMultiProcessor/32);
}
```

```
Device 0: GeForce GTX 1080 Ti
Number of multiprocessors: 28
Total amount of constant memory: 64.00 KB
Total amount of shared memory per block: 48.00 KB
Total number of registers available per block: 65536
Warp size32
Maximum number of threads per block: 1024
Maximum number of threads per multiprocessor: 2048
Maximum number of warps per multiprocessor: 64
```

CUDA ToolKit یک فایل اکسل نیز درون خودش دارد، کـه **CUDA Occupancy Calculator** نامیـده می‌شود، که به شما در انتخاب ابعاد گرید و بلاک کمک می‌کند تا بیشـترین مقـدار **occupancy** رو بـرای یک کرنل داشته باشید. شکل زیر یک اسکرین شات از این ماشین‌حساب را نشان می‌دهد.

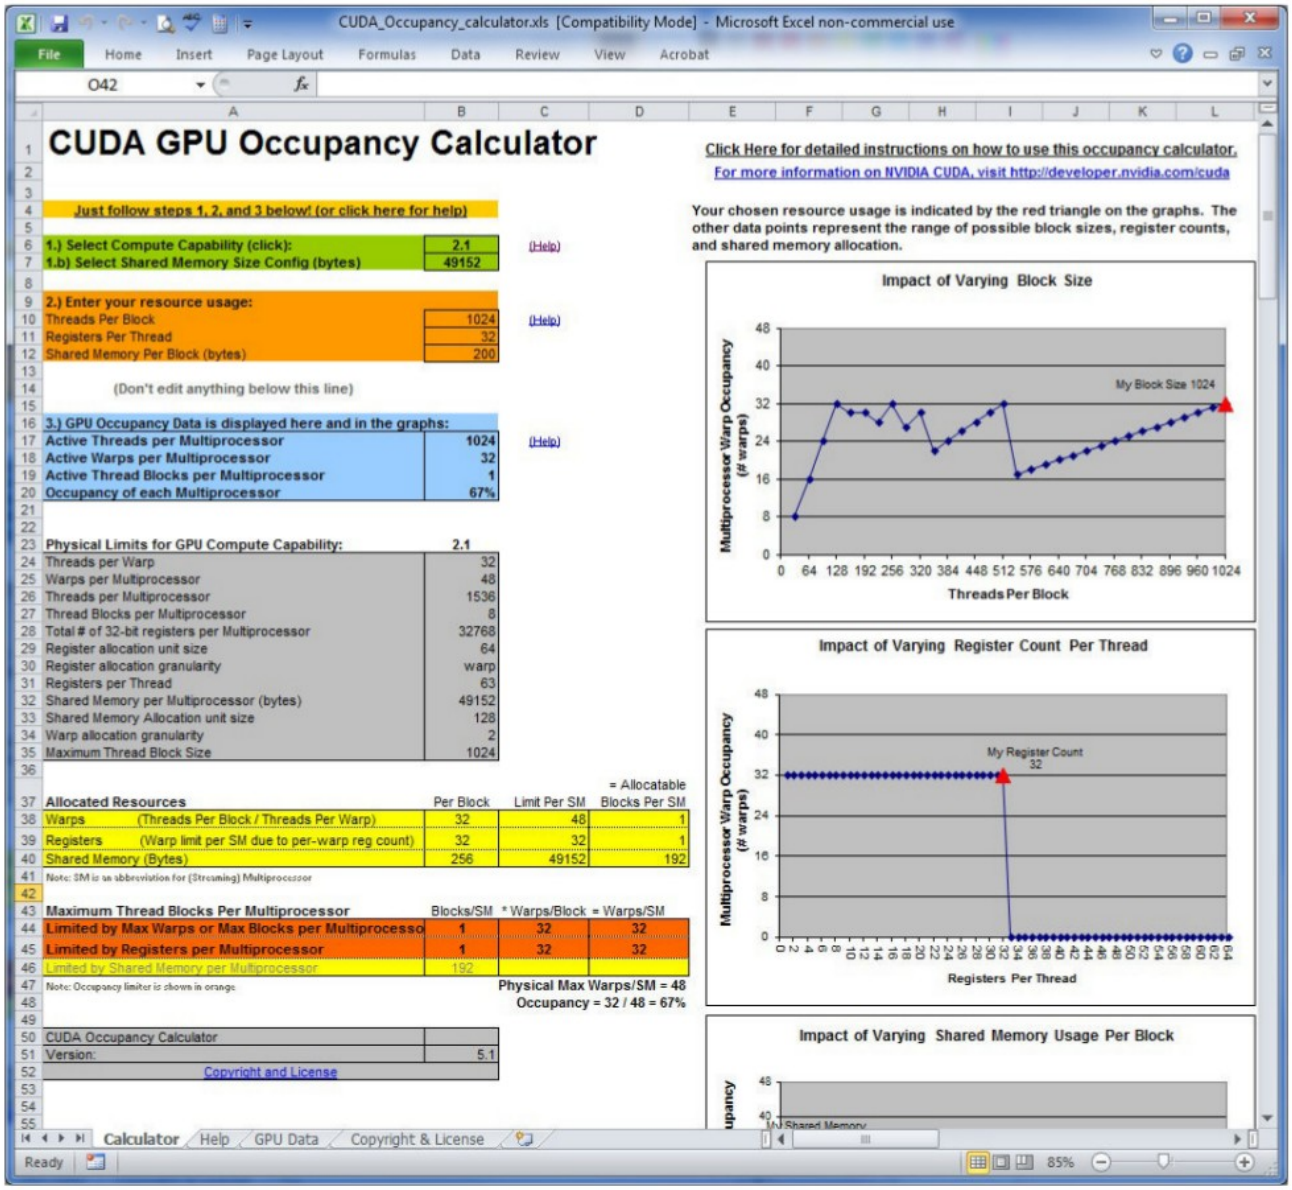

همچنین می‌توانیم از این لینک نیز استفاده کنیم. در ابتدا نیاز است که برخی از اطلاعات مـورد نیـاز در مورد **compute capability** و میزان منابع کرنل را به عنوان ورودی بدهیم.

پس از این که مقدار **compute capability** را مشخص کردید، داده‌ها در قسمت **physical limit section** به صورت خودکار پر می‌شود. در ادامه، نیاز داریم که اطلاعات زیر را در مورد منابع کرنل وارد کنیم:

- Threads per block (execution confi guration)
- Registers per thread (resource usage)
- Shared memory per block (resource usage)

تعداد رجیستر به ازای هر ترد و حافظه‌ی اشتراکی به ازای هر بلاک را می‌توان توسط **nvcc** به دست بیاورید که این کار از طریق استفاده از آپشن **--ptxas-options=-v** باید استفاده کرد:

```
$ nvcc cuda_code.cu --ptxas-options=-v -arch=sm_61
ptxas info    : 0 bytes gmem
ptxas info    : Compiling entry function '_Z11mathKernel1Pf' for 'sm_61'
ptxas info    : Function properties for _Z11mathKernel1Pf
    0 bytes stack frame, 0 bytes spill stores, 0 bytes spill loads
ptxas info    : Used 6 registers, 328 bytes cmem[0], 8 bytes cmem[2]
```

نحوه‌ی تفسیر این خروجی به صورت زیر است:

- هر ترد کودا، از شش رجیستر استفاده می‌کند.
- متغیر **smem** برای **shared memory** استفاده می‌شود.
- متغیر **cmem** برای **constant memory** استفاده می‌شود.
- متغیر **lmem** برای **local memory** استفاده می‌شود.

وقتی که این مقادیر را وارد کنید، میزان **occupancy** کرنل شما در قسمت **GPU Occupancy Data Section** نمایش داده می‌شود. قسمت‌های دیگر یک سری اطلاعات ضروری را برای تنظیم کردن تنظیمات اجرایی و مدیریت منابع را در اختیار شما قرار میدهد.

تعداد رجیسترهایی که توسط کرنل استفاده می‌شود تاثیر خیلی زیادی بر روی تعداد رشته‌ها دارد. تعداد رجیسترها را می‌توان به صورت دستی و با استفاده از یک فلگ کامپایلر **nvcc** کنترل کرد.

```
–maxrregcount=NUM
```

این گزینه **maxrregcount**- به کامپایلر می‌گوید که رجیستر بیشتری از **NUM** به ازای هر ترد استفاده نکند. شما می‌توانید از تعداد رجیسترهای پیشنهاد شده توسط **Occupancy Calculator** در کامپایلر استفاده کنید تا پرفرمنس برنامه را بالا ببرید.

برای بهبود میزان **Occupancy** ، همچنین نیاز داریم که تنظیمات **thread block** رو **resize** کنید و یا منابع رو تعدیل کنید تا امکان اجرای هر چه بیشتر رشته‌ها به صورت موازی وجود داشته باشد. دستکاری **thread block** همچنین می‌تواند استفاده از منابع را محدود کند:

- **thread block** کوچک: تعداد خیلی اندک از تردها درون یک بلاک ممکن است منجر به محدودیت سخت‌افزاری در تعداد رشته‌ها به ازای هر **SM** شود و نتوانیم به طور کامل از منابع استفاده کنیم.

- **Thread block** بزرگ: تعداد زیاد ترد به ازای هر بلاک ممکن است که باعث کمبود منابع سخت‌افزاری به ازای هر ترد شود.

اگر چه هر کدام منجر به محدودیت سخت افزاری مختلف می‌شود، اما هر دو مورد باعث این می‌شود که منابع محاسباتی به اندازه‌ی کافی استفاده نشود و میزان موازی‌سازی کاهش یابد که باعث عدم مخفی‌سازی تاخیر دستورالعمل و حافظه می‌شود. **Occupancy** به صورت ویژه بر روی تردهای موازی یا رشته‌ها به ازای هر **SM** تمرکز دارد. اگر چه، **Occupancy** کامل تنها هدف ما در بهینه‌سازی پرفرمنس نیست. وقتی که به یک حد خوبی از **Occupancy** برای یک کرنل برسیم، افزایش **Occupancy** دیگر تاثیری نخواهد داشت. و فاکتورهای دیگری وجود دارد که برای افزایش پرفرمنس باید آن‌ها را نیز دستکاری کنید. در مورد این فاکتورها در فصول بعدی بیشتر بحث خواهیم کرد.

۱ راهنمای انتخاب ابعاد **grid,block**

با استفاده از این راهنما به برنامه‌تان کمک می‌کنید که بر روی deviceهای حال حاظر و آینده اجرا شود:
۱-تعداد تردها به ازای هر بلاک را مضربی از ۳۲ نگه دارید.
۲-از block size های کوچک استفاده نکنید: با برای اندازه‌ی بلاک از ۱۲۸ و یا ۲۵۶ ترد به ازای هر بلاک استفاده کنید.
۳-اندازه‌ی بلاک را بر حسب نیاز کرنل به منابع کوچک و بزرگ کنید.
۴-تعداد بلاک‌ها را خیلی بیشتر از تعداد SM ها قرار دهید تا میزان موازی‌سازی مناسبی بر روی device داشته باشید.
۵-برای پیدا کردن بهترین تنظیمات اجرایی و استفاده از منابع، سعی و خطا کنید.

۱۲ سنکرون کردن

Barrier synchronization یکی از متداول‌ترین روش‌های سنکرون کردن در زبان‌های برنامه‌نویسی موازی است. در **CUDA** می‌توان سنکرون سازی را در دو سطح انجام داد:

- **system-level** : منتظر همه‌ی کارهای **host** و **device** باشیم تا کامل شود.
- **Block-level** : منتظر همه‌ی تردهای درون یک **thread block** باشیم تا به یک موقعیت و نقطه خاص در اجرا بر روی **device** برسد.

از آنجایی که همه‌ی کرنل‌هایی که اجرا می‌شود نسبت به **host** به صورت آسنکرون هستند، دستور **cudaDeviceSynchronize** می‌تواند برای متوقف کردن **host** استفاده شود تا همه‌ی عملیات‌های **CUDA** پایان یابد(کپی، کرنل و ...):

```
cudaError_t  cudaDeviceSynchronize(void)
```

این تابع ممکن است خطاها را از عملیات آسنکرون قبلی برگرداند.

از آنجایی که رشته‌ها در یک **thread block** در یک ترتیب نامشخص اجرا می‌شوند، **CUDA** امکانی را برای سنکرون کردن اجرای آن‌ها با استفاده از **block-local barrier** در اختیار ما گذاشته است. شما می‌توانید نقطه‌ی سنکرون‌سازی درون کرنل را با استفاده از تابع زیر مشخص کنید:

```
__device__ void __syncthreads(void);
```

وقتی که **__syncthreads** فراخوانی می‌شود، هر تردی درون **thread block** یکسان باید منتظر بماند تا همه‌ی تردهای درون آن **thread block** به نقطه‌ی سنکرون سازی برسد. همه‌ی دسترسی‌های تردها به حافظه‌ی **global** و **shared** که قبل از **barrier** ساخته شده، بعد از **barrier** برای همه‌ی تردهای دیگر قابل دسترسی خواهد بود. این تابع برای ارتباط مکانی بین تردهای درون یک بلاک استفاده می‌شود، ولی می‌تواند باعث افت پرفرمنس نیز شود چون باعث می‌شود که رشته‌ها به حالت معلق دربیایند. تردها درون **thread block** می‌توانند داده را از طریق **shared momory** و رجیسترها به اشتراک بگذارند. در هنگام به اشتراک گذاری داده بین تردها باید مواظب وقوع **race condition** باشید. **Race condition** و یا **hazards**، به دسترسی غیر مرتب چندین ترد به یک حافظه گفته می‌شود. وقتی که تردهای درون **thread block** به صورت موازی با هم کار می‌کنند، همه‌ی تردها نمی‌توانند به صورت فیزیکی در یک زمان اجرا را تمام کنند. اگر ترد **A** تلاش کند که داده‌ای را بخواند که توسط ترد **B** در یک رشته‌ی دیگر نوشته شده است، شما تنها می‌توانید اطمینان حاصل کنید که ترد **B** کارش را تمام کرده اگر و تنها اگر سنکرون سازی مناسبی را انجام داده باشید. در غیر این صورت، **race condition** رخ خواهد داد. در مورد مباحث سنکرون سازی در فصل چهارم بیشتر بحث خواهیم کرد.

هیچگونه سنکرون سازی بین تردهای بین **block** های مختلف وجود ندارد. تنها راه مطمعن برای سنکرون کردن بین بلاک‌های مختلف استفاده از سنکرون‌سازی **global** در انتهای هر اجرای کرنل می‌باشد. پایان پذیرفتن کرنل فعلی و شروع یک کرنل جدید برای کار جدید پس از **global synchronization**.

اگر نیازی به سنکرون کردن تردهای مربوط به بلاک‌های مختلف نداشته باشیم، **GPU** می‌تواند **block** ها را در هر ترتیبی که دوست داشت اجرا کند. این باعث می‌شود که برنامه‌ی **CUDA** بتواند بر روی تعداد زیادی **GPU** مقیاس پذیر باشد.

۱۳ مقیاس پذیری

مقیاس‌پذیری یک ویژگی مطلوب برای هر برنامه‌ی موازی محسوب می‌شود. مقایس پذیری یعنی با فراهم کردن منابع سخت‌افزاری بیشتر برای برنامه‌ی موازی می‌توانیم سرعت برنامه را افزایش بدهیم. به

طور مثال، یک برنامه‌ی **CUDA** یی که برای روی دو تا **SM** اجرا می‌شود باید نسبت به موقعی که بر روی یک **SM** اجرا می‌شود، دو برابر سریع‌تر باشد. برنامه‌ی موازی مقیاس‌پذیر از همه‌ی منابع سخت‌افزاری به صورت موثری استفاده می‌کند تا پرفرمنس را افزایش دهد. مقیاس‌پذیری می‌گوید که پرفرمنس را می‌توان با اضافه کردن هسته‌های محاسباتی بیشتر، بهبود بخشید. کد سریال به خاطر پیشینه‌ی خود مثل برنامه‌های موازی مقیاس پذیر نیست. کد موازی به صورت بالقوه مقیاس‌پذیر می‌باشد، ولی مقیاس‌پذیری واقعی بسته به طراحی الگوریتم و ویژگی‌های سخت‌افزاری می‌باشد.

توانایی اجرای یک برنامه‌ی مشخص بر روی تعداد هسته‌های متفاوت را **transparent scalability** می‌نامند. شاید مقیاس‌پذیر از موثر بودن کد مهم‌تر باشد. یک کد مقیاس‌پذیر بد می‌تواند با افزودن هسته‌های سخت‌افزاری بالاخره کار کند و بهبود پیدا کند. ولی یک سیستم خوب ولی مقیاس‌ناپذیر نمی‌تواند با اضافه کردن هسته‌های سخت‌افزاری بهبود پیدا کند.

وقتی که یک کرنل **CUDA** اجرا می‌شود، **block thread** ها بین چندین **SM** پخش می‌شوند. **Thread block** های درون یک گرید می‌توانند در هر ترتیبی اجرا شوند، به صورت پارالل و یا به صورت سریال. این عدم وابستگی باعث می‌شود که برنامه‌های **CUDA** روی تعداد هسته‌های مختلف محاسباتی مقیاس پذیر باشند.

شکل زیر یک مثال از معماری مقیاس‌پذیر **CUDA** را نمایش‌میدهد. در سمت چپ، یک **GPU** در اختیار دارید که دو تا **SM** دارد که دو **block** را به صورت همزمان اجرا می‌کند و در سمت راست، یک **GPU** دارید که چهار تا **SM** دارد که چهار تا **block** را به صورت همزمان اجرا می‌کند. بدون این که کد تغییر بکند، برنامه می‌تواند روی **GPU** های مختلف کار کند و میزان زمان اجرا بر اساس میزان منابع محاسباتی تغییر می‌کند.

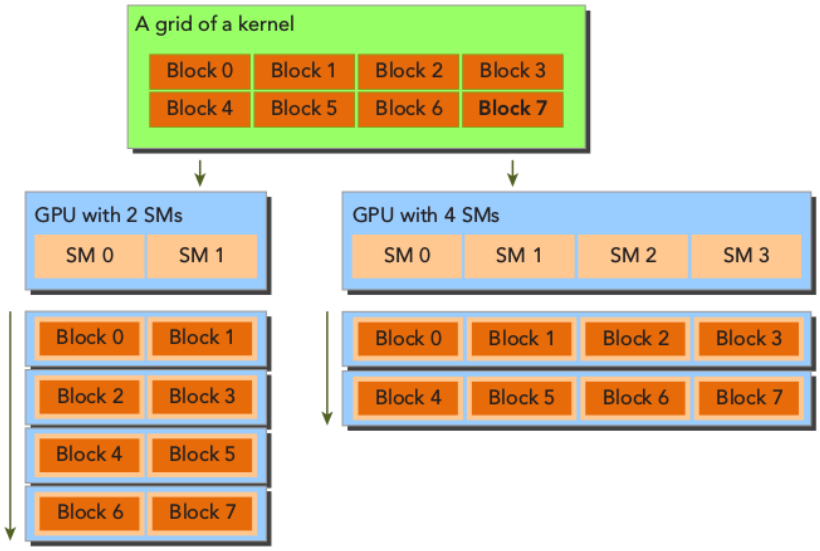

۱۴ توزیع موازی

برای درک بهتر طبیعت اجرای رشته، تمرین **sumMatrixOnGPU1D** را با تنظیمات اجرایی مختلف بررسی خواهیم کرد. در این مورد و با استفاده از **nvprof** و متریک‌هایی که وجود دارد سعی خواهیم کرد که درک بهترین از ابعاد **grid/block** به دست بیاوریم و بفهمیم چرا برخی تنظیمات از برخی دیگر بهترند.

کرنل جمع ماتریس دو بعدی به صورت زیر می‌باشد:

```
__global__ void sumMatrixOnGPU2D(float *MatA, float *MatB, float *MatC,
                                 int nx, int ny) {
    unsigned int ix = threadIdx.x + blockIdx.x * blockDim.x;
    unsigned int iy = threadIdx.y + blockIdx.y * blockDim.y;
    unsigned int idx = iy*nx + ix;
    if (ix < nx && iy < ny)
        MatC[idx] = MatA[idx] + MatB[idx];
}
```

کد زیر باعث می‌شود که بتوانیم تنظیمات کرنل را توسط **command line** وارد کنیم:

```
    if(argc>2)
    {
        dimx = atoi(argv[1]);
        dimy = atoi(argv[2]);
    }
    dim3 block(dimx, dimy);
    dim3 grid((nx+block.x-1)/block.x, (ny+block.y-1)/block.y);
```

۱۵ چک کردن رشته‌های فعال توسط nvprof

ابتدا نیاز داریم که یک نتیجه رفرنس برای پرفرمنس ایجاد کنیم. برای این کار، مجموعه‌ای از تنظیمات ترد بلاک را تست می‌کنیم، مثلا ترد بلاک (۳۲,۳۲) و (۳۲,۱۶) و (۱۶,۳۲) و (۱۶,۱۶) . به خاطر بیاورید که **sumMatrix** بعد **x** رو به عنوان اولین آرگومان میگیرد، و بعد **y** را به عنوان دومین آرگومان

block thread میگیرد. می‌توانید تنظیمات **block thread** مختلفی را توسط **sumMatrix** با **command line** وارد کنید و نتایج را ببینید:

```
$ nvprof --metrics achieved_occupancy ./sumMatrix 32 32
sumMatrixOnGPU2D <<<(512,512),  (32,32)>>> Achieved Occupancy    0.501071
$ nvprof --metrics achieved_occupancy ./sumMatrix 32 16
sumMatrixOnGPU2D <<<(512,1024), (32,16)>>> Achieved Occupancy    0.736900
$ nvprof --metrics achieved_occupancy ./sumMatrix 16 32
sumMatrixOnGPU2D <<<(1024,512), (16,32)>>> Achieved Occupancy    0.766037
$ nvprof --metrics achieved_occupancy ./sumMatrix 16 16
sumMatrixOnGPU2D <<<(1024,1024),(16,16)>>> Achieved Occupancy    0.810691
```

با مقایسه‌ی این نتایج، کندترین پرفرمنس مربوط به تنظیمات بلاک (۳۲,۳۲) است. و سریع‌ترین تنظیمات **block thread** مربوط به (۳۲,۱۶) می‌باشد. شاید شما این دلیل را بیاورید که مورد دوم تعداد **block thread** های بیشتری از مورد اول دارد و در نتیجه میزان موازی‌سازی بیشتری دارد. این دلیل را می‌توان توسط **nvprof** و میزان **achieved_occupancy** ثابت کرد. در واقع **achieved_occupancy** از کرنل نسبت میانگین رشته‌های فعال در هر سیکل به بیشترین تعداد رشته‌هایی که یک **SM** می‌تواند پشتیبانی کند. نتایج در زیر به صورت خلاصه آورده شده است.

از این نتایجی که در بالا گرفتیم می‌توان دو نکته را مشاهده کرد:

- از آنجایی که مورد دوم، تعداد **block** های بیشتری از مورد اول را دارد، توزیع رشته‌های فعال بیشتری روی **device** دارد. این دلیلی است که چرا مورد دوم مقدار **occupancy** بیشتری داشته و در نتیجه پرفرمنس بهتری دارد.
- مورد چهارم بیشترین مقدار **achieved occupancy** را دارد، ولی سریع‌ترین نیست، بنابراین، داشتن **occupancy** بالا همیشه منتج به پرفرمنس بیشتر نمی‌شود. و حتما فاکتورهای دیگری هم هست که موجب محدود شدن پرفرمنس می‌شود.

۱۶ چک کردن عملیات‌های حافظه با nvprof

سه عملیات حافظه‌ای در کرنل **sumMatrix** وجود دارد (**C[idx]=A[idx]+B[idx]**) : دو تا بارگزاری از حافظه و یکی هم ذخیره. میزان کارآمدی این عملیات‌های حافظه‌ای را می‌توان توسط **nvprof** ارزیابی کرد. ابتدا، میزان کارآمدی خواندن از حافظه را توسط متریک **gld_throughput** را برای کرنل‌های مختلف مشاهده کرد:

```
$ nvprof --metrics gld_throughput./sumMatrix 32 32
sumMatrixOnGPU2D <<<(512,512),  (32,32)>>> Global Load Throughput  35.908GB/s
$ nvprof --metrics gld_throughput./sumMatrix 32 16
sumMatrixOnGPU2D <<<(512,1024), (32,16)>>> Global Load Throughput  56.478GB/s
$ nvprof --metrics gld_throughput./sumMatrix 16 32
sumMatrixOnGPU2D <<<(1024,512), (16,32)>>> Global Load Throughput  85.195GB/s
$ nvprof --metrics gld_throughput./sumMatrix 16 16
sumMatrixOnGPU2D <<<(1024,1024),(16,16)>>> Global Load Throughput  94.708GB/s
```

از آنجایی که مورد چهارم بیشترین **load throughput** را دارد، در نتیجه از مورد دوم کندتر می‌باشد(که تنها نصف این توان بارگزاری را دارد). از اینجا، می‌توانید ببینید که **load throughput** بالاتر همواره برابر با بالاترین پرفرمنس نیست. دلیل این موضوع را با یاد گرفتن این که ارتباطات حافظه‌ای درون **GPU** چطور کار می‌کند در فصل چهارم یاد خواهیم گرفت.

در ادامه، میزان کارآمدی بارگزاری را با استفاده از متریک **gld_efficiency** به دست بیاوریم، که نسبت **global load throughput** درخواست شده به **global load throughput** مورد نیاز است. در واقع این متریک واحدی است که نشان میدهد که یک برنامه چقدر عملیات‌های بارگزاری را به خوبی استفاده می‌کند. نتایج در زیر خلاصه شده است:

```
$ nvprof --metrics gld_efficiency ./sumMatrix 32 32
sumMatrixOnGPU2D <<<(512,512),  (32,32)>>> Global Memory Load Efficiency 100.00%
$ nvprof --metrics gld_efficiency ./sumMatrix 32 16
sumMatrixOnGPU2D <<<(512,1024), (32,16)>>> Global Memory Load Efficiency 100.00%
$ nvprof --metrics gld_efficiency ./sumMatrix 16 32
sumMatrixOnGPU2D <<<(1024,512), (16,32)>>> Global Memory Load Efficiency 49.96%
$ nvprof --metrics gld_efficiency ./sumMatrix 16 16
sumMatrixOnGPU2D <<<(1024,1024),(16,16)>>> Global Memory Load Efficiency 49.80%
```

از این نتایج می‌توانیم بفهمیم که، **load efficiency** برای دو مورد آخر نصف دو مورد اول می‌باشد. این می‌توان توضیحی برای این باشد که حتی با داشتن **load throughput** و **achieved occupancy** بالاتر دو مورد آخر پرفرمنس بالاتری نداشته اند. با این وجود که تعداد بارگزاری‌های حافظه در دو مورد دوم بیشتر بوده(**throuput**) ، میزان کارآمدی این بارگزاری‌های (**efficiency**) پایین‌تر بوده.

توجه داشته باشید که ویژگی عمومی برای دو مورد آخر اندازه‌ی بلاک داخلی بوده که نصف می‌باشد. در ابتدای صحبت گفتیم که ابعاد داخلی باید مضربی از **warp size** باشد تا پرفرمنس بیشتری بگیریم. فصل چهارم در مورد این که چطور **half-warp** می‌تواند روی پرفرمنس تاثیر بگذارد بحث خواهد کرد.

۱۷ افزایش میزان موازی‌سازی

نتیجه‌ای که از بحث پیشین داشتیم این است که داخلی‌ترین بعد از **block** یعنی **block.x** باید مضربی از اندازه‌ی رشته باشد. با این کار دیدیم که **load efficiency** خیلی بهبود پیدا کرد. باز هم ممکن است که شما در موارد زیر کنجکاو باشید:

- آیا این امکان وجود دارد که میزان **load throughput** را با تنظیم **block.x** افزایش دهیم؟
- آیا امکان افزایش میزان موازی‌سازی وجود دارد؟

حال که یک رفرنس برای پرفرمنس درست کرده‌ایم، این سوالات را می‌توان با تست کردن **sumMatrix** در یک طیف گسترده‌تر از تنظیمات آزمود:

```
$ ./sumMatrix 64 2
sumMatrixOnGPU2D <<<(256,8192), (64,2) >>> elapsed 0.033567 sec
$ ./sumMatrix 64 4
sumMatrixOnGPU2D <<<(256,4096), (64,4) >>> elapsed 0.034908 sec
$ ./sumMatrix 64 8
sumMatrixOnGPU2D <<<(256,2048), (64,8) >>> elapsed 0.036651 sec
$ ./sumMatrix 128 2
sumMatrixOnGPU2D <<<(128,8192), (128,2)>>> elapsed 0.032688 sec
$ ./sumMatrix 128 4
sumMatrixOnGPU2D <<<(128,4096), (128,4)>>> elapsed 0.034786 sec
$ ./sumMatrix 128 8
sumMatrixOnGPU2D <<<(128,2048), (128,8)>>> elapsed 0.046157 sec
$ ./sumMatrix 256 2
sumMatrixOnGPU2D <<<(64,8192),  (256,2)>>> elapsed 0.032793 sec
$ ./sumMatrix 256 4
sumMatrixOnGPU2D <<<(64,4096),  (256,4)>>> elapsed 0.038092 sec
$ ./sumMatrix 256 8
sumMatrixOnGPU2D <<<(64,2048),  (256,8)>>> elapsed 0.000173 sec
Error: sumMatrix.cu:163, code:9, reason: invalid configuration argument
```

در اینجا برخی نتیجه‌گیری‌ها که از این نتایج گرفته‌ایم را با هم می‌بینیم:

- آخرین تنظیمی که انجام داده‌ایم یعنی (۲۵۶,۸) نامعتبر است. تعداد کل تردهای درون **block** برابر با ۲۵۶*۸=۱۰۲۴ شده که از محدودیت سخت‌افزاری **GPU** عبور کرده است.
- بهترین نتیجه توسط مورد چهارم بدست آمده که ابعاد بلاک (۱۲۸,۲) می‌باشد.
- با این وجود که اولین مورد یعنی (۶۴,۲) بیشترین تعداد **thread block** را دارد، سریع‌ترین نیست.
- از آنجایی که دومین مورد دارای تنظیم (۶۴,۶) می‌باشد و تعداد ترد برابری با بهترین مورد دارد، هر دو مورد باید میزان موازی‌سازی برابر را داشته باشند. ولی چون نسبت به (۱۲۸,۲) پرفرمنس کمتری دارد می‌توانیم نتیجه بگیریم که ابعاد داخلی نقش مهم‌تری در پرفرمنس دارند.
- همه‌ی موارد دیگر تعداد **thread block** کمتری نسبت به بهترین مورد دارند. در نتیجه، توانایی موازی‌سازی بیشتر، همچنان به عنوان یک فاکتور مهم در بهینه‌سازی محسوب می‌شود.

شاید حدس زده باشید که تعداد **thread block** های بیشتر باید **achieved occupancy** بیشتری را گزارش بدهند. این فرضیه را می‌توان با گرفتن متریک **achieved_occupancy** با استفاده از **nvprof** گرفت:

```
$ nvprof --metrics achieved_occupancy ./sumMatrix 64 2
sumMatrixOnGPU2D <<<(256,8192), (64,2) >>>  Achieved Occupancy    0.554556
$ nvprof --metrics achieved_occupancy ./sumMatrix 64 4
sumMatrixOnGPU2D <<<(256,4096), (64,4) >>>  Achieved Occupancy    0.798622
$ nvprof --metrics achieved_occupancy ./sumMatrix 64 8
sumMatrixOnGPU2D <<<(256,2048), (64,8) >>>  Achieved Occupancy    0.753532
$ nvprof --metrics achieved_occupancy ./sumMatrix 128 2
sumMatrixOnGPU2D <<<(128,8192), (128,2)>>>  Achieved Occupancy    0.802598
$ nvprof --metrics achieved_occupancy ./sumMatrix 128 4
sumMatrixOnGPU2D <<<(128,4096), (128,4)>>>  Achieved Occupancy    0.746367
```

```
$ nvprof --metrics achieved_occupancy ./sumMatrix 128 8
sumMatrixOnGPU2D <<<(128,2048), (128,8)>>>  Achieved Occupancy    0.573449
$ nvprof --metrics achieved_occupancy ./sumMatrix 256 2
sumMatrixOnGPU2D <<<(64,8192), (256,2) >>>  Achieved Occupancy    0.760901
$ nvprof --metrics achieved_occupancy ./sumMatrix 256 4
sumMatrixOnGPU2D <<<(64,4096), (256,4) >>>  Achieved Occupancy    0.595197
```

شاید تعجب کرده باشید که اولین مورد (۶۴,۲) کمترین مقدار **achieved occupancy** را در بین همه دارد، در حالی که بیشترین تعداد **thread block** را دارد. در واقع در این مورد به محدودیت سخت‌افزاری روی تعداد **thread block** ها خورده ایم.

مورد چهارم (۱۲۸,۲) و مورد هفتم (۲۵۶,۲) ، بهترین عملکرد را دارند، که تقریبا به **achieved occupancy** ایده‌ال رسیده‌اند. شاید جالب باشه که وقتی که **block.y** برابر با ۱ هست نیز پرفرمنس رو اندازه بگیریم. با این کار اندازه‌ی هر **thread block** را کاهش داده‌ایم، و این یعنی تعداد **thread block** بیشتری برای پردازش میزان برابر از داده کار خواهد کرد. با این کار نتایج زیر را در خروجی گرفته‌ایم:

```
$ ./sumMatrix 128 1
sumMatrixOnGPU2D <<<(128,16384),(128,1)>>> elapsed 0.032602 sec
$ ./sumMatrix 256 1
sumMatrixOnGPU2D <<<(64,16384), (256,1)>>> elapsed 0.030959 sec
```

این تنظیمات بهترین پرفرمنس را تا به این جای کار به ما داد. به طور مشخص، تنظیم (۲۵۶,۱) نسبت به تنظیم (۱۲۸,۱) دارای پرفرمنس بالاتری بوده است. شما می‌توانید مقدار **load** ، **achieved occupancy** **throughput** و **load efficiency** را با دستور زیر بگیرید:

```
$ nvprof --metrics achieved_occupancy ./sumMatrix 256 1
$ nvprof --metrics gld_throughput ./sumMatrix 256 1
$ nvprof --metrics gld_efficiency ./sumMatrix 256 1
```

که نتایج زیر را در خروجی به ما میدهد:

```
Achieved Occupancy                0.808622
Global Load Throughput            69.762GB/s
Global Memory Load Efficiency     100.00%
```

توجه داشته باشید که بهترین تنظیمات اجرایی که شما پیدا کرده اید نه بالاترین مقدار **achieved occupancy** را دارد و نه بیشترین مقدار **load throughput** را به ثبت رسانده. از این تست‌ها می‌توانیم نتیجه بگیریم که تنها یک متریک نمی‌تواند به طور مستقیم باعث بالا بردن پرفرمنس شود. شما باید به دنبال تعادل بین چندین پارامتر باشید تا پرفرمنس کل را بتوانید بالا ببرید:

- **در بسیاری از موارد، یک متریک تنها نمی‌تواند بیان کننده پرفرمنس باشد.**
- **این که چه متریکی بیشترین تاثیر را روی پرفرمنس کلی دارد وابسته به طبیعت کد کرنل نوشته شده دارد.**
- **به دنبال یک تعادل خوب بین متریک‌های مرتبط باشید.**
- **کرنل را از زوایای متفاوت چک کرده و بهترین تعادل را بین متریک‌های مرتبط پیدا کنید.**

۱۸ جلوگیری از انشعاب رشته

در برخی موارد، کنترل جریان محاسبات وابسته به اندیس ترد است. اجرای شرطی در داخل یک رشته ممکن است که منجر به انشعاب رشته شود که آن هم منجر به پرفرمنس پایین می‌شود. با چینش دوباره‌ی داده می‌توان انشعاب رشته را کاهش داد و یا از بین برد. در این بخش، برخی تکنیک‌های ابتدایی را برای جلوگیری از انشعاب رشته را با همدیگر بحث خواهیم کرد. در اینجا مثال **parallel reduction** را با هم خواهیم دید.

۱۹ مساله‌ی parallel reduction

فرض کنید که قصد دارید جمع آرایه‌های صحیح یک آرایه را حساب کنید، این آرایه **N** المان داشته. این مساله برای پیاده‌سازی به صورت سریال خیلی آسان است:

```
int sum = 0;
for (int i = 0; i < N; i++)
sum += array[i];
```

حال اگر تعداد المان‌ها خیلی بزرگ باشد چه؟چطور می‌توان این جمع را به صورت موازی انجام داد؟ از آنجایی که عمل جمع وابسته به موقعیت نیست، می‌توان المان‌ها را در هر ترتیبی با همدیگر جمع کرد. بنابراین جمع را می‌توان به صورت موازی و به شکل زیر انجام داد:

۱. تقسیم کردن داده‌ی ورودی با قسمت‌های کوچکتر

۲. تردی داشته باشیم که مسول جمع روی هر قسمت باشد.

۳. نتایج هر قسمت را در نهایت با همدیگر جمع کنیم.

یک راه متداول برای جمع موازی استفاده از پیاده‌سازی زوج‌وار است: یک بخش از داده تنها شامل یک زوج از داده ها بوده، و هر ترد دو المان مربوط به خودش را جمع می‌کند تا نتایج جزیی به دست بیاید. این نتایج بر روی بردار اصلی ذخیره شده. این مقادیر جدید برای تکرار بعدی دوباره استفاده می‌شود. از

آنجایی که تعداد ورودی در هر تکرار نصف می‌شود، جمع نهایی را می‌توان وقتی که طول بردار به یک می‌رسد، نتیجه نهایی به دست آورده می‌شود.

بر اساس این که نتایج در هر تکرار در کجای بردار ذخیره می‌شود، الگوریتم را می‌توان به دو دسته تقسیم بندی کرد:

- **زوج‌های همسایه**: المان‌ها با زوج‌های کنار هم به عنوان یک بخش از داده شناخته می‌شوند.
- زوج‌های **interleaved** : زوج‌ها با یک گام مشخص از یکدیگر جدا هستند.

شکل زیر الگوریتم **زوج‌های همسایه** را نشان میدهد. در این پیاده‌سازی، یک ترد دو المان نزدیک به هم را برای تولید جمع جزیی در هر گام برداشته و جمع می‌کند. برای یک آرایه با **N** المان، این پیاده‌سازی نیازمند **N-1** بار جمع کردن بوده و تعداد گام‌ها نیز **log2(N)** می‌باشد.

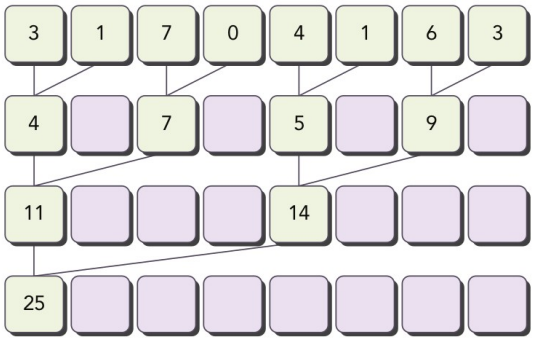

شکل زیر الگوریتم **زوج‌های interleaved** را نشان میدهد. توجه داشته باشید که در این پیاده‌سازی ورودی‌های تردها نصف طول بردار ورودی در هر گام هست.

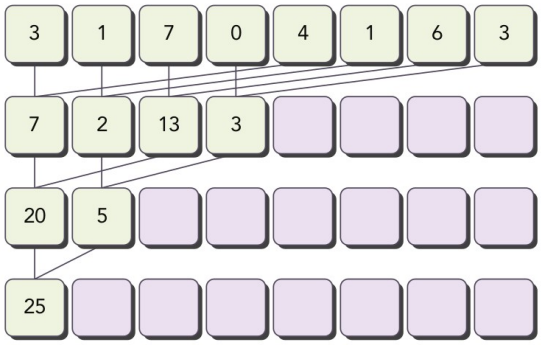

تابع زیر یک تابع برگشتی از رویکرد **interleaved pair** می‌باشد:

```
int recursiveReduce(int *data, int const size) {
    // terminate check
    if (size == 1) return data[0];
    // renew the stride
    int const stride = size / 2;
    // in-place reduction
```

```
    for (int i = 0; i < stride; i++) {
        data[i] += data[i + stride];
    }
    // call recursively
    return recursiveReduce(data, stride);
}
```

در حالی که کد بالا عملیات جمع را پیاده‌سازی می‌کند، هر عملیات تجمعی و وابسته را می‌توان به جای جمع گذاشت. به طور مثال، بیشینه مقدار ورودی را می‌توان با محاسبه‌ی همین تابع و فراخوانی تابع **max** انجام داد. مثال‌های دیگر مانند مینیمم، میانگین و ضرب هستند. چنین الگوریتمی را مساله‌ی **reduction problem** می‌نامند. حال **parallel reduction** یک اجرای موازی از این عملیات است و کلید بسیاری از عملیات‌های موازی به حساب میآید.

در این بخش، ما چندین پیاده‌سازی از کرنل‌های **parallel reduction** را خواهیم داشت، و این موضوع را بررسی خواهیم کرد که چطور پیاده‌سازی‌های مختلف روی پرفرمنس تاثیر میگذارد.

۲۰ انشعاب در مساله‌ی parallel reduction

به عنوان یک نقطه‌ی شروع، تجربه‌ی پیاده‌سازی زوج‌های همسایگی را پیدا خواهیم کرد که در شکل زیر نشان داده شده. هر ترد دو المان نزدیک به هم را با همدیگر جمع کرده تا به نتیجه‌ی نهایی برسیم.

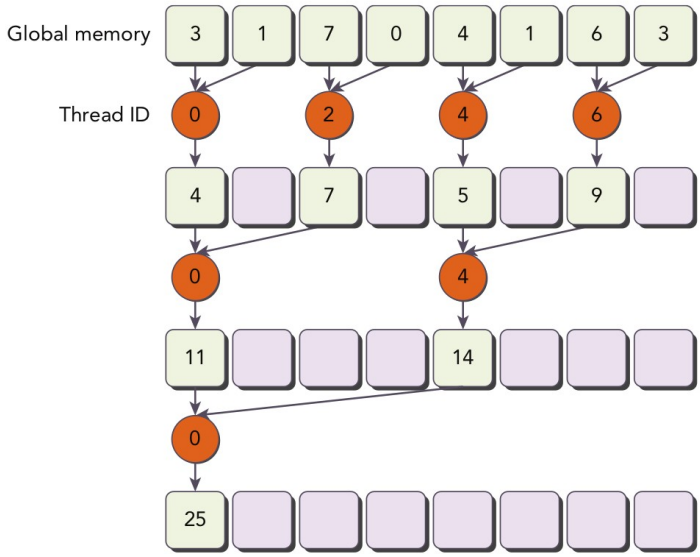

در این کرنل، دو حافظه‌ی **global** وجود دارد: یک آرایه‌ی بزرگ برای ذخیره‌ی آرایه اصلی، و یک آرایه‌ی کوچکتر برای نگه‌داری جمع‌های جزیی هر **thread block** . هر **thread block** به صورت مستقل عملیات خودش را بر روی قسمتی از دیتا پیدا می‌کند. یک تکرار از حلقه یک گام **reduction** را انجام میدهد. عمل **reduction** به صورت **in-place** انجام می‌شود، یعنی این که مقادیر در حافظه‌ی **global** با نتایج جمع جدید جایگزین می‌شوند. عبارت **syncthreads___** این اطمینان را به ما میدهد که قبل از این که تردی

در یک **block** **thread** یکسان مرحله‌ی بعدی را شروع بکند، همه‌ی مقادیر در حافظه‌ی **global** ذخیره شده باشند. همه‌ی تردهایی که وارد مرحله‌ی بعدی می‌شوند، مقادیری که در گام قبلی تولید شده را مصرف می‌کنند. پس از اتمام کار، نتایج جمع روی حافظه‌ی **global memory** ذخیره می‌شود.

```
__global__ void reduceNeighbored(int *g_idata, int *g_odata, unsigned int n) {
    // set thread ID
    unsigned int tid = threadIdx.x;
    // convert global data pointer to the local pointer of this block
    int *idata = g_idata + blockIdx.x * blockDim.x;
    // boundary check
    if (idx >= n) return;
    // in-place reduction in global memory
    for (int stride = 1; stride < blockDim.x; stride *= 2) {
        if ((tid % (2 * stride)) == 0) {
            idata[tid] += idata[tid + stride];
        }
        // synchronize within block
        __syncthreads();
    }
    // write result for this block to global mem
    if (tid == 0) g_odata[blockIdx.x] = idata[0];
}
```

فاصله بین دو همسایگی المان‌ها، یا همان **stride** در ابتدا با ۱ شروع می‌شود. پس از هر دور **reduction** ، این فاصله در ۲ ضرب می‌شود. پس از اولین راند، موقعیت‌های زوج از **idata** با جمع جزیی جایگزین می‌شود. پس از راند دوم، هر مضرب چهار از **idata** جایگزین شده و جمع‌جزیی جلوتر می‌رود. از آنجایی که هیچگونه سنکرون‌سازی بین **block** **thread** ها وجود ندارد، جمع جزیی‌ای که توسط هر **thread** **block** تولید می‌شود روی **host** کپی شده و روی آن به صورت ترتیبی جمع می‌شود که در شکل زیر نشان داده شده است.

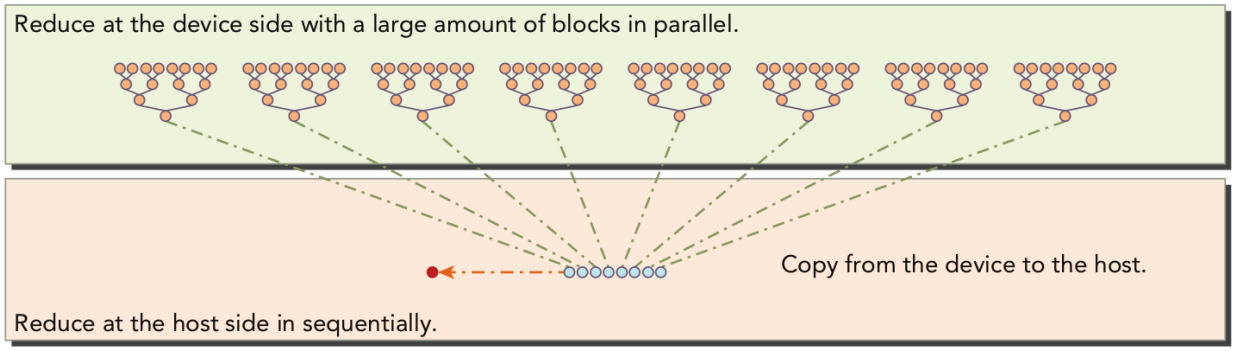

The distance between two neighbor elements, stride , is initialized to 1 at fi rst. After each reduction round, this distance is multiplied by 2. After the fi rst round, the even elements of idata will be replaced by partial sums. After the second round, every fourth element of idata will be replaced with further partial sums. Because there is no synchronization between thread blocks, the partial sum produced by each thread block is copied back to the host and summed sequentially there, as illustrated in Figure 3-22.

۲۱ موازی‌سازی پویا

تا اینجای کتاب، همه‌ی کرنل‌ها از سمت ترد **host** اجرا شده‌اند. عملیات **GPU** کاملا تحت کنترل **CPU** بوده. **CODA Dynamic Parallelism** به ما اجازه میدهد که کرنل‌های جدید را روی **GPU** ایجاد و سنکرون کنیم. این توانایی که بتوانیم موازی‌سازی را به **GPU** به صورت پویا اضافه کنیم در برخی کاربردها توانایی‌های جدیدی را به ما می‌دهد.

تا اینجا، شما باید الگوریتم خودتان رو به صورت مجزا تعریف می‌کردید، که موازی‌سازی دیتای سنگین اجرا می‌شد. موازی‌سازی دینامیک به شما اجازه میدهد که یک رویکرد با سلسله‌مراتبی بیشتر داشته باشید که در آن همروندی در چندین مرتبه روی کرنل **GPU** می‌باشد.با استفاده از موازی‌سازی دینامیک الگوریتم بازگشتی خیلی شفاف‌تر می‌شود.

با استفاده از موازی‌سازی پویا، شما می‌توانید این که اندازه‌ی **block** و **grid** چقدر باشد را تا **runtime** به تعویق بیندازید، و از مزیت‌های برنامه‌ریز سخت‌افزاری **GPU** و تعدیل کننده‌ی بار و تطبیق آن بر اساس داده یا بار باشد.

این توانایی که با **GPU** به طور مستقیم کار کنیم می‌تواند دستورات کنترلی که از سمت **host** هست را کاهش دهد، همچنین داده‌ای که بین **host** و **device** جابه‌جا می‌شود کاهش پیدا می‌کند، همچنانکه تنظیمات کرنل می‌تواند در **runtime** گرفته شود.

در این بخش، شما یک دید اولیه از این که چطور موازی‌سازی پویا کار می‌کند به دست خواهید آورد.

با استفاده از موازی‌سازی پویا، مفاهیم مربوط به تنظیمات اجرایی(گریدها، بلاک‌ها و تنظیمات اجرا و ...) که با آن‌ها آشنا هستید، همچنان بر روی فراخوانی کرنل صدق خواهد کرد. در واقع همان **syntax** ای که قبلا داشتیم در موازی‌سازی پویا استفاده می‌شود، اجرای کرنل بـه دو دسـته تقسـیم می‌شـود: **parent** و **child**. یک ترد **parent**، یک **parent thread block** و یا **parent grid** وظیفه‌ی تولید یک **grid** جدید را به عهده خواهند داشت که **child grid** محسوب می‌شود. یک **child thread**،یک **child thread block** و یا یک **child grid** توسط **parent** اجرا خواهد شد. یک **child grid** باید قبل از **parent thread** ، یا **parent thread block** و یا **parent grid** اجرا شود. یک **parent** را نمی‌توان تکمیل شده فرض کـرد مگـر این کـه همه‌ی **child**های آن پایان پذیرفته باشد.

شکل زیر **scope** مربوط به **parent grid** و **child grid** را نشان میدهد. **Parent grid** توسط ترد **host** تنظیم و اجرا می‌شود، و تنظیمات **child grid** توسط **parent grid** است. اجرا و اتمام **child grid** به صورت کاملا **nested** بوده، به این معنی که **parent grid** را نمی‌توان کامل شده فرض کرد مگر این که همه‌ی تردهایی که توسط آن به وجود آمده‌اند کامل شوند. اگر تردها به طور صریح روی **child grid** ها سـنکرون نشـود، **runtime** این اطمینان را به ما میدهد که یـک سـنکرون سـازی غـیر صـریح بین **parent** و **child** وجـود داشته باشد. در این شکل، روی **parent thread** یک **barrier** ست شده تا به طور صریح سنکرون سـازی داشته باشیم.

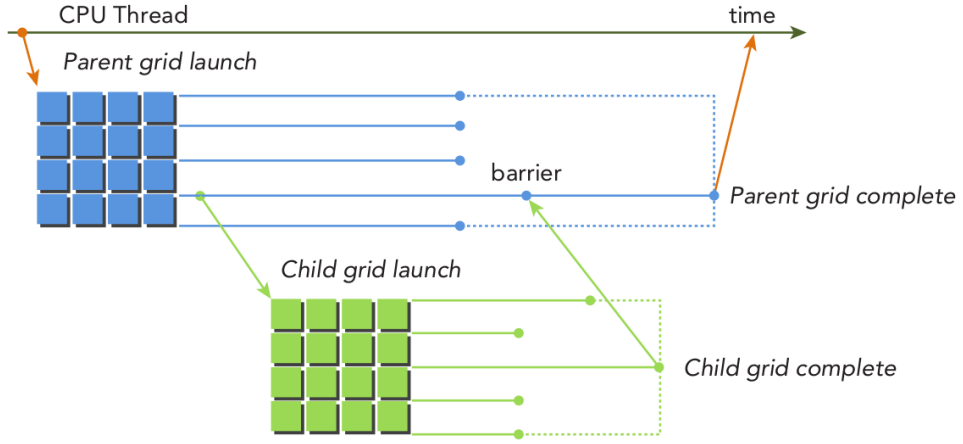

FIGURE 3-26

Figure 3-26 illustrates the scope of a parent grid and child grid. The parent grid is confi gured and launched by the host thread, and the child grid is confi gured and launched by the parent grid. The invocation and completion of the child grid must be properly nested, meaning that the parent grid is not considered complete until all child grids created by its threads have completed. If the invoking

threads do not explicitly synchronize on the launched child grids, the runtime guarantees an implicit synchronization between the parent and child. In this fi gure, a barrier is set in the parent thread to explicitly synchronize with its child grid.